

Página www

Página de Abertura

Contenido



Página 1 de 22

Regresar

Full Screen

Cerrar

Abandonar

Estadística Bayesiana: Clase 11

Juan Carlos Correa

8 de abril de 2021

Parcial I

Determine el impacto que tiene el sector de los peluqueros en la economía de Medellín. Para hacer esto y con la ayuda de tres expertos, determine:

- El número de peluqueros (estos reciben nombres tales como estilistas, barberos, etc.) que hay en la ciudad (una distribución discreta elicitada).
- Elicite el número promedio de servicios a clientes (pueden ser los mismos clientes varias veces) que atiende cada peluquero en un mes.
- Elicite el ingreso promedio por servicio.

Con esto determine el ingreso total del sector por mes (en forma de distribución) usando las tres distribuciones elicitadas. Construya un marco teórico donde discuta la importancia del sector tanto a nivel social como a nivel económico. Documente detalladamente todo el proceso de elicitación.

Página www

Página de Abertura

Contenido



Página 3 de 22

Regresar

Full Screen

Cerrar

Abandonar

Pruebas de Hipótesis Bayesianas

- La aproximación bayesiana a las pruebas de hipótesis está basada en el cálculo de de la probabilidad condicional de una hipótesis H_0 dada la información disponible.

- Cuando la hipótesis nula es $H_0 : \theta \in \Theta_0$ y la alternativa $H_1 : \theta \in \Theta_1$, con $\Theta_0 \cap \Theta_1 = \emptyset$, son formuladas, hay creencias apriori sobre ambas, digamos $\xi(H_0)$ y $\xi(H_1)$, con

$$\xi(H_0) + \xi(H_1) = 1$$

- Por el teorema de la probabilidad total, la distribución apriori de θ es:

$$\xi(\theta) = \xi(\theta|H_0)\xi(H_0) + \xi(\theta|H_1)\xi(H_1)$$

donde $\xi(\theta|H_i)$, son las densidades apriori de θ , condicionadas en cada hipótesis.

La información muestral es utilizada entonces para calcular de los odds apriori:

$$\frac{\xi(H_0)}{\xi(H_1)}$$

los odds posteriores en favor de H_0 :

$$\frac{\xi(H_0|\mathbf{y})}{\xi(H_1|\mathbf{y})} = \frac{p(y|H_0)}{p(y|H_1)} \frac{\xi(H_0)}{\xi(H_1)}$$

de la cual se deriva la siguiente regla de decisión:

- | | |
|--|----------------------------|
| Si $\xi(H_0 \mathbf{y}) < \xi(H_1 \mathbf{y})$ | Rechace H_0 |
| Si $\xi(H_0 \mathbf{y}) > \xi(H_1 \mathbf{y})$ | Acepte H_0 |
| Si $\xi(H_0 \mathbf{y}) = \xi(H_1 \mathbf{y})$ | Indecisión acerca de H_0 |

Página [www](#)

Página de Abertura

Contenido



Página 6 de 22

Regresar

Full Screen

Cerrar

Abandonar

Factor de Bayes

La razón

$$\frac{p(y|H_0)}{p(y|H_1)}$$

es llamado el factor de Bayes, denotado por BF o $B_{01}(y)$.

- Queremos probar

$$H_0 : \theta \in \Theta_0 \text{ versus } \mathbf{y} : \theta \in \Theta_1$$

- Sea $f(x|\theta)$ la verosimilitud de x dado θ .
- Tenemos las siguientes formas del factor de Bayes

$$B_{01}(x) = \frac{f(x|\theta_0)}{f(x|\theta_1)} \quad (\text{Prueba simple vs. simple})$$

$$B_{01}(x) = \frac{f(x|\theta_0)}{\int_{\Theta_1} f(x|\theta)\xi_1(\theta)d\theta} \quad (\text{Prueba simple vs. compuesta})$$

$$B_{01}(x) = \frac{\int_{\Theta_0} f(x|\theta_0)\xi_0(\theta)d\theta}{\int_{\Theta_1} f(x|\theta)\xi_1(\theta)d\theta} \quad (\text{Prueba compuesta vs. compuesta})$$

Página [www](#)

Página de Abertura

Contenido



Página 8 de 22

Regresar

Full Screen

Cerrar

Abandonar

	$\log_{10} BF > 2$	Evidencia decisiva a favor de H_0 ,
2	$> \log_{10} BF > 1,5$	Evidencia muy fuerte a favor H_0 ,
1	$> \log_{10} BF > 1,5$	Evidencia sustancial a favor H_0 ,
0,5	$> \log_{10} BF > 0$	Evidencia a favor H_0 , pero apenas para mencionar.
-0,5	$< \log_{10} BF < 0$	Evidencia contra H_0 , pero apenas para mencionar.
-1	$< \log_{10} BF < -1,5$	Evidencia sustancial contra H_0 ,
-1,5	$< \log_{10} BF < -1$	Evidencia fuerte contra H_0 ,
-2	$< \log_{10} BF < -1,5$	Evidencia muy fuerte contra H_0 ,
	$\log_{10} BF < -2$	Evidencia decisiva contra H_0 ,

[Página www](#)[Página de Abertura](#)[Contenido](#)[Página 9 de 22](#)[Regresar](#)[Full Screen](#)[Cerrar](#)[Abandonar](#)

Cuando las probabilidades apriori son iguales, el factor de Bayes determina la regla de decisión. La evaluación del factor de Bayes involucra el cálculo de

$$p(y|H_0) = \int p(y|H_0, \theta) \xi(\theta|H_0) d\theta$$

$$p(y|H_1) = \int p(y|H_1, \theta) \xi(\theta|H_1) d\theta$$

Cuando las probabilidades apriori son iguales, el factor de Bayes determina la regla de decisión. La evaluación del factor de Bayes involucra el cálculo de

$$p(y|H_0) = \int p(y|H_0, \theta) \xi(\theta|H_0) d\theta$$

$$p(y|H_1) = \int p(y|H_1, \theta) \xi(\theta|H_1) d\theta$$

Página [www](#)

Página de Abertura

Contenido



Página **11** de **22**

Regresar

Full Screen

Cerrar

Abandonar

- El factor de Bayes proporciona una indicación de cuánto cambian nuestras razones de probabilidad de una situación sin datos, a la luz de los datos, para favorecer un modelo.
- Puede verse como una medida de la evidencia proporcionada por los datos en favor de un modelo comparado con un competidor. El logaritmo del factor de Bayes ha sido llamado *el peso de la evidencia* proporcionada por los datos (De Santis y Spezzaferri, 1999).

[Página www](#)[Página de Abertura](#)[Contenido](#)[Página 12 de 22](#)[Regresar](#)[Full Screen](#)[Cerrar](#)[Abandonar](#)

El factor de Bayes puede verse como la versión bayesiana de la prueba clásica de la razón de verosimilitudes (De Santis y Spezzaferri, 1999). Si se asumen dos hipótesis simples, digamos H_1 y H_2 , el factor de Bayes se reduce a la razón de verosimilitud

$$\frac{f(y|H_1)}{f(y|H_2)}.$$

Ejemplo

- Suponga que deseamos verificar si la hipótesis que el número promedio de goles del equipo local marcados en el primer tiempo de un partido en el campeonato colombiano es 1.0 ó menos es más plausible que si el promedio es mayor que 1.0.
- Asumamos que el número de goles metidos por el local en el primer tiempo se distribuye $\text{Poisson}(\lambda)$.
- Las hipótesis serán:
 - $H_1 : \lambda \leq 1$
 - $H_2 : \lambda > 1$

Suponga que a priori $\xi(H_1) = 0,4$ y $\xi(H_2) = 0,6$.

- Bajo H_1 la apriori sobre Θ_1 la escogemos $Beta(\alpha_0, \beta_0)$ y
- bajo H_2 asumimos una normal truncada con parámetros μ_0 y σ_0^2 .

El factor de Bayes es

$$\frac{p(y|H_1)}{p(y|H_2)} = \frac{\int p(y|H_1, \lambda) \xi(\lambda|H_1) d\lambda}{\int p(y|H_2, \lambda) \xi(\lambda|H_2) d\lambda}$$

Ahora

$$p(y|H_i) = \int_{\Theta_i} \frac{\lambda^y \exp(-n\lambda)}{y!} \xi(\lambda|H_i) d\lambda = E_{\xi_i}[P(Y = y|\lambda)]$$

Para H_1

$$p(y|H_1) = \int_0^1 \frac{\lambda^y \exp(-n\lambda)}{y!} \frac{\Gamma(\alpha_0 + \beta_0)}{\Gamma(\alpha_0) \Gamma(\beta_0)} \lambda^{\alpha_0-1} (1-\lambda)^{\beta_0-1} d\lambda$$

Un algoritmo que nos permite estimar este valor sería:

1. Genere $\lambda_1, \lambda_2, \dots, \lambda_M$ de una *Beta* (α_0, β_0) .
2. Calcule $p_i = P(y|n\lambda_i)$, $i = 1, 2, \dots, M$
3. Calcule

$$p_{H_1} = p(y|H_1) \approx \frac{1}{M} \sum_{i=1}^M p_i$$

Para H_2

$$p(y|H_2) = \int_1^{\infty} \frac{\lambda^y \exp(-n\lambda)}{y!} \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left(-\frac{1}{2\sigma_0^2}(\lambda - \mu_0)^2\right) d\lambda$$

Un algoritmo que nos permite estimar este valor sería:

1. Genere $\lambda_1, \lambda_2, \dots, \lambda_M$ de una Normal truncada $\lambda \sim N(\mu_0, \sigma_0^2)I(\lambda > 1)$
2. Calcule $p_i = P(y|n\lambda_i)$, $i = 1, 2, \dots, M$
3. Calcule

$$p_{H_2} = p(y|H_2) \approx \frac{1}{M} \sum_{i=1}^M p_i$$

Página www

Página de Abertura

Contenido



Página 17 de 22

Regresar

Full Screen

Cerrar

Abandonar

El factor de Bayes Simulado

$$BF \approx \frac{p_{H_1}}{p_{H_2}}$$

Datos muestrales

Datos observados: Campeonato 2002 I primeras 4 fechas Goles marcados por el local el primer tiempo

0,1,0,2,1,0,2,1,1, 1,0,1,0,1,0,1,1,0, 0,0,3,0,0,0,0,1,0,
0,2,0,1,0,1,0,1,0.

Por suficiencia $y = \sum_{i=1}^n x_i \sim Poisson(n\lambda)$

Ejemplo de Factor de Bayes

```
# Modelo muestral Poisson(lamb)
```

```
# H1: lam<=1
```

```
# H2: lam>1
```

```
# apriori bajo H1--> beta(a0,b0)
```

```
# apriori bajo H2--> normal tuncada(u0,s20)
```

```
# Datos observados: Campeonato 2002 I primeras 4 fechas
```

```
# Goles marcados por el local el primer tiempo
```

```
x<-c(0,1,0,2,1,0,2,1,1,  
1,0,1,0,1,0,1,1,0,  
0,0,3,0,0,0,0,1,0,  
0,2,0,1,0,1,0,1,0)
```

```
a0<-2
```

```
b0<-3
```

```
mu0<-1.5
```

```
sigma0<-1.0
```

Página [www](#)

Página de Abertura

Contenido



Página 20 de 22

Regresar

Full Screen

Cerrar

Abandonar

Cálculo exacto...

```
f.int<-function(la) dpois(y,n*la)*dbeta(la,a0,b0)
res.H1<-integrate(f.int,0,1)$value
```

```
f.int2<-function(la) dpois(y,n*la)*dnorm(la,mu0,
sd=sigma0)/pnorm(1.0,mu0,sd=sigma0,lower.tail=F)
```

```
res.H2<- integrate(f.int2,1,Inf)$value
```

```
> (BF.verd<-res.H1/res.H2)
[1] 224.3688
```

```
log10(BF.verd)
[1] 2.511194
```

Página www

Página de Abertura

Contenido



Página 21 de 22

Regresar

Full Screen

Cerrar

Abandonar

```
> razon.apriori<-0.4/0.6
```

```
> razon.apriori
```

```
[1] 0.6666667
```

```
> #razon.aposteriori
```

```
> 0.6666667*224.3688
```

```
[1] 149.5792
```

```
set.seed(12345)
Nsim<-100000
lambdas0<-rbeta(Nsim,a0,b0)

lambda.min<-1.0
lambdas1<-qnorm(runif(Nsim,min=pnorm(lambda.min,mean=mu0,
sd=sigma0),max=1),mean=mu0,sd=sigma0)

y<-sum(x)
n<-length(x)

calcula.Poisson<-function(lam,y,n)dpois(y,n*lam)

p.H0<-mean(sapply(lambdas0,calcula.Poisson,y,n))
p.H1<-mean(sapply(lambdas1,calcula.Poisson,y,n))

(BF<-p.H0/p.H1)
[1] 225.0946

log10(BF)
[1] 2.352365
```