

Página www

Página de Abertura

Contenido



Página 1 de 54

Regresar

Full Screen

Cerrar

Abandonar

Estadística Bayesiana: Clase 14

Juan Carlos Correa

20 de abril de 2021

Aproximación Bayesiana vía Simulación

Suponga tenemos una población Multinomial con k categorías. El problema lo trabajaremos usando la familia conjugada Dirichlet. Además queremos realizar inferencias acerca de θ , un parámetro que es una función de $(\pi_1, \pi_2, \dots, \pi_k)$, por ejemplo

- $\theta = \frac{\pi_1}{\pi_2}$
- $\theta = \frac{\pi_1 \pi_4}{\pi_2 \pi_3}$
- $\theta = \log(\pi_1) \log(\pi_2)$
- $\theta = (\theta_1, \theta_2) = \left(\frac{\pi_2}{\pi_1}, \frac{\pi_3}{\pi_1} \right)$
- etc.

Algoritmo

1. Genere π_i de la *Dirichlet* $(\alpha_i + \mathbf{n}_i)$ para $i = 1, 2, \dots, k$.
2. Haga $\pi' = (\pi'_1, \pi'_2, \dots, \pi'_k)$
3. Calcule

$$\theta = g(\pi'_1, \pi'_2, \dots, \pi'_k)$$

Repita los pasos 1 a 3 muchas veces, digamos N . Al final se obtendrá

$$\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$$

la distribución posterior de θ se aproxima mediante un “histograma” de los valores calculados.

Tabla 2×2

Ejemplo de niños zurdos

La siguiente tabla presenta información sobre niños zurdos y el sexo:

	Zurdo	Diestro
Niño	79	202
Niña	57	138

La pregunta que nos surge es: Hay más niños zurdos que niñas?

Esquema Producto-Binomial

	Éxito	Fracaso
Pob. I	π_1	$1 - \pi_1$
Pob. II	π_2	$1 - \pi_2$

En esta situación se sacan dos muestras independientes con tamaños predeterminados, digamos n_1 y n_2 . Aquí nos interesa comparar las distribuciones de las dos poblaciones binomiales, o sea comparar π_1 con π_2 . La función de verosimilitud de los datos será

	Éxito	Fracaso
Pob. I	x_1	$n_1 - x_1$
Pob. II	x_2	$n_2 - x_2$

La verosimilitud será

$$L(\pi_1, \pi_2) \propto \pi_1^{x_1} (1 - \pi_1)^{n_1 - x_1} \pi_2^{x_2} (1 - \pi_2)^{n_2 - x_2}$$

Apriori

Problema: Se pueden definir varias apriori.

- Por ejemplo una apriori conjunta para (π_1, π_2) , por ejemplo

$$\xi(\pi_1, \pi_2) \propto \pi_1^{\alpha_1-1} (1 - \pi_1)^{\beta_1-1} \pi_2^{\alpha_2-1} (1 - \pi_2)^{\beta_2-1}$$

Este es el caso más sencillo ya que corresponde a la conjugada. La aposteriori será

$$\xi(\pi_1, \pi_2 | \text{Datos}) \propto \pi_1^{\alpha_1+x_1-1} (1 - \pi_1)^{n_1-x_1+\beta_1-1} \pi_2^{\alpha_2+x_2-1} (1 - \pi_2)^{n_2-x_2+\beta_2-1}$$

- Una apriori sobre $\pi_1 - \pi_2$
- Una apriori sobre π_1/π_2

Ejemplo de los niños.

```
# Suponga apriori Beta(1,1)xBeta(1,1)
pi1<-rbeta(1000,79+1,202+1)
pi2<-rbeta(1000,57+1,138+1)
```

```
plot(pi1,pi2)
library(KernSmooth)
```

```
x <- cbind(pi1, pi2)
est <- bkde2D(x, bandwidth=c(0.7,7))
contour(est$x1, est$x2, est$fhat)
persp(est$fhat)
```

```
dif<-pi1-pi2
summary(dif)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.12510	-0.03980	-0.01140	-0.01182	0.01590	0.10900

Página [www](#)

Página de Abertura

Contenido



Página 8 de 54

Regresar

Full Screen

Cerrar

Abandonar

```
library(hdrcde)
hdr.den(dif)
$hdr
      [,1]      [,2]
99% -0.11388344 0.09407083
95% -0.09382573 0.06901195
50% -0.03672022 0.01884642

$mode
[1] -0.00719232

$falpha
      1%      5%     50%
0.5544871 1.5005082 7.6356746

hdr.boxplot.2d(pi1, pi2)
```


Página [www](#)

Página de Abertura

Contenido




Página 9 de 54

Regresar

Full Screen

Cerrar

Abandonar



Página [www](#)

Página de Abertura

Contenido




Página 10 de 54

Regresar

Full Screen

Cerrar

Abandonar



Página [www](#)

Página de Abertura

Contenido



Página 11 de 54


Regresar

Full Screen

Cerrar

Abandonar

density.default(x = x, bw = h)



[Página www](#)

[Página de Abertura](#)

[Contenido](#)




[Página 12 de 54](#)

[Regresar](#)

[Full Screen](#)

[Cerrar](#)

[Abandonar](#)



Esquema Multinomial

	B	B^c
A	π_{11}	π_{12}
A^c	π_{21}	π_{22}

$$\sum_i \sum_j \pi_{ij} = 1$$

En esta situación se sacan una muestra con tamaño predefinido, digamos N . Aquí nos interesa determinar si las dos variables son dependientes o no. O sea queremos ver si $\pi_{ij} = \pi_{i+} \pi_{+j}$. La función de verosimilitud de los datos será

	B	B^c
A	x_{11}	x_{12}
A^c	x_{21}	x_{22}

La verosimilitud será

$$L(\pi_{11}, \pi_{12}, \pi_{21}, \pi_{22}) \propto \pi_{11}^{x_{11}} \pi_{12}^{x_{12}} \pi_{21}^{x_{21}} \pi_{22}^{x_{22}}$$

Bajo el esquema multinomial la distribución apriori no informativa puede seleccionarse de una amplia clase:

- **Apriori Uniforme**

$$\xi(\pi_1, \pi_2, \pi_3, \pi_4) \propto 1$$

- **Apriori de Jeffreys**

$$\xi(\pi_1, \pi_2, \pi_3, \pi_4) \propto \pi_1^{-1/2} \pi_2^{-1/2} \pi_3^{-1/2} \pi_4^{-1/2}$$

La razón de odds

La siguiente tabla presenta el modelo poblacional para una tabla 2×2 , donde cada celda presenta la probabilidad de ella.

	A	A^c
B	$P(A \cap B)$	$P(A^c \cap B)$
B^c	$P(A \cap B^c)$	$P(A^c \cap B^c)$

Los odds^a de que el evento B ocurra relativo al evento A se define como la razón de las probabilidades

$$\frac{P[B \mid A]}{P[B^c \mid A]}$$

La interpretación de la razón anterior es directa: Asumiendo que el evento A ha ocurrido, esta razón nos dice cuántas veces ocurre el evento B por cada aparición del evento B^c . Los odds de B relativo a A^c son

$$\frac{P[B \mid A^c]}{P[B^c \mid A^c]}$$

^aLa palabra *odds* no tiene una única y precisa traducción, algunos la traducen como disparidad y otros como apuestas.

Cornfield (1951) definió la razón de odds como

$$\psi = \frac{\frac{P[B|A]}{P[B^c|A]}}{\frac{P[B|A^c]}{P[B^c|A^c]}}$$

- La interpretación es clara.
- Valores de ψ que se alejen de 1.0 en una dirección particular representa una asociación fuerte.
- Dos valores de ψ pueden representar un mismo nivel de asociación (un valor y su inverso) pero en direcciones opuestas.
- Valores menores que uno indican una asociación negativa, mientras valores mayores que 1 indican una asociación positiva.
- Para simetrizar esta medida se trabaja con el $\log(\psi)$.

Tabla 2×2

Ejemplo de habilidad manual de esposos

La siguiente tabla presenta información sobre la destreza manual del esposo y la esposa:

	Esposa	
Esposo	Zurda	Diestra
Zurdo	1	13
Diestro	20	284

La pregunta que nos surge es: hay independencia entre la habilidad manual del esposo y la de la esposa?

```
library(MCMCpack)
res<-rdirichlet(10000,c(1+1,13+1,20+1,284+1))
```

```
log.OR<-log(res[,1]*res[,4]/(res[,2]*res[,3]))
```

```
> summary(log.OR)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-4.28776	-0.04726	0.55672	0.47431	1.07621	3.37960

```
> summary(exp(log.OR))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.01374	0.95384	1.74494	2.25216	2.93354	29.35900

```
> hdr.den(log.OR,main='Distribución Posterior del log(OR)')
```

```
$hdr
```

	[,1]	[,2]
--	------	------

99%	-2.1751819	2.574805
-----	------------	----------

95%	-1.2844725	2.138309
-----	------------	----------

50%	0.1082924	1.217970
-----	-----------	----------

```
$mode
```

```
[1] 0.7007231
```

```
$falpha
```

	1%	5%	50%
	0.01613558	0.06673433	0.36814598

Página [www](#)

Página de Abertura

Contenido



Página 19 de 54

Regresar

Full Screen

Cerrar

Abandonar

```
> hdr.den(exp(log.OR),main='Distribución Posterior del OR')  
$hdr
```

	[,1]	[,2]	[,3]	[,4]
99%	-0.22562515	8.800509	9.15823	9.465179
95%	-0.08071155	5.863276	NA	NA
50%	0.35235364	1.960321	NA	NA

```
$mode
```

```
[1] 0.8342001
```

```
$falpha
```

	1%	5%	50%
	0.003528188	0.025444277	0.247903836

Página [www](#)

Página de Abertura

Contenido



Página 20 de 54


Regresar

Full Screen

Cerrar

Abandonar

Distribución Posterior del log(OR)



Página [www](#)

Página de Abertura

Contenido



Página 21 de 54


Regresar

Full Screen

Cerrar

Abandonar

Distribución Posterior del OR



MCMC: Monte Carlo por Cadenas de Markov

Los métodos MCMC son algoritmos iterativos que se utilizan cuando el muestreo directo de una distribución de interés ξ no es factible.

Una cadena de Markov es generada muestreando

$$\theta^{(t+1)} \sim p\left(\theta | \theta^{(t)}\right)$$

Este p es llamado el *kernel de transición* de la cadena de Markov. Así $\theta^{(t+1)}$ depende solo de $\theta^{(t)}$, y no de $\theta^{(0)}, \theta^{(1)}, \dots, \theta^{(t-1)}$

Glosario de Cadenas de Markov

Irreducibilidad Una cadena de Markov X_1, X_2, \dots es irreducible si la cadena puede moverse libremente a través del espacio de estados; esto es, para dos estados cualesquiera x y x' , existe un n tal que

$$P(X_n = x' | X_0 = x) > 0.$$

Recurrencia Una cadena de Markov es recurrente si el número promedio de visitas a un estado arbitrario es infinito.

Período Un estado x tiene período d si $P(X_{n+t} = x | X_t = x) = 0$ si n no es divisible por d , donde d es el mayor entero con esta propiedad.

Aperiodicidad Si un estado x tiene período $d = 1$ se dice que es aperiódico.

En una cadena irreducible todos los estados tienen el mismo período. Si ese período es $d = 1$, la cadena de Markov es aperiódica.

Convergencia a una Distribución Estacionaria

Si una cadena de Markov con espacio de estados contable X_1, X_2, \dots es positiva, recurrente y aperiódica con distribución estacionaria π , entonces desde cualquier estado inicial

$$X_n \rightarrow X \sim \pi$$

Ergodicidad Una cadena de Markov positiva, recurrente y aperiódica es llamada ergódica.

Convergencia de Sumas (Teorema Ergódico)

Si una cadena de Markov con espacio de estados contable X_1, X_2, \dots es ergódica con distribución estacionaria π , entonces desde cualquier estado inicial

$$\frac{1}{n} \sum_{i=1}^n h(X_i) \rightarrow E_{\pi}[h(X)]$$

Algoritmo Metropolis-Hastings

- El muestreo de importancia y el muestreo de rechazo trabajan bien si la densidad propuesta $q(\theta)$ es similar a $p(\theta)$.
- En problemas complejos puede ser difícil crear una única $q(\theta)$ que tenga esta propiedad.
- El algoritmo Metropolis utiliza una densidad propuesta q que depende del estado actual de $\theta^{(t)}$.
- La densidad $q(\theta'|\theta^{(t)})$ puede ser tan simple como una normal localizada en $\theta^{(t)}$ y no es necesario que se parezca a $p(\theta)$.

El algoritmo se resume así:

1. Comience en cualquier lugar, y digamos que estamos en $\theta^{(t)} = \theta$.
2. Genere θ^* de $q(\theta^*|\theta)$. θ^* es llamado un *punto candidato* y q es llamada una *distribución propuesta*.
3. Calcule

$$\alpha(\theta, \theta^*) = \min \left\{ 1, \frac{\xi(\theta^*|\text{Datos}) q(\theta|\theta^*)}{\xi(\theta|\text{Datos}) q(\theta^*|\theta)} \right\}$$

4. Acepte $\theta^{(t+1)} = \theta^*$ con probabilidad $\alpha(\theta, \theta^*)$.
5. En otro caso $\theta^{(t+1)} = \theta$