

Introducción al Análisis Multivariado

SEMANA-4: Distribución Normal Multivariada-I

Raúl Alberto Pérez

Universidad Nacional de Colombia

Escuela de Estadística

Semestre 2021-I

Oficina 43-216A

Correo: raperez1@unal.edu.co

Distribución Normal Multivariada

Normal Univariada: Una v.a $X \sim N(\mu, \sigma^2)$, si su f.d.p es:

$$\begin{aligned} f(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2} = \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \\ &= \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\sigma^2}} e^{-\frac{1}{2}(x-\mu)(\sigma^2)^{-1}(x-\mu)} \\ &= \frac{1}{(2\pi)^{1/2}} \frac{1}{(\sigma^2)^{1/2}} e^{-\frac{1}{2}(x-\mu)^t(\sigma^2)^{-1}(x-\mu)} \end{aligned}$$

donde, $E[X] = \mu$ y $Var[X] = \sigma^2$.

NOTA: Notar que $\left(\frac{X-\mu}{\sigma}\right)^2 = (X - \mu)^t(\sigma^2)^{-1}(X - \mu)$, es el cuadrado de la distancia entre X y μ escalada por su desviación estándar.

Normal Multivariada

En el caso multivariado, se trabaja con la distancia de Mahalanobis entre el vector aleatorio \underline{x} y su vector de media poblacional $\underline{\mu}$, es decir, con:

$$(\underline{x} - \underline{\mu})^t \Sigma^{-1} (\underline{x} - \underline{\mu}),$$

donde, $E[\underline{x}] = \underline{\mu}$ y $Var[\underline{x}] = \Sigma$.

Definición 1 (f.d.p Normal) .

Sea \underline{x} un vector aleatorio p -dimensional, ie. $\underline{x} \in \mathbb{R}^p$. Se dice que \underline{x} tiene una distribución aleatoria Normal-Multivariada (o normal p -variada), con vector de medias $\underline{\mu}$ y matriz de Var-Cov Σ , lo cual se denota por:

$\underline{x} \sim N_p(\underline{\mu}, \Sigma)$, si su f.d.p multivariada está dada por:


$$f(\underline{x}) = (2\pi)^{-\frac{p}{2}} \times |\Sigma|^{-\frac{1}{2}} \times e^{-\frac{1}{2}(\underline{x}-\underline{\mu})^t \Sigma^{-1} (\underline{x}-\underline{\mu})}.$$

Algunos Aspectos Geométricos de la Normal Multivariada


La expresión $(\underline{x} - \underline{\mu})^t \Sigma^{-1} (\underline{x} - \underline{\mu}) = c^2$, en la cual se basa el exponente de la f.d.p. normal multivariada, corresponde a un hiper-elipsoide, para cualquier constante $c > 0$, el cual está centrado en $\underline{\mu}$ y sus ejes están dados por: $\pm c \sqrt{\lambda_i} \underline{e}_i$ para $i = 1, 2, \dots, p$, donde los λ_i -son los valores propios de Σ asociados a los respectivos vectores propios \underline{e}_i .

Para el caso de $p = 3$ -un Elipsoide, para el caso de $p = 2$ -una Elipse.


Ejemplo 1 (Aspecto Gráfico) .




$$\underline{\mu} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 0.165 & 0 \\ 0 & 0.75 \end{bmatrix}$$



$$\underline{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 0.165 & 0 \\ 0 & 0.165 \end{bmatrix}$$



$$\underline{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 0.7 & 0.6 \\ 0.6 & 0.7 \end{bmatrix}$$



$$\underline{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 0.7 & -0.6 \\ -0.6 & 0.7 \end{bmatrix}$$

Ejemplo 2 (Aspecto Gráfico) .

Suponga que un vector aleatorio 2-dimensional \underline{x} tiene la siguiente matriz de Var-Cov,

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{11} \end{bmatrix}$$

es decir que: $\sigma_{11} = \sigma_{22}$. Graficar el elipsoide (la ellipse) correspondiente bajo la restricción de que $\rho = \text{Corr}(X, Y) > 0$. Es decir, dos variables con igual varianza y correlación positiva.

Solución :

Los ejes de la ellipse están dados por: $\pm c\sqrt{\lambda_i}\underline{e}_i$, para $i = 1, 2$ y $c > 0$, es decir: $\pm c\sqrt{\lambda_1}\underline{e}_1$ y $\pm c\sqrt{\lambda_2}\underline{e}_2$.

Ahora se deben hallar los valores propios de Σ , para lo cual se debe resolver la ecuación característica dada por:

$$|\Sigma - \lambda I_2| = 0.$$

$$|\Sigma - \lambda I_2| = \left| \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{11} \end{pmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \right| = \begin{vmatrix} \sigma_{11} - \lambda & \sigma_{12} \\ \sigma_{12} & \sigma_{11} - \lambda \end{vmatrix}$$

$$= (\sigma_{11} - \lambda)^2 - \sigma_{12}^2$$

$$= (\sigma_{11} - \lambda - \sigma_{12})(\sigma_{11} - \lambda + \sigma_{12})$$

Al hacer, $(\sigma_{11} - \lambda - \sigma_{12})(\sigma_{11} - \lambda + \sigma_{12}) = 0$ se obtiene que:

$$\lambda_1 = \sigma_{11} + \sigma_{12} \text{ y que } \lambda_2 = \sigma_{11} - \sigma_{12}.$$

Ahora los vectores propios asociados a estos valores propios se obtienen resolviendo la ecuación:

$$\Sigma \underline{e} = \lambda \underline{e}$$

Por Ejemplo si,

$\underline{e}_1 = \begin{bmatrix} e_1 \\ e_2 \end{bmatrix}$ -es el vector propio asociado al valor propio $\lambda_1 = \sigma_{11} + \sigma_{12}$, entonces debe cumplir que:

$$\begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{11} \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \end{pmatrix} = (\sigma_{11} + \sigma_{12}) \begin{pmatrix} e_1 \\ e_2 \end{pmatrix},$$

de donde, se obtiene el siguiente sistema de ecuaciones:

$$\sigma_{11}e_1 + \sigma_{12}e_2 = (\sigma_{11} + \sigma_{12})e_1 \implies e_1 = e_2$$

$$\sigma_{12}e_1 + \sigma_{11}e_2 = (\sigma_{11} + \sigma_{12})e_2 \implies e_1 = e_2$$

El vector,

$$\underline{\mathbf{e}}_1 = \begin{bmatrix} e_1 \\ e_2 \end{bmatrix} = \begin{bmatrix} e_1 \\ e_1 \end{bmatrix} \quad \text{normalizado está dado por:}$$

$$\frac{\underline{\mathbf{e}}_1}{\|\underline{\mathbf{e}}_1\|} = \frac{(e_1, e_1)}{\|(e_1, e_1)\|} = \frac{(e_1, e_1)}{\sqrt{2e_1^2}} = \left(\frac{e_1}{e_1\sqrt{2}}, \frac{e_1}{e_1\sqrt{2}} \right) = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$


De manera análoga, se encuentra que el segundo vector-propio asociado al segundo valor-propio:

$\lambda_2 = \sigma_{11} - \sigma_{12}$ es:

$$\underline{\mathbf{e}}_2^t = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

Ahora, Como $\rho = \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} > 0$, entonces $\sigma_{12} > 0$ y por lo tanto $\lambda_1 > \lambda_2$,
 pues: $\lambda_1 = \sigma_{11} + \sigma_{12} > \sigma_{11} > \sigma_{11} - \sigma_{12} = \lambda_2$.

De lo anterior se concluye que si $\sigma_{11} = \sigma_{22}$ y $\rho > 0$, entonces el eje mayor de la elipse está a lo largo de una línea cuya inclinación es de 45° y que pasa por el punto $\underline{\mu} = (\mu_1, \mu_2)$.



Ejemplo 3 Suponga que el vector aleatorio $\underline{x}^t = (X_1, X_2)$ tiene una distribución normal-bivariada, con vector de medias $\underline{\mu} = (\mu_1, \mu_2)$ y matriz de Var-Cov dada por Σ . Halla la f.d.p multivariada de \underline{x} .

Solución: Recordemos que la f.d.p normal bi-variada está dada por:

$$f(\underline{x}) = (2\pi)^{-\frac{2}{2}} |\Sigma|^{-\frac{1}{2}} e^{-\frac{1}{2}(\underline{x}-\underline{\mu})^t \Sigma^{-1}(\underline{x}-\underline{\mu})}.$$

Para

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}, \quad \Sigma^{-1} = \frac{1}{|\Sigma|} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}$$

con $|\Sigma| = \sigma_{11}\sigma_{22} - \sigma_{12}^2$, pero $\sigma_{12} = \rho\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}$, es decir que

$|\Sigma| = \sigma_{11}\sigma_{22} - \rho^2\sigma_{11}\sigma_{22} = \sigma_{11}\sigma_{22}(1 - \rho^2)$, de donde:

$$\Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22}(1 - \rho^2)} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}$$

Ahora se tiene que:

$$\begin{aligned}(\underline{\mathbf{x}} - \underline{\mu})^t \Sigma^{-1} (\underline{\mathbf{x}} - \underline{\mu}) &= \\ \frac{1}{\sigma_{11}\sigma_{22}(1 - \rho^2)} [x_1 - \mu_1 \quad x_2 - \mu_2] \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= \frac{1}{\sigma_{11}\sigma_{22}(1 - \rho^2)} \sigma_{22}(x_1 - \mu_1)^2 + \sigma_{11}(x_2 - \mu_2)^2 \\ &\quad - 2\rho\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}(x_1 - \mu_1)(x_2 - \mu_2) \\ &= \frac{1}{1 - \rho^2} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right]\end{aligned}$$

de donde

$$\begin{aligned}\frac{1}{2}(\underline{\mathbf{x}} - \underline{\mu})^t \Sigma^{-1} (\underline{\mathbf{x}} - \underline{\mu}) &= \\ \frac{1}{2(1 - \rho^2)} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right]\end{aligned}$$

y como $|\Sigma| = \sigma_{11}\sigma_{22}(1 - \rho^2)$, entonces

$$|\Sigma|^{-\frac{1}{2}} = [\sigma_{11}\sigma_{22}(1 - \rho^2)]^{-\frac{1}{2}}$$


por lo tanto,

$$\begin{aligned} f(\underline{\mathbf{x}}) &= f(x_1, x_2) = (2\pi)^{-\frac{2}{2}} |\Sigma|^{-\frac{1}{2}} e^{-\frac{1}{2}(\underline{\mathbf{x}} - \underline{\mu})^t \Sigma^{-1}(\underline{\mathbf{x}} - \underline{\mu})} \\ &= (2\pi)^{-1} [\sigma_{11}\sigma_{22}(1 - \rho^2)]^{-\frac{1}{2}} \\ &\quad \text{Exp} \left[-\frac{1}{2(1 - \rho^2)} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_1 - \mu_2}{\sqrt{\sigma_{22}}} \right) + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \right] \\ &= (2\pi)^{-1} [\sigma_{11}\sigma_{22}(1 - \rho^2)]^{-\frac{1}{2}} \text{Exp} \left[-\frac{1}{2(1 - \rho^2)} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 \right] \\ &\quad \text{Exp} \left[-\frac{1}{2(1 - \rho^2)} \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \text{Exp} \left[\frac{\rho}{1 - \rho^2} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_1 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right] \end{aligned}$$


Ahora, si las variables X_1 y X_2 tienen $\rho = 0$ entonces:

$$\begin{aligned} f(\underline{\mathbf{x}}) &= f(x_1, x_2) = (2\pi)^{-1} |\Sigma|^{-\frac{1}{2}} e^{-\frac{1}{2}(\underline{\mathbf{x}} - \underline{\mu})^t \Sigma^{-1} (\underline{\mathbf{x}} - \underline{\mu})} \\ &= (2\pi)^{-1} [\sigma_{11}\sigma_{22}]^{-\frac{1}{2}} \text{Exp} \left[-\frac{1}{2} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 - \frac{1}{2} \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \\ &= \frac{1}{\sqrt{2\pi}\sqrt{\sigma_{11}}} \text{Exp} \left[-\frac{1}{2} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 \right] \frac{1}{\sqrt{2\pi}\sqrt{\sigma_{22}}} \text{Exp} \left[-\frac{1}{2} \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \\ f(x_1, x_2) &= f(x_1)f(x_2) \end{aligned}$$

con $f(x_1)$ la f.d.p de una normal uni-variada con media μ_1 y varianza σ_{11} y $f(x_2)$ la f.d.p de una normal uni-variada con media μ_2 y varianza σ_{22} , ie., si $\rho = 0$ entonces X_1 y X_2 son independientes, pues $f(x_1, x_2) = f(x_1)f(x_2)$.



$$\sigma_{11} = \sigma_{22}, \quad \rho = 0$$




$$\sigma_{11} = \sigma_{22}, \quad \rho = 0.750$$


Notar que la presencia de correlación causa que la probabilidad se concentre a lo largo de una línea.

La densidad normal multivariada tiene un máximo valor cuando la distancia cuadrática.

$(\underline{x} - \underline{\mu})^t \Sigma^{-1} (\underline{x} - \underline{\mu})$ es igual a cero, es decir, cuando $\underline{x} = \underline{\mu}$. Por tanto el punto $\underline{\mu}$ es el punto de máxima densidad, o la moda, y también es la media, como se observa en la siguiente gráfica.



Contornos de probabilidad



Definición 2 (Función Generadora de Momentos (FGM)) .

Caso Univariado:

Si una v.a $X \sim N_1(\mu, \sigma^2)$, entonces la FGM de X es:

$$M_X(t) := E[e^{tX}] = e^{\mu t + \frac{1}{2}\sigma^2 t^2}, \quad t \in \mathbb{R}$$

Definición 3 (Función Generadora de Momentos (FGM)) .

Caso Multivariado:

Si un vector aleatorio $\underline{X} \sim N_p(\underline{\mu}, \Sigma)$, entonces la FGM de \underline{X} es:

$$M_{\underline{X}}(\underline{t}) := E[e^{\underline{t}^t \underline{X}}] = e^{\underline{t}^t \underline{\mu} + \frac{1}{2} \underline{t}^t \Sigma \underline{t}}, \quad \underline{t} \in \mathbb{R}^p$$

Propiedades de la distribución Normal Multivariada

1. Si $\underline{X} \sim N_p(\underline{\mu}, \Sigma)$, entonces

$$\underline{a}^t \underline{X} = a_1 X_1 + a_2 X_2 + \dots + a_p X_p \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \Sigma \underline{a})$$

Análogamente,

si $\forall \underline{a} \in \mathbb{R}^p$: $\underline{a}^t \underline{X} \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \Sigma \underline{a})$ entonces $\underline{X} \sim N_p(\underline{\mu}, \Sigma)$,

es decir:

$$\underline{X} \sim N_p(\underline{\mu}, \Sigma) \iff \underline{a}^t \underline{X} \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \Sigma \underline{a})$$

Luego, si $\underline{X} \sim N_p(\underline{\mu}, \Sigma)$ entonces cada $X_i \sim N_1(\mu_i, \sigma_{ii})$,

lo cual se logra con $\underline{a} = (0, 0, \dots, 1, \dots, 0, 0)^t$ con 1-en la posición i -ésima del vector \underline{a} y $\underline{\mu}$ y Σ dados por:

$$\underline{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} \quad \text{y} \quad \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}$$

Demostración de 1:

$$\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma}) \iff \underline{a}^t \underline{X} \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \underline{\Sigma} \underline{a})$$

Sea la v.a $Y = \underline{a}^t \underline{X}$

$$\begin{aligned} M_Y(t) &= E[e^{tY}] = E\left[e^{t(\underline{a}^t \underline{X})}\right] = E\left[e^{(\underline{a}t)^t \underline{X}}\right], \text{ pues } (\underline{a}t)^t = t^t \underline{a}^t = t \underline{a}^t \\ &= M_{\underline{X}}(\underline{a}t) = e^{(\underline{a}t)^t \underline{\mu} + \frac{1}{2}(\underline{a}t)^t \underline{\Sigma} (\underline{a}t)} \end{aligned}$$

$$= e^{t \underline{a}^t \underline{\mu} + \frac{1}{2} t \underline{a}^t \underline{\Sigma} \underline{a} t} = e^{t(\underline{a}^t \underline{\mu}) + \frac{1}{2} t(\underline{a}^t \underline{\Sigma} \underline{a}) t}$$

$$= e^{t(\underline{a}^t \underline{\mu}) + \frac{1}{2} (\underline{a}^t \underline{\Sigma} \underline{a}) t^2}$$

es decir, la FGM de $Y = \underline{a}^t \underline{X}$ -corresponde a la FGM de una v.a normal univariada con media $\underline{a}^t \underline{\mu}$ y varianza $\underline{a}^t \underline{\Sigma} \underline{a}$, es decir:

$$Y = \underline{a}^t \underline{X} \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \underline{\Sigma} \underline{a}), \text{ l.q.q.d}$$

Ejemplo 4 :

Suponga que $\underline{\mathbf{x}} \sim N_3(\underline{\mu}, \Sigma)$ y considere la combinación lineal de las componentes de $\underline{\mathbf{x}}$ dada por:

$$\underline{y} = 2X_1 - X_2 + 3X_3 = \begin{bmatrix} 2 & -1 & 3 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} = \underline{a}^t \underline{\mathbf{x}}, \text{ con } \underline{a} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix}, \text{ ie.}$$

$$E[\underline{y}] = E[\underline{a}^t \underline{\mathbf{x}}] = \underline{a}^t \underline{\mu} = \begin{bmatrix} 2 & -1 & 3 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix} = 2\mu_1 - \mu_2 + 3\mu_3, \text{ y}$$

$$\begin{aligned}
Var[\underline{y}] &= Var[\underline{a}^t \underline{x}] = \underline{a}^t \underline{\Sigma} \underline{a} = \begin{bmatrix} 2 & -1 & 3 \end{bmatrix} \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_{22} & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_{33} \end{bmatrix} \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix} \\
&= \begin{bmatrix} 2\sigma_{11} - \sigma_{12} + 3\sigma_{13} & 2\sigma_{12} - \sigma_{22} + 3\sigma_{23} & 2\sigma_{13} - \sigma_{23} + 3\sigma_{33} \end{bmatrix} \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix} \\
&= 4\sigma_{11} - 2\sigma_{12} + 6\sigma_{13} - 2\sigma_{12} + \sigma_{22} - 3\sigma_{23} + 6\sigma_{13} - 3\sigma_{23} + 9\sigma_{33}
\end{aligned}$$

$$Var[\underline{y}] = 4\sigma_{11} + \sigma_{22} + 9\sigma_{33} - 4\sigma_{12} + 12\sigma_{13} - 6\sigma_{23}$$

Es decir que:

$$\underline{y} = \underline{a}^t \underline{X} = 2X_1 - X_2 + 3X_3 \sim N_1(\underline{a}^t \underline{\mu}, \underline{a}^t \underline{\Sigma} \underline{a}), \text{ con,}$$

$$\underline{a}^t \underline{\mu} = 2\mu_1 - \mu_2 + 3\mu_3$$

$$\underline{a}^t \underline{\Sigma} \underline{a} = 4\sigma_{11} + \sigma_{22} + 9\sigma_{33} - 4\sigma_{12} + 12\sigma_{13} - 6\sigma_{23}$$

2. Si $\underline{\mathbf{x}} \sim N_p(\underline{\mu}, \Sigma)$, entonces: $\underline{\mathbf{y}} = A\underline{\mathbf{x}} \sim N_q(A\underline{\mu}, A\Sigma A^t)$

Demostración de 2:

$$M_{\underline{\mathbf{y}}}(\underline{t}) = E \left[e^{\underline{t}^t \underline{\mathbf{y}}} \right] = E \left[e^{\underline{t}^t (A\underline{\mathbf{x}})} \right] = E \left[e^{\underline{t}^t A\underline{\mathbf{x}}} \right]$$

$$= E \left[e^{(A^t \underline{t})^t \underline{\mathbf{x}}} \right]; \quad \text{pues, } (A^t \underline{t})^t = \underline{t}^t A$$

$$= M_{\underline{\mathbf{x}}}(A^t \underline{t}) = e^{(A^t \underline{t})^t \underline{\mu} + \frac{1}{2} (A^t \underline{t})^t \Sigma (A^t \underline{t})} ;$$

$$\text{pues, } M_{\underline{\mathbf{x}}}(\underline{t}) = e^{\underline{t}^t \underline{\mu} + \frac{1}{2} \underline{t}^t \Sigma \underline{t}}$$

$$= e^{\underline{t}^t A \underline{\mu} + \frac{1}{2} \underline{t}^t A \Sigma A^t \underline{t}}$$

lo cual corresponde a la FGM de un Vector aleatorio normal multivariado con vector de medias $A\underline{\mu}$ y matriz de varianzas-covarianzas $A\Sigma A^t$, es decir:

$$\underline{y} = A\underline{X} \sim N_q\left(A\underline{\mu}, A\Sigma A^t\right), \text{ l.q.q.d.}$$

Ejemplo 5 .

Suponga que $\underline{x} \sim N_3(\underline{\mu}, \Sigma)$ y considere el vector de combinaciones lineales de las variables de \underline{x} dado por:

$$\underline{z} = A\underline{x} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} = \begin{bmatrix} X_1 - X_2 \\ X_2 - X_3 \end{bmatrix} = \begin{bmatrix} Z_1 \\ Z_2 \end{bmatrix}$$

entonces,

$$\underline{z} = A\underline{x} \sim N_q\left(A\underline{\mu}, A\Sigma A^t\right), \text{ donde}$$

$$A\underline{\mu} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{bmatrix} = \begin{bmatrix} \mu_1 - \mu_2 \\ \mu_2 - \mu_3 \end{bmatrix} = \begin{bmatrix} E[Z_1] \\ E[Z_2] \end{bmatrix}$$

$$\begin{aligned}
A\Sigma A^t &= \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} \sigma_{11} & \sigma_{12} & \sigma_{13} \\ \sigma_{12} & \sigma_{22} & \sigma_{23} \\ \sigma_{13} & \sigma_{23} & \sigma_{33} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{bmatrix} \\
&= \begin{bmatrix} \sigma_{11} - \sigma_{12} & \sigma_{12} - \sigma_{22} & \sigma_{13} - \sigma_{23} \\ \sigma_{12} - \sigma_{13} & \sigma_{22} - \sigma_{23} & \sigma_{23} - \sigma_{33} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{bmatrix} \\
&= \begin{bmatrix} \sigma_{11} - \sigma_{12} - \sigma_{12} + \sigma_{22} & \sigma_{12} - \sigma_{22} - \sigma_{13} + \sigma_{23} \\ \sigma_{12} - \sigma_{13} - \sigma_{22} + \sigma_{23} & \sigma_{22} - \sigma_{23} - \sigma_{23} + \sigma_{33} \end{bmatrix} \\
A\Sigma A^t &= \begin{bmatrix} \sigma_{11} - 2\sigma_{12} + \sigma_{22} & \sigma_{12} - \sigma_{22} - \sigma_{13} + \sigma_{23} \\ \sigma_{12} - \sigma_{22} - \sigma_{13} + \sigma_{23} & \sigma_{22} - 2\sigma_{23} + \sigma_{33} \end{bmatrix}
\end{aligned}$$

Ejemplo 6 .

Suponga que $\underline{x}' = (X_1, X_2, X_3) \sim N_3(\underline{\mu}, \Sigma)$, donde:

$$\underline{\mu} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}, \quad y \quad \Sigma = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Hallar la distribución conjunta de probabilidad de:

$$Z_1 = X_1 + X_2 + X_3 \quad y \quad Z_2 = X_1 - X_2.$$

Sea

$$\underline{z} = \begin{bmatrix} Z_1 \\ Z_2 \end{bmatrix} = \begin{bmatrix} X_1 + X_2 + X_3 \\ X_1 - X_2 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} = A\underline{x}, \quad \text{luego,}$$

$$\underline{z} = \begin{bmatrix} Z_1 \\ Z_2 \end{bmatrix} \sim N_2\left(A\underline{\mu}, A\Sigma A^t\right),$$

donde:

$$A\bar{\mu} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}_{2 \times 1}$$

y

$$\begin{aligned} A\Sigma A^t &= \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix} \\ &= \begin{bmatrix} 4 & 4 & 2 \\ 1 & -2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 10 & 0 \\ 0 & 3 \end{bmatrix} \end{aligned}$$

de lo anterior, Z_1 y Z_2 son independientes, pues $Cov(Z_1, Z_2) = 0$ y Z_1 y Z_2 son distribuidas normales uni-variadas.

3. Sea $\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma})$ y sean los vectores y matrices particionadas dadas por:

$$\underline{\mathbf{x}} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = \begin{bmatrix} \underline{\mathbf{x}}^{(1)} \\ \dots \\ \underline{\mathbf{x}}^{(2)} \end{bmatrix}, \quad \underline{\mu} = \begin{bmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{bmatrix} \quad y \quad \underline{\Sigma}_{p \times p} = \begin{bmatrix} \underline{\Sigma}_{11} & | & \underline{\Sigma}_{12} \\ \hline & & \\ \underline{\Sigma}_{21} & | & \underline{\Sigma}_{22} \end{bmatrix}$$

entonces:

$$\underline{\mathbf{x}}^{(1)} \sim N_q(\underline{\mu}^{(1)}, \underline{\Sigma}_{11})$$

$$\underline{\mathbf{x}}^{(2)} \sim N_{p-q}(\underline{\mu}^{(2)}, \underline{\Sigma}_{22}).$$

La anterior propiedad también se puede enunciar como sigue:

Todos los subconjuntos de variables de $\underline{\mathbf{x}}$ tienen distribución normal, sea univariada o multivariada.

Demostración de 3:

Para esto se usará la siguiente matriz particionada:

$$A_{q \times p} = \begin{matrix} & \begin{matrix} q & p-q \end{matrix} \\ \begin{matrix} q \end{matrix} & \left[\begin{matrix} \mathbf{I}_q & \vdots & \mathbf{O} \end{matrix} \right]_{q \times p} \end{matrix} = \left[\begin{matrix} \mathbf{I}_q & \vdots & \mathbf{O} \end{matrix} \right]_{q \times p}, \text{ luego,}$$

$$A\underline{X} = \left[\begin{matrix} \mathbf{I}_q & \vdots & \mathbf{O} \end{matrix} \right]_{q \times p} \begin{bmatrix} \underline{\mathbf{x}}^{(1)} \\ \vdots \\ \underline{\mathbf{x}}^{(2)} \end{bmatrix}_{p \times 1}$$

$$= \left[\begin{matrix} \mathbf{I}_q \underline{\mathbf{x}}^{(1)} & + & \mathbf{O} \underline{\mathbf{x}}^{(2)} \end{matrix} \right]_{q \times 1}$$

$$= \left[\begin{matrix} \mathbf{I}_q \underline{\mathbf{x}}^{(1)} \end{matrix} \right]_{q \times 1}$$

$$A\underline{X} = \left[\begin{matrix} \underline{\mathbf{x}}^{(1)} \end{matrix} \right]_{q \times 1} = \underline{\mathbf{x}}^{(1)}$$

de donde, usando la propiedad (2) se tiene que:

$$A\underline{X} = \underline{\mathbf{x}}^{(1)} \sim N_q(A\underline{\mu}, A\underline{\Sigma}A^t)$$

Pero,

$$\begin{aligned} A\underline{\mu} &= \begin{bmatrix} \mathbf{I}_q & \vdots & \mathbf{O} \end{bmatrix} \begin{bmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{I}_q \underline{\mu}^{(1)} & + & \mathbf{O} \underline{\mu}^{(2)} \end{bmatrix} \\ &= \begin{bmatrix} \mathbf{I}_q \underline{\mu}^{(1)} \end{bmatrix} \\ A\underline{\mu} &= \begin{bmatrix} \underline{\mu}^{(1)} \end{bmatrix}_{q \times 1} = \underline{\mu}^{(1)} \end{aligned}$$

$$A\Sigma A^t = \left[\begin{array}{ccc} \mathbf{I}_q & \vdots & \mathbf{O} \end{array} \right] \left[\begin{array}{c|c} \Sigma_{11} & \Sigma_{12} \\ \hline \Sigma_{21} & \Sigma_{22} \end{array} \right] \left[\begin{array}{c} \mathbf{I}_q \\ \cdots \\ \mathbf{O} \end{array} \right]$$

$$= \left[\begin{array}{ccc} \mathbf{I}_q \Sigma_{11} + \mathbf{O} \Sigma_{21} & \vdots & \mathbf{I}_q \Sigma_{12} + \mathbf{O} \Sigma_{22} \end{array} \right] \left[\begin{array}{c} \mathbf{I}_q \\ \cdots \\ \mathbf{O} \end{array} \right]$$

$$= \left[\begin{array}{ccc} \Sigma_{11} + \mathbf{O} & \vdots & \Sigma_{12} + \mathbf{O} \end{array} \right] \left[\begin{array}{c} \mathbf{I}_q \\ \cdots \\ \mathbf{O} \end{array} \right]$$

$$= \left[\begin{array}{ccc} \Sigma_{11} & \vdots & \Sigma_{12} \end{array} \right] \left[\begin{array}{c} \mathbf{I}_q \\ \cdots \\ \mathbf{O} \end{array} \right]$$

$$= \left[\begin{array}{ccc} \Sigma_{11} \mathbf{I}_q + \Sigma_{12} \mathbf{O} \end{array} \right] = \left[\begin{array}{ccc} \Sigma_{11} + \mathbf{O} \end{array} \right] = \Sigma_{11}$$

Es decir que:

$$\underline{\mathbf{x}}^{(1)} \sim N_q \left(A \underline{\mu}, A \Sigma A^t \right)$$

$$N_q \left(\underline{\mu}^{(1)}, \Sigma_{11} \right), \quad l.q.q.d.$$

De manera similar, se demuestra que: (TAREA):

$$\underline{\mathbf{x}}^{(2)} \sim N_q \left(\underline{\mu}^{(2)}, \Sigma_{22} \right),$$

en este caso usando la matriz particionada dada por:

$$A = \begin{matrix} & \begin{matrix} q & p-q \end{matrix} \\ \begin{matrix} p-q \end{matrix} & \left[\begin{array}{c|c} \mathbf{O} & \mathbf{I}_{p-q} \end{array} \right] \end{matrix} = \left[\begin{array}{c|c} \mathbf{O} & \mathbf{I}_{p-q} \end{array} \right]$$

Ejemplo 7 . Sea $\underline{x} \sim N_5(\underline{\mu}, \Sigma)$, hallar la distribución de: $\begin{bmatrix} X_2 \\ X_4 \end{bmatrix}$.

$$\text{Sean, } \underline{x}^{(1)} = \begin{bmatrix} X_2 \\ X_4 \end{bmatrix}, \quad \underline{\mu}^{(1)} = \begin{bmatrix} \mu_2 \\ \mu_4 \end{bmatrix} \quad y \quad \Sigma_{11} = \begin{bmatrix} \sigma_{22} & \sigma_{24} \\ \sigma_{24} & \sigma_{44} \end{bmatrix}$$

Asumiendo que \underline{x} , $\underline{\mu}$ y Σ son particionados como sigue:

$$\underline{x} = \begin{bmatrix} X_2 \\ X_4 \\ \dots \\ X_1 \\ X_3 \\ X_5 \end{bmatrix}, \quad \underline{\mu} = \begin{bmatrix} \mu_2 \\ \mu_4 \\ \dots \\ \mu_1 \\ \mu_3 \\ \mu_5 \end{bmatrix} \quad y \quad \Sigma = \begin{bmatrix} \sigma_{22} & \sigma_{24} & \vdots & \sigma_{12} & \sigma_{23} & \sigma_{25} \\ \sigma_{24} & \sigma_{44} & \vdots & \sigma_{14} & \sigma_{34} & \sigma_{45} \\ \dots & \dots & \dots & \dots & \dots & \dots \\ \sigma_{12} & \sigma_{14} & \vdots & \sigma_{11} & \sigma_{13} & \sigma_{15} \\ \sigma_{23} & \sigma_{34} & \vdots & \sigma_{13} & \sigma_{33} & \sigma_{35} \\ \sigma_{25} & \sigma_{45} & \vdots & \sigma_{15} & \sigma_{35} & \sigma_{55} \end{bmatrix}$$

$$\text{es decir: } \underline{x} = \begin{bmatrix} \underline{x}^{(1)} \\ \dots \\ \underline{x}^{(2)} \end{bmatrix}, \quad \underline{\mu} = \begin{bmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{bmatrix} \quad y \quad \Sigma = \begin{bmatrix} \Sigma_{11} & | & \Sigma_{12} \\ \hline \Sigma_{21} & | & \Sigma_{22} \end{bmatrix}$$

$$\text{luego: } \underline{x}^{(1)} \sim N_2(\underline{\mu}^{(1)}, \Sigma_{11}) \sim N_2\left(\begin{bmatrix} \mu_2 \\ \mu_4 \end{bmatrix}, \begin{bmatrix} \sigma_{22} & \sigma_{24} \\ \sigma_{24} & \sigma_{44} \end{bmatrix}\right).$$

4. (a) Si $\underline{\mathbf{x}}^{(1)}$ y $\underline{\mathbf{x}}^{(2)}$ son estadísticamente independientes, entonces $\Sigma_{12} = \Sigma_{21}^t = O$.

(b)

$$\text{Si, } \underline{\mathbf{x}} = \begin{bmatrix} \underline{\mathbf{x}}^{(1)} \\ \dots \\ \underline{\mathbf{x}}^{(2)} \end{bmatrix} \sim N_p \left[\begin{pmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & | & \Sigma_{12} \\ \hline \Sigma_{21} & | & \Sigma_{22} \end{pmatrix} \right]$$

entonces,

$$\underline{\mathbf{x}}^{(1)} \perp \underline{\mathbf{x}}^{(2)} \text{ si } \Sigma_{12} = \Sigma_{21}^t = O.$$

Ejemplo 8 Suponga que $\underline{\mathbf{x}} \sim N_3(\underline{\mu}, \Sigma)$, con

$$\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

¿Son las variables X_1 y X_2 independientes?

Rta. NO, porque $\sigma_{12} = 1 \neq 0$.

¿Son los siguientes vectores aleatorios independientes?:

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad y \quad \begin{bmatrix} X_3 \end{bmatrix}$$

$$\underline{\mathbf{x}} = \begin{bmatrix} X_1 \\ X_2 \\ \dots \\ X_3 \end{bmatrix}, \quad \underline{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \dots \\ \mu_3 \end{bmatrix} \quad y \quad \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \vdots & \sigma_{13} \\ \sigma_{21} & \sigma_{22} & \vdots & \sigma_{23} \\ \dots & \dots & \dots & \dots \\ \sigma_{31} & \sigma_{32} & \vdots & \sigma_{33} \end{bmatrix} = \begin{bmatrix} 4 & 1 & \vdots & 0 \\ 1 & 3 & \vdots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \vdots & 2 \end{bmatrix}$$

$$\text{luego para : } \underline{\mathbf{x}}^{(1)} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad y \quad \underline{\mathbf{x}}^{(2)} = \begin{bmatrix} X_3 \end{bmatrix}$$

$$\text{se tiene: } \Sigma_{12} = Cov(\underline{\mathbf{x}}^{(1)}, \underline{\mathbf{x}}^{(2)}) = \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

por lo tanto, si son independientes.

(c) Si $\underline{\mathbf{x}}^{(1)} \perp \underline{\mathbf{x}}^{(2)}$ y

$$\underline{\mathbf{x}}^{(1)} \sim N_q(\underline{\mu}^{(1)}, \Sigma_{11}) \text{ y } \underline{\mathbf{x}}^{(2)} \sim N_q(\underline{\mu}^{(2)}, \Sigma_{22})$$

entonces,

$$\underline{\mathbf{x}} = \begin{bmatrix} \underline{\mathbf{x}}^{(1)} \\ \dots \\ \underline{\mathbf{x}}^{(2)} \end{bmatrix} \sim N_p \left[\begin{pmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & | & O \\ \hline O & | & \Sigma_{22} \end{pmatrix} \right]$$

Además:

$$\underline{\mathbf{x}}^{(1)} + \underline{\mathbf{x}}^{(2)} \sim N_k(\underline{\mu}^{(1)} + \underline{\mu}^{(2)}, \Sigma_{11} + \Sigma_{22}), \text{ si } q = p - q = k$$

Demostración de 4(c): Para esto se usarán la FGM de un vector normal-multivariado. Sean

$$\underline{\mathbf{x}}^{(1)} \perp \underline{\mathbf{x}}^{(2)} , \quad \underline{\mathbf{x}}^{(1)} \sim N_q \left(\underline{\mu}^{(1)} , \Sigma_{11} \right) \quad y \quad \underline{\mathbf{x}}^{(2)} \sim N_q \left(\underline{\mu}^{(2)} , \Sigma_{22} \right)$$

$$M_{\underline{\mathbf{x}}^{(1)} + \underline{\mathbf{x}}^{(2)}}(\underline{t}) := E \left[e^{\underline{t}^t (\underline{\mathbf{x}}^{(1)} + \underline{\mathbf{x}}^{(2)})} \right] = E \left[e^{\underline{t}^t \underline{\mathbf{x}}^{(1)}} e^{\underline{t}^t \underline{\mathbf{x}}^{(2)}} \right]$$

$$= E \left[e^{\underline{t}^t \underline{\mathbf{x}}^{(1)}} \right] E \left[e^{\underline{t}^t \underline{\mathbf{x}}^{(2)}} \right] , \quad \text{pues, } \underline{\mathbf{x}}^{(1)} \perp \underline{\mathbf{x}}^{(2)}$$

$$= M_{\underline{\mathbf{x}}^{(1)}}(\underline{t}) M_{\underline{\mathbf{x}}^{(2)}}(\underline{t}) = e^{\underline{t}^t \underline{\mu}^{(1)} + \frac{1}{2} \underline{t}^t \Sigma_{11} \underline{t}} e^{\underline{t}^t \underline{\mu}^{(2)} + \frac{1}{2} \underline{t}^t \Sigma_{22} \underline{t}}$$

$$= e^{\underline{t}^t \underline{\mu}^{(1)} + \underline{t}^t \underline{\mu}^{(2)} + \frac{1}{2} \underline{t}^t \Sigma_{11} \underline{t} + \frac{1}{2} \underline{t}^t \Sigma_{22} \underline{t}} = e^{\underline{t}^t (\underline{\mu}^{(1)} + \underline{\mu}^{(2)}) + \frac{1}{2} \underline{t}^t (\Sigma_{11} + \Sigma_{22}) \underline{t}}$$

lo cual corresponde a la FGM de un vector aleatorio normal multivariado con vector de medias $\underline{\mu}^{(1)} + \underline{\mu}^{(2)}$ y matriz de varianzas covarianzas $\Sigma_{11} + \Sigma_{22}$,

es decir:

$$\underline{\mathbf{x}}^{(1)} + \underline{\mathbf{x}}^{(2)} \sim N_k\left(\underline{\mu}^{(1)} + \underline{\mu}^{(2)}, \Sigma_{11} + \Sigma_{22}\right), \quad l.q.q.d$$

Demostración de 5(a) y 5(b); (Ejercicio 4.14 del libro de Johnson, sixth edition)).

5. Si $\underline{\mathbf{x}} = \begin{bmatrix} \underline{\mathbf{x}}^{(1)} \\ \dots \\ \underline{\mathbf{x}}^{(2)} \end{bmatrix} \sim N_p \left[\begin{pmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & | & \Sigma_{12} \\ \hline \Sigma_{21} & | & \Sigma_{22} \end{pmatrix} \right]$, con $|\Sigma_{22}| > 0$,

entonces, la distribución condicional de $\underline{\mathbf{x}}^{(1)}$ dado $\underline{\mathbf{x}}^{(2)}$ esta dada por:

$$\underline{\mathbf{x}}^{(1)} | \underline{\mathbf{x}}^{(2)} = \underline{\mathbf{x}}^{(2)} \sim N_q \left[\underline{\mu}^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (\underline{\mathbf{x}}^{(2)} - \underline{\mu}^{(2)}), \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \right]$$

es decir:

$$E \left[\underline{\mathbf{x}}^{(1)} | \underline{\mathbf{x}}^{(2)} = \underline{\mathbf{x}}^{(2)} \right] = \underline{\mu}^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (\underline{\mathbf{x}}^{(2)} - \underline{\mu}^{(2)})$$

y

$$Var \left[\underline{\mathbf{x}}^{(1)} | \underline{\mathbf{x}}^{(2)} = \underline{\mathbf{x}}^{(2)} \right] = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

De manera similar, si $|\Sigma_{11}| > 0$, entonces:

$$\underline{\mathbf{x}}^{(2)} | \underline{\mathbf{x}}^{(1)} = \underline{\mathbf{x}}^{(1)} \sim N_{p-q} \left[\underline{\mu}^{(2)} + \Sigma_{21} \Sigma_{11}^{-1} (\underline{\mathbf{x}}^{(1)} - \underline{\mu}^{(1)}), \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \right]$$

Demostración de (5): Considere la matriz $p \times p$ dada por:

$$\mathbf{A} = \left[\begin{array}{c|c} \mathbf{I}_{q \times q} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \hline \mathbf{0}_{(p-q) \times q} & \mathbf{I}_{(p-q) \times (p-q)} \end{array} \right]_{p \times p}$$

teniendo en cuenta que el siguiente vector aleatorio:

$$(\underline{X} - \underline{\mu}) \sim N_p(\underline{0}, \Sigma)$$

se tiene que:

$$\begin{aligned} \underline{Z}_{p \times 1} = \mathbf{A}(\underline{X} - \underline{\mu}) &= \left[\begin{array}{c|c} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \hline \mathbf{0} & \mathbf{I} \end{array} \right] \begin{bmatrix} \underline{X}^{(1)} - \underline{\mu}^{(1)} \\ \underline{X}^{(2)} - \underline{\mu}^{(2)} \end{bmatrix} \\ &= \begin{bmatrix} \underline{X}^{(1)} - \underline{\mu}^{(1)} - \Sigma_{12}\Sigma_{22}^{-1} (\underline{X}^{(2)} - \underline{\mu}^{(2)}) \\ \underline{X}^{(2)} - \underline{\mu}^{(2)} \end{bmatrix} \sim N_p(\underline{\mu}_Z, \Sigma_Z) \end{aligned}$$

con, $\underline{\mu}_Z = \mathbf{A}\underline{0} = \underline{0}$ y $\underline{\Sigma}_Z = \mathbf{A}\underline{\Sigma}\mathbf{A}^t$

$$\mathbf{A}\underline{\Sigma}\mathbf{A}^t = \left[\begin{array}{c|c} \mathbf{I} & -\underline{\Sigma}_{12}\underline{\Sigma}_{22}^{-1} \\ \hline \mathbf{0} & \mathbf{I} \end{array} \right] \left[\begin{array}{c|c} \underline{\Sigma}_{11} & \underline{\Sigma}_{12} \\ \hline \underline{\Sigma}_{21} & \underline{\Sigma}_{22} \end{array} \right] \mathbf{A}^t$$

$$= \left[\begin{array}{c|c} \underline{\Sigma}_{11} - \underline{\Sigma}_{12}\underline{\Sigma}_{22}^{-1}\underline{\Sigma}_{21} & \mathbf{0} \\ \hline \underline{\Sigma}_{21} & \underline{\Sigma}_{22} \end{array} \right] \left[\begin{array}{c|c} \mathbf{I} & \mathbf{0} \\ \hline -\underline{\Sigma}_{22}^{-1}\underline{\Sigma}_{21} & \mathbf{I} \end{array} \right]$$

$$\underline{\Sigma}_Z = \left[\begin{array}{c|c} \underline{\Sigma}_{11} - \underline{\Sigma}_{12}\underline{\Sigma}_{22}^{-1}\underline{\Sigma}_{21} & \mathbf{0} \\ \hline \mathbf{0} & \underline{\Sigma}_{22} \end{array} \right], \text{ es decir que:}$$

$$\underline{\mathbf{Z}} = \left[\begin{array}{c} \underline{X}^{(1)} - \underline{\mu}^{(1)} - \underline{\Sigma}_{12}\underline{\Sigma}_{22}^{-1}(\underline{X}^{(2)} - \underline{\mu}^{(2)}) \\ \underline{X}^{(2)} - \underline{\mu}^{(2)} \end{array} \right] \sim N_p(\underline{\mu}_Z, \underline{\Sigma}_Z) = N_p(\underline{0}, \underline{\Sigma}_Z)$$

de lo anterior se tiene que como los vectores aleatorios:

$$\underline{Z}_1 = \underline{X}^{(1)} - \underline{\mu}^{(1)} - \Sigma_{12}\Sigma_{22}^{-1} \left(\underline{X}^{(2)} - \underline{\mu}^{(2)} \right) \quad \text{y} \quad \underline{Z}_2 = \underline{X}^{(2)} - \underline{\mu}^{(2)}$$

tienen matriz de var-cov 0, entonces son independientes (por (4.b)), y además se cumple que:

$$\underline{Z}_1 = \underline{X}^{(1)} - \underline{\mu}^{(1)} - \Sigma_{12}\Sigma_{22}^{-1} \left[\underline{X}^{(2)} - \underline{\mu}^{(2)} \right] \sim N_p \left(\underline{0}, \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \right)$$

por lo tanto, la distribución condicional de:

$$\underline{Z}_1 = \underline{X}^{(1)} - \underline{\mu}^{(1)} - \Sigma_{12}\Sigma_{22}^{-1} \left(\underline{X}^{(2)} - \underline{\mu}^{(2)} \right) \quad \text{dado} \quad \underline{Z}_2 = \underline{X}^{(2)} - \underline{\mu}^{(2)}$$

es igual a la marginal de:

$$\underline{Z}_1 = \underline{X}^{(1)} - \underline{\mu}^{(1)} - \Sigma_{12}\Sigma_{22}^{-1} \left(\underline{X}^{(2)} - \underline{\mu}^{(2)} \right)$$

cuando $\underline{X}^{(2)}$ toma un valor fijo, es decir,

$$\underline{x}^{(1)} \mid \underline{x}^{(2)} = \underline{X}^{(2)} \sim N_q \left[\underline{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1} \left(\underline{X}^{(2)} - \underline{\mu}^{(2)} \right), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \right]$$

Ejemplo 9 *Distribución condicional de una Normal-Bivariada.*

$$\text{Sea } \underline{\mathbf{x}} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim N_2 \left[\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_{11} & | & \sigma_{12} \\ \hline \sigma_{21} & | & \sigma_{22} \end{pmatrix} \right], \text{ con } \sigma_{22} > 0,$$

luego, la distribución condicional de $X_1 | X_2$ esta dada por:

$$X_1 | X_2 = x_2 \sim N_1 \left(\mu_1 + \frac{\sigma_{12}}{\sigma_{22}}(x_2 - \mu_2), \sigma_{11} - \frac{\sigma_{12}}{\sigma_{22}}\sigma_{21} \right)$$

pues,

$$\Sigma_{12}\Sigma_{22}^{-1} = \sigma_{12}\sigma_{22}^{-1} = \frac{\sigma_{12}}{\sigma_{22}}, \text{ y}$$

$$\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = \sigma_{11} - \sigma_{12}\sigma_{22}^{-1}\sigma_{21} = \sigma_{11} - \frac{\sigma_{12}}{\sigma_{22}}\sigma_{21}$$

y como, $\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}}$, es decir: $\sqrt{\sigma_{11}}\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{22}}}$, luego,

$$\frac{\sigma_{12}}{\sigma_{22}} = \frac{\sqrt{\sigma_{11}}}{\sqrt{\sigma_{22}}}\rho_{12} \quad y \quad \frac{\sigma_{12}^2}{\sigma_{22}} = \frac{\sigma_{11}\sigma_{22}\rho_{12}^2}{\sigma_{22}} = \sigma_{11}\rho_{12}^2$$

y

$$\sigma_{11} - \frac{\sigma_{12}}{\sigma_{22}}\sigma_{21} = \sigma_{11} [1 - \rho_{12}^2]$$

es decir:

$$\begin{aligned} X_1 \mid X_2 = x_2 &\sim N_1 \left(\mu_1 + \frac{\sqrt{\sigma_{11}}}{\sqrt{\sigma_{22}}}\rho_{12}(x_2 - \mu_2), \sigma_{11} [1 - \rho_{12}^2] \right) \\ &\sim N_1 \left(\underbrace{\mu_1 - \frac{\sqrt{\sigma_{11}}}{\sqrt{\sigma_{22}}}\rho_{12}\mu_2}_{a_0} + \underbrace{\frac{\sqrt{\sigma_{11}}}{\sqrt{\sigma_{22}}}\rho_{12}x_2}_b, \sigma_{11} [1 - \rho_{12}^2] \right) \end{aligned}$$

$$X_1 \mid X_2 = x_2 \sim N_1 \left(a_0 + bx_2, \sigma_{11} [1 - \rho_{12}^2] \right)$$

de donde se observa que la media de la distribución condicional de $X_1 \mid X_2 = x_2$, corresponde a la ecuación de una línea recta con intercepto a_0 y pendiente b , ie. la ecuación del modelo de regresión lineal de X_1 v.s X_2 .

Observaciones:

- En regresión multivariada, la media condicional

$$\underline{\mu}_{1.2} = E[\underline{X}^{(1)} \mid \underline{X}^{(2)}]$$

es llamada la **curva de regresión**.

- Es decir, la curva de regresión en la normal multivariada,

$$\underline{\mu}_{1.2} = E[\underline{X}^{(1)} \mid \underline{X}^{(2)}],$$

se puede escribir como:

$$E[\underline{X}^{(1)} \mid \underline{X}^{(2)}] = \begin{bmatrix} E[X_1 \mid X_{q+1}, X_{q+2}, \dots, X_p] \\ E[X_2 \mid X_{q+1}, X_{q+2}, \dots, X_p] \\ \vdots \\ \vdots \\ E[X_q \mid X_{q+1}, X_{q+2}, \dots, X_p] \end{bmatrix} = \underline{\mu}^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (\underline{X}^{(2)} - \underline{\mu}^{(2)})$$

$$\text{Ahora con, } \Sigma_{12} \Sigma_{22}^{-1} = \begin{bmatrix} \beta_{1,q+1} & \beta_{1,q+2} & \cdots & \beta_{1,p} \\ \beta_{2,q+1} & \beta_{2,q+2} & \cdots & \beta_{2,p} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \beta_{q,q+1} & \beta_{q,q+2} & \cdots & \beta_{q,p} \end{bmatrix}$$

entonces, la curva de regresión se puede escribir como:

$$E[\underline{X}^{(1)} \mid \underline{X}^{(2)}] = \underline{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1} (\underline{X}^{(2)} - \underline{\mu}^{(2)})$$

$$= \begin{bmatrix} E[X_1|X_{q+1}, X_{q+2}, \cdots, X_p] \\ E[X_2|X_{q+1}, X_{q+2}, \cdots, X_p] \\ \vdots \\ \vdots \\ E[X_q|X_{q+1}, X_{q+2}, \cdots, X_p] \end{bmatrix}$$

$$= \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \vdots \\ \mu_q \end{bmatrix} + \begin{bmatrix} \beta_{1,q+1} & \beta_{1,q+2} & \cdots & \beta_{1,p} \\ \beta_{2,q+1} & \beta_{2,q+2} & \cdots & \beta_{2,p} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \beta_{q,q+1} & \beta_{q,q+2} & \cdots & \beta_{q,p} \end{bmatrix} \begin{bmatrix} X_{q+1} - \mu_{q+1} \\ X_{q+2} - \mu_{q+2} \\ \vdots \\ \vdots \\ X_p - \mu_p \end{bmatrix}$$

$$E[\underline{X}^{(1)} \mid \underline{X}^{(2)}] = \begin{bmatrix} \mu_1 + \beta_{1,q+1}(X_{q+1} - \mu_{q+1}) + \cdots + \beta_{1,p}(X_p - \mu_p) \\ \mu_2 + \beta_{2,q+1}(X_{q+1} - \mu_{q+1}) + \cdots + \beta_{2,p}(X_p - \mu_p) \\ \vdots \\ \mu_q + \beta_{q,q+1}(X_{q+1} - \mu_{q+1}) + \cdots + \beta_{q,p}(X_p - \mu_p) \end{bmatrix}$$

lo anterior implica que, cuando la distribución conjunta de las variables en una regresión (dependientes e independientes) es normal multivariada, todas las curvas de regresión son lineales.

- La matriz de var-cov condicional

$$\Sigma_{1.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

es constante pues no depende de los valores de las variables condicionantes. Por tanto, la curva de regresión es homocedástica.

Ejemplo 10 Suponga que $\underline{\mathbf{x}}' = (X_1, X_2, X_3) \sim N_p(\underline{\mu}, \Sigma)$,

donde:

$$\underline{\mu} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}, \text{ y } \Sigma = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Hallar la distribución condicional de: $\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}$, donde:

$$\underline{\mathbf{x}}^{(1)} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \text{ y } \underline{\mathbf{x}}^{(2)} = [X_3]$$

La distribución condicional de: $\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}$ es normal bi-variada con vector de medias:

$$E\left[\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}\right] = \underline{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\underline{\mathbf{x}}^{(2)} - \underline{\mu}^{(2)})$$

y matriz de var-cov dada por:

$$Var\left[\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}\right] = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

Haciendo,

$$\underline{\mu} = \begin{bmatrix} \underline{\mu}^{(1)} \\ \dots \\ \underline{\mu}^{(2)} \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \dots \\ \mu_3 \end{bmatrix} = \begin{bmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} \\ \dots \\ \begin{pmatrix} 2 \end{pmatrix} \end{bmatrix}$$

y

$$\Sigma = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 1 \end{bmatrix} = \left(\begin{array}{c|c} \Sigma_{11} & \Sigma_{12} \\ \hline \Sigma_{21} & \Sigma_{22} \end{array} \right) = \left[\begin{array}{c|c} \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} & \begin{pmatrix} 1 \\ 0 \end{pmatrix} \\ \hline \begin{pmatrix} 1 & 0 \end{pmatrix} & \begin{pmatrix} 1 \end{pmatrix} \end{array} \right]$$

luego,

$$E[\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}] = \underline{\mu}^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (\underline{\mathbf{x}}^{(2)} - \underline{\mu}^{(2)}) = \begin{pmatrix} 2 \\ 1 \end{pmatrix} + \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{1} (x_3 - 2) = \begin{pmatrix} x_3 \\ 1 \end{pmatrix}$$

y

$$Var[\underline{\mathbf{x}}^{(1)} \mid \underline{\mathbf{x}}^{(2)}] = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} \frac{1}{1} \begin{pmatrix} 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 3 \end{pmatrix}$$

6. Sea $\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma})$. Si $|\underline{\Sigma}| > 0$, entonces:

$$\underline{z} = \underline{\Sigma}^{-1/2}(\underline{X} - \underline{\mu}) \sim N_p(\underline{0}, \underline{I}_p),$$

ie, \underline{z} -tiene una distribución normal-multivariada estándar.

Demostración de la propiedad (6): Estudiarla del libro de Jonhson.

7. Sea $\underline{X} \sim N_p(\underline{\mu}, \underline{\Sigma})$, con $|\underline{\Sigma}| > 0$.

(a) $(\underline{X} - \underline{\mu})^t \underline{\Sigma}^{-1}(\underline{X} - \underline{\mu}) \sim \chi_p^2$

(b) La distribución $N_p(\underline{\mu}, \underline{\Sigma})$ -asigna probabilidad de $(1 - \alpha)100\%$ al elipsoide determinado por:

$$\left\{ \underline{x} : (\underline{x} - \underline{\mu})^t \underline{\Sigma}^{-1}(\underline{x} - \underline{\mu}) \leq \chi_{\alpha;p}^2 \right\}$$

donde, $\chi_{\alpha;p}^2$ -es el percentil superior α de la distribución χ_p^2 .

Demostración: (a).

Sea

$$\underline{Z} = \underline{\Sigma}^{-1/2}(\underline{X} - \underline{\mu}),$$

donde $\underline{\Sigma}^{-1/2}$ es la matriz inversa de $\underline{\Sigma}^{1/2} = \Gamma \Delta^{1/2} \Gamma^t$ (llamada la matriz raíz cuadrada positiva de la matriz $\underline{\Sigma}$).

entonces

$$\underline{Z} = \underline{\Sigma}^{-1/2}(\underline{X} - \underline{\mu}) \sim N_p(\underline{0}, \mathbf{I}_p) \quad (\text{Resultado - 6})$$

luego, Las marginales de las variables del vector \underline{Z} son $N(0, 1)$ e independientes.

Ahora, se Considera la variable:

$$\begin{aligned} (\underline{X} - \underline{\mu})^t \underline{\Sigma}^{-1} (\underline{X} - \underline{\mu}) &= (\underline{X} - \underline{\mu})^t \underline{\Sigma}^{-1/2} \underline{\Sigma}^{-1/2} (\underline{X} - \underline{\mu}) \\ &= \left(\underline{\Sigma}^{-1/2} (\underline{X} - \underline{\mu}) \right)^t \left(\underline{\Sigma}^{-1/2} (\underline{X} - \underline{\mu}) \right) = \underline{Z}^t \underline{Z} = \sum_{i=1}^p Z_i^2 \sim \chi_{(p)}^2 \end{aligned}$$

Observaciones:

- Por el teorema de descomposición espectral de la matriz simétrica y definida positiva Σ se tiene que:

$$\Sigma = \Gamma \Delta \Gamma^t$$

donde Γ es una matriz ortogonal con los vectores propios de Σ como columnas ($\Gamma^T \Gamma = I$), y Δ es una matriz diagonal con los valores propios de Σ en su diagonal. Entonces,

$$\Sigma = \Gamma \Delta \Gamma^t = \Gamma \Delta^{1/2} \Delta^{1/2} \Gamma^t = (\Gamma \Delta^{1/2} \Gamma^t) (\Gamma \Delta^{1/2} \Gamma^t) = \Sigma^{1/2} \Sigma^{1/2}$$

donde $\Delta^{1/2}$ es una matriz diagonal con la raíz cuadrada de los elementos de la diagonal de Δ en su diagonal.

A $\Sigma^{1/2} = \Gamma \Delta^{1/2} \Gamma^t$ se le llama la matriz raíz cuadrada positiva de la matriz Σ .

- El empleo de la matriz $\Sigma^{-1/2}$ sobre el vector aleatorio $(\underline{X} - \underline{\mu})$, estandariza todas las variables y elimina los efectos de correlación entre ellas.

8. Sean $\underline{\mathbf{x}}_1, \underline{\mathbf{x}}_2, \dots, \underline{\mathbf{x}}_n$, vectores aleatorios p -variados mutuamente-independientes tales que:

$$\underline{\mathbf{x}}_i \sim N_p(\underline{\mu}_i, \Sigma) , \text{ para } i = 1, 2, \dots, n,$$

entonces:

$$\underline{\mathbf{v}}_1 = \sum_{i=1}^n c_i \underline{\mathbf{x}}_i = c_1 \underline{\mathbf{x}}_1 + c_2 \underline{\mathbf{x}}_2 + \dots + c_n \underline{\mathbf{x}}_n$$

$$\sim N_p \left[\sum_{i=1}^n c_i \underline{\mu}_i , \left(\sum_{i=1}^n c_i^2 \right) \Sigma \right]$$

$$\underline{\mathbf{v}}_1 \sim N_p \left(c_1 \underline{\mu}_1 + c_2 \underline{\mu}_2 + \dots + c_n \underline{\mu}_n , [c_1^2 + c_2^2 + \dots + c_n^2] \Sigma \right)$$

además si, $\underline{\mathbf{v}}_2 = \sum_{i=1}^n b_i \underline{\mathbf{x}}_i = b_1 \underline{\mathbf{x}}_1 + b_2 \underline{\mathbf{x}}_2 + \cdots + b_n \underline{\mathbf{x}}_n$

entonces: $\underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \cdots \\ \underline{\mathbf{v}}_2 \end{bmatrix} \sim N_{2p} \left[\begin{pmatrix} \sum_{i=1}^n c_i \underline{\mu}_i \\ \cdots \cdots \cdots \\ \sum_{i=1}^n b_i \underline{\mu}_i \end{pmatrix}, \Sigma_{\underline{\mathbf{v}}} \right], \text{ donde}$

$$\Sigma_{\underline{\mathbf{v}}} = Var(\underline{\mathbf{v}}) = \begin{bmatrix} \left(\sum_{i=1}^n c_i^2 \right) \Sigma & \vdots & \left(\sum_{i=1}^n b_i c_i \right) \Sigma \\ \cdots \cdots \cdots & & \cdots \cdots \cdots \\ \left(\sum_{i=1}^n b_i c_i \right) \Sigma & \vdots & \left(\sum_{i=1}^n b_i^2 \right) \Sigma \end{bmatrix}$$

$$= \begin{bmatrix} \left(\underline{c}^t \underline{c} \right) \Sigma & \vdots & \left(\underline{b}^t \underline{c} \right) \Sigma \\ \cdots \cdots \cdots & & \cdots \cdots \cdots \\ \left(\underline{b}^t \underline{c} \right) \Sigma & \vdots & \left(\underline{b}^t \underline{b} \right) \Sigma \end{bmatrix}$$

y además, $\underline{\mathbf{v}}_1 \perp \underline{\mathbf{v}}_2$ si $\underline{b}^t \underline{c} = \sum_{i=1}^n b_i c_i = 0$.

Demostración:

Considere el vector $np \times 1$ dado por:

$$\underline{Z} = \begin{bmatrix} \underline{\mathbf{x}}_1 \\ \underline{\mathbf{x}}_2 \\ \vdots \\ \vdots \\ \underline{\mathbf{x}}_n \end{bmatrix}_{np \times 1}, \quad \text{recuerde que: } \underline{\mathbf{x}}_i_{p \times 1}$$

por el resultado (4.c) se tiene que:

$$\underline{Z} \sim N_{np}(\underline{\mu}_Z, \underline{\Sigma}_Z)$$

donde,

$$\underline{\mu}_Z = \begin{bmatrix} \underline{\mu}_1 \\ \underline{\mu}_2 \\ \vdots \\ \vdots \\ \underline{\mu}_n \end{bmatrix}_{np \times 1} \quad y \quad \underline{\Sigma}_Z = \begin{bmatrix} \underline{\Sigma} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \underline{\Sigma} & \cdots & \mathbf{0} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \underline{\Sigma} \end{bmatrix}_{np \times np}$$

1. para la parte (a):

Considere la matriz

$$\mathbf{A} = \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \end{bmatrix}_{p \times np}$$

donde \mathbf{I} es la matriz identidad $p \times p$, entonces

$$\mathbf{A}\underline{Z} = \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \end{bmatrix} \begin{bmatrix} \underline{\mathbf{x}}_1 \\ \underline{\mathbf{x}}_2 \\ \vdots \\ \underline{\mathbf{x}}_n \end{bmatrix} = c_1 \underline{\mathbf{x}}_1 + c_2 \underline{\mathbf{x}}_2 + \cdots + c_n \underline{\mathbf{x}}_n = \underline{\mathbf{v}}_1$$

y por el resultado o propiedad (2) se tiene que:

$$\mathbf{A}\underline{Z} = \underline{\mathbf{v}}_1 \sim N_p \left(\mathbf{A}\underline{\mu}_Z, \mathbf{A}\underline{\Sigma}_Z \mathbf{A}^t \right)$$

$$\text{donde, } \mathbf{A}_{\underline{\mu_Z}} = \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \end{bmatrix} \begin{bmatrix} \underline{\mu_1} \\ \underline{\mu_2} \\ \vdots \\ \underline{\mu_n} \end{bmatrix} = \sum_{i=1}^n c_i \underline{\mu_i}, \quad y$$

$$\begin{aligned} \mathbf{A} \Sigma_Z \mathbf{A}^t &= \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \end{bmatrix} \begin{bmatrix} \Sigma & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \Sigma & \cdots & \mathbf{0} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \Sigma \end{bmatrix} \begin{bmatrix} c_1 \mathbf{I} \\ c_2 \mathbf{I} \\ \vdots \\ \vdots \\ c_n \mathbf{I} \end{bmatrix} \\ &= \begin{bmatrix} c_1 \Sigma & c_2 \Sigma & \cdots & c_n \Sigma \end{bmatrix} \begin{bmatrix} c_1 \mathbf{I} \\ c_2 \mathbf{I} \\ \vdots \\ \vdots \\ c_n \mathbf{I} \end{bmatrix} = \left(\sum_{i=1}^n c_i^2 \right) \Sigma, \quad \text{es decir,} \end{aligned}$$

$$\underline{\mathbf{v}}_1 = \sum_{i=1}^n c_i \underline{X_i} \sim N_p \left[\sum_{i=1}^n c_i \underline{\mu_i}, \left(\sum_{i=1}^n c_i^2 \right) \Sigma \right], \quad l.q.q.d$$

2. para la parte (b):

Sea

$$\mathbf{B} = \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \\ b_1 \mathbf{I} & | & b_2 \mathbf{I} & | & \cdots & | & b_n \mathbf{I} \end{bmatrix}_{2p \times np}$$

entonces,

$$\begin{aligned} \underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \underline{\mathbf{v}}_2 \end{bmatrix} &= \begin{bmatrix} c_1 \underline{\mathbf{x}}_1 + c_2 \underline{\mathbf{x}}_2 + \cdots + c_n \underline{\mathbf{x}}_n \\ b_1 \underline{\mathbf{x}}_1 + b_2 \underline{\mathbf{x}}_2 + \cdots + b_n \underline{\mathbf{x}}_n \end{bmatrix} \\ &= \begin{bmatrix} c_1 \mathbf{I} & | & c_2 \mathbf{I} & | & \cdots & | & c_n \mathbf{I} \\ b_1 \mathbf{I} & | & b_2 \mathbf{I} & | & \cdots & | & b_n \mathbf{I} \end{bmatrix} \begin{bmatrix} \underline{\mathbf{x}}_1 \\ \underline{\mathbf{x}}_2 \\ \vdots \\ \underline{\mathbf{x}}_n \end{bmatrix} = \mathbf{B} \underline{\mathbf{Z}} \end{aligned}$$

y del resultado (2) nuevamente se tiene que:

$$\mathbf{B}\underline{Z} \sim N_{2p} \left(\mathbf{B}\underline{\mu_Z}, \mathbf{B}\underline{\Sigma_Z}\mathbf{B}^t \right)$$

donde,

$$\mathbf{B}\underline{\mu_Z} = \begin{bmatrix} c_1\mathbf{I} & | & c_2\mathbf{I} & | & \cdots & | & c_n\mathbf{I} \\ b_1\mathbf{I} & | & b_2\mathbf{I} & | & \cdots & | & b_n\mathbf{I} \end{bmatrix} \begin{bmatrix} \underline{\mu_1} \\ \underline{\mu_2} \\ \vdots \\ \vdots \\ \underline{\mu_n} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n c_i \underline{\mu_i} \\ - - - - - \\ \sum_{i=1}^n b_i \underline{\mu_i} \end{bmatrix}$$

$$\mathbf{B}\underline{\Sigma_Z}\mathbf{B}^t = \begin{bmatrix} c_1\mathbf{I} & | & c_2\mathbf{I} & | & \cdots & | & c_n\mathbf{I} \\ b_1\mathbf{I} & | & b_2\mathbf{I} & | & \cdots & | & b_n\mathbf{I} \end{bmatrix} \begin{bmatrix} \underline{\Sigma} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \underline{\Sigma} & \cdots & \mathbf{0} \\ \vdots & \vdots & & \vdots \\ \vdots & \vdots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \underline{\Sigma} \end{bmatrix} \begin{bmatrix} c_1\mathbf{I} & b_1\mathbf{I} \\ c_2\mathbf{I} & b_2\mathbf{I} \\ \vdots & \\ \vdots & \\ c_n\mathbf{I} & b_n\mathbf{I} \end{bmatrix}$$

$$\Sigma_{\underline{\mathbf{v}}_1, \underline{\mathbf{v}}_2} = \begin{bmatrix} c_1 \Sigma & | & c_2 \Sigma & | & \cdots & | & c_n \Sigma \\ b_1 \Sigma & | & b_2 \Sigma & | & \cdots & | & b_n \Sigma \end{bmatrix} \begin{bmatrix} c_1 \mathbf{I} & b_1 \mathbf{I} \\ c_2 \mathbf{I} & b_2 \mathbf{I} \\ \vdots & \\ \vdots & \\ c_n \mathbf{I} & b_n \mathbf{I} \end{bmatrix}$$

$$= \begin{bmatrix} \left(\sum_{i=1}^n c_i^2 \right) \Sigma & \vdots & \left(\sum_{i=1}^n b_i c_i \right) \Sigma \\ \dots\dots\dots & & \dots\dots\dots \\ \left(\sum_{i=1}^n b_i c_i \right) \Sigma & \vdots & \left(\sum_{i=1}^n b_i^2 \right) \Sigma \end{bmatrix} = \begin{bmatrix} \left(\underline{c}^t \underline{c} \right) \Sigma & \vdots & \left(\underline{b}^t \underline{c} \right) \Sigma \\ \dots\dots\dots & & \dots\dots\dots \\ \left(\underline{b}^t \underline{c} \right) \Sigma & \vdots & \left(\underline{b}^t \underline{b} \right) \Sigma \end{bmatrix}_{2p \times 2p}$$

es decir que,

$$\underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \cdots \\ \underline{\mathbf{v}}_2 \end{bmatrix} \sim N_{2p} \left[\begin{pmatrix} \sum_{i=1}^n c_i \underline{\mu}_i \\ \dots\dots\dots \\ \sum_{i=1}^n b_i \underline{\mu}_i \end{pmatrix}, \Sigma_{\underline{\mathbf{v}}} \right]$$

3. **para la parte (c):** Evidente por resultado (4.b).

Ejemplo 11 Suponga que $\underline{x}_1, \underline{x}_2, \underline{x}_3, \underline{x}_4$, son vectores aleatorios 3-variados independientes e idénticamente distribuidos, ie. $\underline{x}_i = (X_{i1}, X_{i2}, X_{i3})^t$ para $i = 1, 2, 3, 4$, con:

$$\underline{\mu} = E[\underline{x}_i] = \begin{bmatrix} 3 \\ -1 \\ 1 \end{bmatrix}, \quad y \quad \Sigma = Var[\underline{x}_i] = \begin{bmatrix} 3 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 2 \end{bmatrix}$$

1. Hallar la media y varianza de: $\underline{a}^t \underline{x}_1 = a_1 X_{11} + a_2 X_{12} + a_3 X_{13}$.

2. Hallar la media y varianza de: $\frac{1}{2}\underline{x}_1 + \frac{1}{2}\underline{x}_2 + \frac{1}{2}\underline{x}_3 + \frac{1}{2}\underline{x}_4$

3. Hallar la media y varianza de:

$$\begin{bmatrix} \frac{1}{2}\underline{x}_1 + \frac{1}{2}\underline{x}_2 + \frac{1}{2}\underline{x}_3 + \frac{1}{2}\underline{x}_4 \\ \underline{x}_1 + \underline{x}_2 + \underline{x}_3 - 3\underline{x}_4 \end{bmatrix}$$

Solución:

1. La distribución de:

$$\underline{a}^t \underline{\mathbf{x}}_1 = a_1 X_{11} + a_2 X_{12} + a_3 X_{13}.$$

La cual es una combinación lineal de las componentes de un vector aleatorio, ie. una c.l de variables, y por lo tanto es una variable aleatoria, de donde se tiene que:

$$\begin{aligned} E[\underline{a}^t \underline{\mathbf{x}}_1] &= E[a_1 X_{11} + a_2 X_{12} + a_3 X_{13}] \\ &= a_1 E[X_{11}] + a_2 E[X_{12}] + a_3 E[X_{13}] \\ &= 3a_1 - a_2 + a_3 \end{aligned}$$

$$Var[\underline{a}^t \underline{\mathbf{x}}_1] = Var\left[a_1 X_{11} + a_2 X_{12} + a_3 X_{13}\right]$$

$$= a_1^2 Var[X_{11}] + a_2^2 Var[X_{12}] + a_3^2 Var[X_{13}]$$

$$+ 2a_1 a_2 Cov(X_{11}, X_{12}) + 2a_1 a_3 Cov(X_{11}, X_{13}) + 2a_2 a_3 Cov(X_{12}, X_{13})$$

$$= 3a_1^2 + a_2^2 + 2a_3^2 - 2a_1 a_2 + 2a_1 a_3$$

$$Var[\underline{a}^t \underline{\mathbf{x}}_1] = \underline{a}^t \underline{\Sigma} \underline{a}.$$

2. La media y varianza de:

$$\frac{1}{2}\underline{\mathbf{x}}_1 + \frac{1}{2}\underline{\mathbf{x}}_2 + \frac{1}{2}\underline{\mathbf{x}}_3 + \frac{1}{2}\underline{\mathbf{x}}_4$$

En este caso se tiene un combinación lineal de vectores aleatorios, lo cual a su vez es un vector aleatorio, por lo tanto:

$$E\left[\frac{1}{2}\underline{\mathbf{x}}_1 + \frac{1}{2}\underline{\mathbf{x}}_2 + \frac{1}{2}\underline{\mathbf{x}}_3 + \frac{1}{2}\underline{\mathbf{x}}_4\right] = \frac{1}{2}E[\underline{\mathbf{x}}_1] + \frac{1}{2}E[\underline{\mathbf{x}}_2] + \frac{1}{2}E[\underline{\mathbf{x}}_3] + c_4E[\underline{\mathbf{x}}_4]$$

$$= \sum_{i=1}^n \frac{1}{2}\underline{\mu}_i = \frac{1}{2}\underline{\mu} + \frac{1}{2}\underline{\mu} + \frac{1}{2}\underline{\mu} + \frac{1}{2}\underline{\mu}$$

$$= \left(\frac{1}{2} + \frac{1}{2} + \frac{1}{2} + \frac{1}{2}\right)\underline{\mu}$$

$$= 2\underline{\mu} = 2 \begin{bmatrix} 3 \\ -1 \\ 1 \end{bmatrix} = \begin{bmatrix} 6 \\ -2 \\ 2 \end{bmatrix}$$

$$\begin{aligned}
& Var\left[c_1\underline{\mathbf{x}}_1 + c_2\underline{\mathbf{x}}_2 + c_3\underline{\mathbf{x}}_3 + c_4\underline{\mathbf{x}}_4\right] \\
&= c_1^2 Var[\underline{\mathbf{x}}_1] + c_2^2 Var[\underline{\mathbf{x}}_2] + c_3^2 Var[\underline{\mathbf{x}}_3] + c_4^2 Var[\underline{\mathbf{x}}_4] \\
&= c_1^2 \Sigma + c_2^2 \Sigma + c_3^2 \Sigma + c_4^2 \Sigma = \left(\sum_{i=1}^n c_i^2\right) \Sigma \\
&= \left(c_1^2 + c_2^2 + c_3^2 + c_4^2\right) \Sigma \\
&= \left(\frac{1}{4} + \frac{1}{4} + \frac{1}{4} + \frac{1}{4}\right) \Sigma = \Sigma = \begin{bmatrix} 3 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 2 \end{bmatrix}
\end{aligned}$$

3. La media y varianza de:

$$\begin{bmatrix} c_1 \underline{\mathbf{x}}_1 + c_2 \underline{\mathbf{x}}_2 + c_3 \underline{\mathbf{x}}_3 + c_4 \underline{\mathbf{x}}_4 \\ b_1 \underline{\mathbf{x}}_1 + b_2 \underline{\mathbf{x}}_2 + b_3 \underline{\mathbf{x}}_3 + b_4 \underline{\mathbf{x}}_4 \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \underline{\mathbf{x}}_1 + \frac{1}{2} \underline{\mathbf{x}}_2 + \frac{1}{2} \underline{\mathbf{x}}_3 + \frac{1}{2} \underline{\mathbf{x}}_4 \\ \underline{\mathbf{x}}_1 + \underline{\mathbf{x}}_2 + \underline{\mathbf{x}}_3 - 3 \underline{\mathbf{x}}_4 \end{bmatrix} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \underline{\mathbf{v}}_2 \end{bmatrix}_{6 \times 1}$$

Sea $\underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \underline{\mathbf{v}}_2 \end{bmatrix}$, luego, $Var[\underline{\mathbf{v}}]$

$$= \begin{pmatrix} Var(\underline{\mathbf{v}}_1) & | & Cov(\underline{\mathbf{v}}_1, \underline{\mathbf{v}}_2) \\ \hline Cov(\underline{\mathbf{v}}_2, \underline{\mathbf{v}}_1) & | & Var(\underline{\mathbf{v}}_2) \end{pmatrix} = \begin{bmatrix} \left(\sum_{i=1}^n c_i^2 \right) \Sigma & : & \left(\sum_{i=1}^n b_i c_i \right) \Sigma \\ \dots\dots\dots & & \dots\dots\dots \\ \left(\sum_{i=1}^n b_i c_i \right) \Sigma & : & \left(\sum_{i=1}^n b_i^2 \right) \Sigma \end{bmatrix}$$

$$= \begin{bmatrix} (\underline{\mathbf{c}}^t \underline{\mathbf{c}}) \Sigma & : & (\underline{\mathbf{b}}^t \underline{\mathbf{c}}) \Sigma \\ \dots\dots\dots & & \dots\dots\dots \\ (\underline{\mathbf{b}}^t \underline{\mathbf{c}}) \Sigma & : & (\underline{\mathbf{b}}^t \underline{\mathbf{b}}) \Sigma \end{bmatrix} = \begin{bmatrix} 1 \times \Sigma & : & 0 \times \Sigma \\ \dots\dots\dots & & \dots\dots\dots \\ 0 \times \Sigma & : & 12 \times \Sigma \end{bmatrix} = \begin{bmatrix} \Sigma & : & \mathbf{0} \\ \dots\dots\dots & & \dots\dots\dots \\ \mathbf{0} & : & 12 \Sigma \end{bmatrix}_{6 \times 6}$$

es decir,

$$Var[\underline{v}] = \begin{bmatrix} \Sigma & \vdots & \mathbf{0} \\ \dots\dots\dots & & \dots\dots\dots \\ \mathbf{0} & \vdots & 12\Sigma \end{bmatrix} = \begin{bmatrix} 3 & -1 & 1 & & 0 & 0 & 0 \\ -1 & 1 & 0 & \vdots & 0 & 0 & 0 \\ 1 & 0 & 2 & & 0 & 0 & 0 \\ & \dots\dots\dots & & & \dots\dots\dots & & \\ 0 & 0 & 0 & & 36 & -12 & 12 \\ 0 & 0 & 0 & \vdots & -12 & 12 & 0 \\ 0 & 0 & 0 & & 12 & 0 & 24 \end{bmatrix}$$

Observaciones:

- Cada componente de la primera combinación lineal es independiente de cada componente de la segunda combinación lineal.
- Conjuntamente las dos combinaciones lineales tienen una distribución normal multivariada 6 dimensional.
- Las dos combinaciones lineales son independientes.

$$\underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \underline{\mathbf{v}}_2 \end{bmatrix} = \begin{bmatrix} \frac{1}{2}\underline{\mathbf{x}}_1 + \frac{1}{2}\underline{\mathbf{x}}_2 + \frac{1}{2}\underline{\mathbf{x}}_3 + \frac{1}{2}\underline{\mathbf{x}}_4 \\ \underline{\mathbf{x}}_1 + \underline{\mathbf{x}}_2 + \underline{\mathbf{x}}_3 - 3\underline{\mathbf{x}}_4 \end{bmatrix} = \begin{bmatrix} \frac{1}{2}(\underline{\mathbf{x}}_1 + \underline{\mathbf{x}}_2 + \underline{\mathbf{x}}_3 + \underline{\mathbf{x}}_4) \\ \underline{\mathbf{x}}_1 + \underline{\mathbf{x}}_2 + \underline{\mathbf{x}}_3 - 3\underline{\mathbf{x}}_4 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{1}{2} \begin{pmatrix} X_{11} \\ X_{12} \\ X_{13} \end{pmatrix} + \frac{1}{2} \begin{pmatrix} X_{21} \\ X_{22} \\ X_{23} \end{pmatrix} + \frac{1}{2} \begin{pmatrix} X_{31} \\ X_{32} \\ X_{33} \end{pmatrix} + \frac{1}{2} \begin{pmatrix} X_{41} \\ X_{42} \\ X_{43} \end{pmatrix} \\ \begin{pmatrix} X_{11} \\ X_{12} \\ X_{13} \end{pmatrix} + \begin{pmatrix} X_{11} \\ X_{12} \\ X_{13} \end{pmatrix} + \begin{pmatrix} X_{11} \\ X_{12} \\ X_{13} \end{pmatrix} - 3 \begin{pmatrix} X_{11} \\ X_{12} \\ X_{13} \end{pmatrix} \end{bmatrix}$$

$$\underline{\mathbf{v}} = \begin{bmatrix} \underline{\mathbf{v}}_1 \\ \underline{\mathbf{v}}_2 \end{bmatrix}_{6 \times 1} = \begin{bmatrix} \frac{1}{2}X_{11} + \frac{1}{2}X_{21} + \frac{1}{2}X_{31} + \frac{1}{2}X_{41} \\ \frac{1}{2}X_{12} + \frac{1}{2}X_{22} + \frac{1}{2}X_{32} + \frac{1}{2}X_{42} \\ \frac{1}{2}X_{13} + \frac{1}{2}X_{23} + \frac{1}{2}X_{33} + \frac{1}{2}X_{43} \\ \dots\dots\dots \\ X_{11} + X_{21} + X_{31} - 3X_{41} \\ X_{12} + X_{22} + X_{32} - 3X_{42} \\ X_{13} + X_{23} + X_{33} - 3X_{43} \end{bmatrix}$$

$$\Sigma_{\underline{\mathbf{x}}_i} = \begin{bmatrix} 3 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 2 \end{bmatrix}, \quad \Sigma_{\underline{\mathbf{v}}} = \begin{bmatrix} 3 & -1 & 1 & & 0 & 0 & 0 \\ -1 & 1 & 0 & : & 0 & 0 & 0 \\ 1 & 0 & 2 & & 0 & 0 & 0 \\ \dots\dots\dots & & & & \dots\dots\dots & & \\ 0 & 0 & 0 & & 36 & -12 & 12 \\ 0 & 0 & 0 & : & -12 & 12 & 0 \\ 0 & 0 & 0 & & 12 & 0 & 24 \end{bmatrix}$$