

Jonathan Smith García Muñoz  
1039 705595

(1) Sea  $X_1, \dots, X_n$  una n.a. de una población con r.f. dada por

$$f(x|\theta) = \frac{\alpha x^{\alpha-1}}{\beta^\alpha}; \quad 0 < x \leq \beta; \quad \alpha > 0$$

MLE para  $\alpha$  y  $\beta$ .

• Suponga  $\alpha$  fijo. MLE para  $\beta$  está dado por

$L(\beta|X, \alpha) = c(\alpha) f(x|\alpha, \beta) \Rightarrow$  Función de verosimilitud

$$= \prod_{i=1}^n \frac{\alpha x_i^{\alpha-1}}{\beta^\alpha} = \alpha^n \prod_{i=1}^n \left( \frac{x_i}{\beta} \right)^{\alpha-1} \cdot \frac{1}{\beta} = \alpha^n \left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} \frac{1}{\beta}$$

• Como  $0 < x_i \leq \beta$ , entonces  $0 < \frac{x_i}{\beta} \leq 1$ .

• Se sabe que  $0 < x_i \leq X_{(n)} \leq \beta$

$$\therefore 0 < x_i \leq X_{(n)} \Rightarrow 0 < \frac{x_i}{X_{(n)}} \leq 1 \quad \text{pero } \beta > X_{(n)} \quad \text{por tanto}$$

$$0 < x_i \leq \beta \Rightarrow 0 < \frac{x_i}{\beta} \leq 1 \quad \text{se concluye que}$$

$$\frac{x_i}{\beta} \leq \frac{x_i}{X_{(n)}} \quad \text{Ahora, en el numerador...}$$

$$\left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} \leq \left( \prod_{i=1}^n \frac{x_i}{X_{(n)}} \right)^{\alpha-1} \Rightarrow \frac{\alpha^n}{\prod_{i=1}^n x_i} \left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} \leq \frac{\alpha^n}{\prod_{i=1}^n x_i} \left( \prod_{i=1}^n \frac{x_i}{X_{(n)}} \right)^{\alpha-1}$$

lo que implica que  $L(\beta|X) \leq L(X_{(n)}|X) \quad \forall X$ , entonces

$X_{(n)}$  maximiza la función y el MLE de  $\beta$ ,  $\hat{\beta} = X_{(n)}$

para  $\alpha$ ... Si fijamos  $\beta = X_{(n)}$

$$L(\alpha|X, X_{(n)}) = \prod_{i=1}^n \frac{\alpha x_i^{\alpha-1}}{X_{(n)}^\alpha} \Rightarrow \alpha^n \frac{\left( \prod_{i=1}^n x_i \right)^{\alpha-1}}{X_{(n)}^{\alpha n}}$$

$$l(\alpha|X, X_{(n)}) = n \ln(\alpha) - \alpha n \ln(X_{(n)}) + (\alpha-1) \sum_{i=1}^n \ln(x_i)$$



Para hallar el máximo, se deriva e iguala a cero.

$$\frac{\partial L}{\partial \alpha} = \frac{n}{\alpha} - n \ln(X_{(n)}) + \sum_{i=1}^n \ln(x_i) = 0$$

$$= \frac{n}{\alpha} + \sum_{i=1}^n \ln(x_i - X_{(n)}) = 0 \Leftrightarrow \frac{1}{\alpha} = \frac{-\sum_{i=1}^n \ln\left(\frac{x_i}{X_{(n)}}\right)}{n}$$

$$\hat{\alpha} = \frac{-n}{\sum_{i=1}^n \ln\left(\frac{x_i}{X_{(n)}}\right)}$$

Verificando que es máximo con la Segunda derivada...

$$\frac{\partial^2 L}{\partial \alpha^2} = -\frac{n}{\alpha^2} < 0, \text{ por tanto } \hat{\alpha} \text{ es un MLE para } \alpha$$

② MLE's Para  $\theta_1, \theta_2$ . Para  $\theta_1$  la F.v. no es concavante.   
 Si  $X_0$  es el max  $f(x) \Leftrightarrow f(X_0) \geq f(x) \forall x$

Como  $\min x_i \leq x_i, \forall i, x_i > \theta_1, \min x_i > \theta_1, X_{(n)} > \theta_1$

Como  $\theta_1 < X_{(n)} \leq x_i$ , se puede asegurar que  $x_i - \theta_1 = (x_i - X_{(n)}) + (X_{(n)} - \theta_1)$

$$\sum_{i=1}^n (x_i - \theta_1) = \sum_{i=1}^n (x_i - X_{(n)}) + \sum_{i=1}^n (X_{(n)} - \theta_1)$$

Ahora, claramente  $\text{😊} > \text{😞}$  Por consiguiente

$$\sum_{i=1}^n (x_i - \theta_1) \geq \sum_{i=1}^n (x_i - X_{(n)}) \text{ pero}$$

$$e^{-\sum_{i=1}^n (x_i - \theta_1)} \leq e^{-\sum_{i=1}^n (x_i - X_{(n)})}, \text{ Finalmente}$$

$$e^{-\frac{1}{\theta_2} \sum_{i=1}^n (x_i - \theta_1)} \leq e^{-\frac{1}{\theta_2} \sum_{i=1}^n (x_i - X_{(n)})} \Leftrightarrow L(X_{(n)}) \geq L(\theta_1 | X) \forall X$$

entonces  $X_{(n)}$  es MLE de  $\theta_1$

Propiedad del cálculo:  
si  $a, b$  son  $C \in \mathbb{R}$   
①  $e^a > e^b$   
②  $e^a < e^b$

exp. neg. es estricta decreciente

Ahora, dejando fijo a  $\theta_1 = X_{(n)}$

$$L(\theta_2 | X, X_{(n)}) = \prod_{i=1}^n \frac{1}{\theta_2} e^{-\frac{(X_i - X_{(n)})}{\theta_2}}$$

$$= \left(\frac{1}{\theta_2}\right)^n \prod_{i=1}^n e^{-\frac{1}{\theta_2} (X_i - X_{(n)})}, \text{ Aplicando Ln}$$

$$l(\theta_2 | X, X_{(n)}) = n \ln\left(\frac{1}{\theta_2}\right) - \frac{1}{\theta_2} \sum_{i=1}^n (X_i - X_{(n)})$$

Para hallar máximo, derivamos e igualamos a cero.

$$\frac{dl}{d\theta_2} = -\frac{n}{\theta_2} + \frac{1}{\theta_2^2} \sum_{i=1}^n X_i - n X_{(n)} = 0$$

$$= \frac{1}{\theta_2} \left( -n + \frac{1}{\theta_2} \sum_{i=1}^n X_i - n X_{(n)} \right) = 0$$

$$= \frac{1}{\theta_2} \sum_{i=1}^n X_i - n X_{(n)} = n$$

$$= \frac{1}{n} \sum_{i=1}^n X_i - X_{(n)} = \hat{\theta}_2$$

$$\hat{\theta}_2 = \bar{X} - X_{(n)}$$

Verifiquemos que sea un máximo (ottendo segundo derivado)

$$\frac{\partial^2 l}{\partial^2 \theta_2} = \frac{n}{\theta_2^2} - \frac{2}{\theta_2^3} \sum_{i=1}^n (X_i - X_{(n)}) \theta = \frac{n}{\theta_2^2} - \frac{2}{\theta_2^3} \sum_{i=1}^n X_i - n X_{(n)}$$

$$= \frac{1}{\theta_2^2} \left( n - \frac{2}{\theta_2} \sum_{i=1}^n X_i - n(X_{(n)}) \right) = 0$$

$$-n = -\frac{2}{\theta_2} \sum_{i=1}^n X_i - n(X_{(n)}) \quad \text{si multiplicamos}$$

$$\hat{\theta}_2 = \frac{1}{2} \bar{X} - n\theta_2 = -2 \left[ \sum_{i=1}^n X_i - n X_{(n)} \right]$$

$$\hat{\theta}_2 = \frac{2}{n} \bar{X} - 2 X_{(n)} \quad \text{Siempre es negativo por lo que } \hat{\theta}_2 \text{ es un MLE para } \theta_2.$$



Jonathan Smith García Muñoz  
1039 705595

(1) Sea  $X_1, \dots, X_n$  una ma de una población con pdf dada por

$$f(x|\theta) = \frac{\alpha x^{\alpha-1}}{\beta^\alpha}; \quad 0 < x < \beta; \quad \alpha > 0$$

MLE para  $\alpha$  y  $\beta$ .

• Suponga  $\alpha$  fijo. MLE para  $\beta$  está dado por

$L(\beta|X, \alpha) = c(x) f(x|\alpha, \beta) \Leftrightarrow$  función de verosimilitud

$$= \prod_{i=1}^n \frac{\alpha x_i^{\alpha-1}}{\beta^\alpha} = \alpha^n \prod_{i=1}^n \left( \frac{x_i}{\beta} \right)^{\alpha-1} \cdot \frac{1}{\prod_{i=1}^n x_i} = \alpha^n \left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} \frac{1}{\prod_{i=1}^n x_i}$$

• Como  $0 < x_i < \beta$ , entonces  $0 < \frac{x_i}{\beta} < 1$ .

• Se sabe que  $0 < x_i \leq X_{(n)} < \beta$

$$\therefore 0 < x_i \leq X_{(n)} \Rightarrow 0 < \frac{x_i}{X_{(n)}} < 1 \quad \text{para } \beta > X_{(n)} \quad \text{por tanto}$$

$$0 < x_i < \beta \Rightarrow 0 < \frac{x_i}{\beta} < 1 \quad \text{se concluye que}$$

$$\frac{x_i}{\beta} < \frac{x_i}{X_{(n)}}; \quad \text{Ahora, en el ejercicio...}$$

$$\left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} < \left( \prod_{i=1}^n \frac{x_i}{X_{(n)}} \right)^{\alpha-1} \Rightarrow \frac{\alpha^n}{\prod_{i=1}^n x_i} \left( \prod_{i=1}^n \frac{x_i}{\beta} \right)^{\alpha-1} \leq \frac{\alpha^n}{\prod_{i=1}^n x_i} \left( \prod_{i=1}^n \frac{x_i}{X_{(n)}} \right)^{\alpha-1}$$

lo que implica que  $L(\beta|X) \leq L(X_{(n)}|X) \quad \forall X$ , entonces

$X_{(n)}$  maximiza la función y el MLE de  $\beta$ ,  $\hat{\beta} = X_{(n)}$

Para  $\alpha$ ... Si fijamos  $\beta = X_{(n)}$

$$L(\alpha|X, X_{(n)}) = \prod_{i=1}^n \frac{\alpha x_i^{\alpha-1}}{X_{(n)}^\alpha} \Rightarrow \alpha^n \frac{\left( \prod_{i=1}^n x_i \right)^{\alpha-1}}{X_{(n)}^{\alpha n}}$$

$$\ell(\alpha|X, X_{(n)}) = n \ln(\alpha) - \alpha n \ln(X_{(n)}) + (\alpha-1) \sum_{i=1}^n \ln(x_i)$$

NOTA= Se me otorgaron los puntos de Bbc

Finalmente, dada la muestra:

$$\hat{\theta}_1 = X_{(1)} = \text{el mínimo} = 2$$

$$\hat{\theta}_2 = \bar{X} - X_{(1)} = 4,323 - 2 = 2,323$$

3)  $X_1, \dots, X_n$  una muestra de  $\text{Ber}(\theta)$ . Sea  $\bar{X}$  un estimador para  $\theta$ . Muestre que  $\bar{X}$  alcanza la cota de Rao-Cramer.

• Decir que alcanza la cota de Rao-Cramer es equivalente a probar que ese estimador es el UMVUE. Probamos esto.

$$E(\bar{X}) = E\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n} \sum E(X_i) = \frac{1}{n} \sum \theta = \frac{n\theta}{n} = \theta$$

$\bar{X}$  es insesgado.

Si  $w(x)$  es un estimador de  $\theta$ :

$$\text{Var}(w(x)) \geq \frac{\left(\frac{\partial}{\partial \theta} E(w(x))\right)^2}{-n E\left(\frac{\partial^2}{\partial^2 \theta} \ln p(x|\theta)\right)}$$

$$\left(\frac{\partial}{\partial \theta} E(\theta)\right)^2$$

$$= \frac{1}{-n E\left(\frac{\partial^2}{\partial^2 \theta} \ln(p(x|\theta))\right) = -n E\left(\frac{\partial^2}{\partial^2 \theta} (\ln p(x|\theta))\right)}$$



$$f(y, p) = \binom{n}{y} p^y (1-p)^{n-y} \left( \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} \right)$$

$$= \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha+y-1} (1-p)^{n-y+\beta-1}, \quad 0 < p < 1, y=0, 1, 2, \dots$$

$$F_Y(y) = \int_0^1 \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha+y-1} (1-p)^{n-y+\beta-1} dp$$

$$= \binom{n}{y} \frac{\Gamma(\alpha+\beta) \Gamma(y+\alpha) \Gamma(n-y+\beta)}{\Gamma(\alpha)\Gamma(\beta) \Gamma(n+\alpha+\beta)} \quad \text{Beta-Binomial}$$

$$\Rightarrow F(p|y) = \frac{f(y, p)}{f_Y(y)} = \frac{\Gamma(n+\alpha+\beta)}{\Gamma(y+\alpha) \Gamma(n-y+\beta)} p^{y+\alpha-1} (1-p)^{n-y+\beta-1}$$

$\Rightarrow p|y \sim \text{Beta}(y+\alpha, n-y+\beta)$ . El estimador Bayesiano para  $p$  está dado por:

$$\hat{p}_B = \frac{y+\alpha}{\alpha+\beta+n} = \left( \frac{n}{\alpha+\beta+n} \right) \left( \frac{y}{n} \right) + \left( \frac{\alpha+\beta}{\alpha+\beta+n} \right) \left( \frac{\alpha}{\alpha+\beta} \right)$$

$$\hat{p}_B = \underbrace{\frac{n}{\alpha+\beta+n}}_{\text{media muestral}} * \underbrace{\frac{y}{n}}_{\text{media muestral}} + (1 - \underbrace{\frac{n}{\alpha+\beta+n}}_{\text{media muestral}}) * \underbrace{\frac{\alpha}{\alpha+\beta}}_{\text{media a priori}}$$

$\hat{p}_B = \frac{n}{\alpha+\beta+n}$ ; Finalmente  $\hat{p}_B$  es un promedio ponderado entre la media muestral y la media de la distribución a priori.

5) Sea  $X = (x_1, \dots, x_n)$  una m.a. de una dist.

$\text{Ber}(p)$  y asuma  $p \sim \text{Beta}(\alpha, \beta)$ , donde  $\alpha, \beta$

son conocidos. Halle un estimador Bayesiano para  $p$  y muestre que dicho estimador es el promedio ponderado de la media muestral y la media a priori.

- El parámetro  $p$  se define como "éxito"

- Para hallar el estimador Bayesiano, se halla la distribución condicional de  $\theta$  dado  $x$  ( $\theta | x$ ), luego se calcula su valor esperado.

- La conjunta es la binomial por la a priori. Por definición.

- La marginal de  $Y$  se obtiene al integrar la conjunta con respecto a  $p$ :

- En vez de trabajar con la conjunta, se define  $Y$  como sumatorio de  $x_i$  y se halla la conjunta entre  $Y$  y  $p$

- $p \text{ distribuye } \sim \text{Beta}(\alpha, \beta)$

Entonces, con esto en mente, calculamos:



⊛ Tanto los logverosimilitudes van acompañados de una constante  $c(x)$  que a lo largo de derivar, se pierde.

Ahora,  $\text{Var}(\bar{x}) = \frac{\theta(1-\theta)}{n}$  por definición Bern.

$$P(x|\theta) = \theta^x (1-\theta)^{1-x}, \quad 0 \leq x \leq 1$$

$$\ln(x|\theta) = x \ln(\theta) + (1-x) \ln(1-\theta) \quad \text{⊛}$$

$$\frac{\partial}{\partial \theta} P(x|\theta) = \frac{x}{\theta} - \frac{(1-x)}{(1-\theta)}$$

$$\frac{\partial^2}{\partial \theta^2} \ln(P(x|\theta)) = \frac{-x}{\theta^2} - \frac{(1-x)}{(1-\theta)^2}$$

Ahora...

$$E\left(\frac{-x}{\theta^2} - \frac{(1-x)}{(1-\theta)^2}\right) = \frac{-\theta}{\theta^2} - \frac{(1-\theta)}{(1-\theta)^2} = -\left[\frac{1}{\theta} + \frac{1}{(1-\theta)}\right]$$

donde  $x$  representa la variable de la muestra

$$= -\frac{1}{\theta(1-\theta)}$$

$$\therefore w(x) = \bar{x}$$

$$E(w(x)) = E(\bar{x}) = \theta$$

Finalmente

$$-n \left( \frac{-1}{\theta(1-\theta)} \right)$$

$$= \frac{\theta(1-\theta)}{n}, \text{ que es la variancia de la distribución y por tanto}$$

es el UMVUE, Probado que alcanza la Cota de Rao-Cramer



$$\frac{\partial \ell}{\partial \theta} = \frac{n}{\theta+1} + \sum_{i=1}^n \ln(x_i) = 0$$

$$\frac{n}{\theta+1} = -\sum_{i=1}^n \ln(x_i)$$

$$\frac{-n}{\sum_{i=1}^n \ln(x_i)} = \theta+1 \Rightarrow \hat{\theta} = \frac{-n}{\sum_{i=1}^n \ln(x_i)} - 1$$

Comprobamos que sea máximo. Criterio segunda derivada

$$\frac{\partial^2 \ell}{\partial \theta^2} = \frac{-n}{(\theta+1)^2} < 0, \text{ por tanto } \hat{\theta} \text{ es}$$

el MLE para  $\theta$ .

9) Si  $x_1, \dots, x_n$  una m.a. de una pdf. dada por.

$$f(x|\theta) = (\theta+1)x^\theta; 0 \leq x < 1$$

- El método de momentos establece una igualdad entre los momentos muestrales y poblacionales.  $E(x)$  es el primer momento.

$$\therefore E(X) = \int_0^1 x(\theta+1)x^\theta dx = \int_0^1 x^{\theta+1}(\theta+1)dx$$

$$= \frac{(\theta+1)x^{\theta+2}}{\theta+2} \Big|_0^1 = \frac{\theta+1 \cdot 1}{\theta+2} = \frac{\theta+1}{\theta+2}$$

$$\therefore \bar{X} = \frac{\theta+1}{\theta+2} \Rightarrow \bar{X}(\theta+2) = \theta+1$$

$$\theta\bar{X} + 2\bar{X} = \theta+1$$

$$\theta\bar{X} - \theta = 1 - 2\bar{X}$$

$$\theta(\bar{X} - 1) = 1 - 2\bar{X}$$

$$\hat{\theta} = \frac{1-2\bar{X}}{\bar{X}-1} \Rightarrow \text{Estimador de momentos de } \theta$$

Hallamos función de verosimilitud

$$l(\theta) = c(x) \prod_{i=1}^n (\theta+1)x_i^\theta = \cancel{(\theta+1)^n \prod_{i=1}^n x_i^\theta}$$

$$= (\theta+1)^n \left( \prod_{i=1}^n x_i \right)^\theta$$

$$l(\theta) = n \ln(\theta+1) + \theta \sum_{i=1}^n \ln(x_i) + \ln(c(x))$$

↓

Se aplica  $\ln$  ya que es una fn más

fácil de maximizar