

## Tarea 2 Muestreo Estadístico.

Jhonatan Smith Garcia

15/4/2021

### Se plantea solución caso de estudio diapositiva 4, semana 5:

MAE CASO DE ESTUDIO: Un Ingeniero está interesado en estudiar la productividad de las máquinas en una multinacional, dicha productividad está representada por la producción mensual (en toneladas) que dichas máquinas generan del producto. La empresa está dividida en TRES plantas de producción. Las características de cada planta, así como los resultados del estudio se muestran en la siguiente tabla. Adicionalmente, se registraron las máquinas que necesitan mantenimiento.

### TABLA DE DATOS:

	Planta 1	Planta 2	Planta 3
Nro. Máq. por Planta	500	1000	4000
Nro. Máq. en la muestra	50	80	160
Nro. Máq. para mantenimiento	4	6	5
Producción Promedio (ton)	40	60	100
Desv. Est. De la producción	12	17	10

Ahora, las preguntas planteadas se encuentran en las diapositivas.

### Solución

- 1) En primera instancia se identifica la población objetivo, la pregunta problema y demás temas relacionados para realizar un correcto análisis estadístico. Para este caso puntual, la pregunta problema o fenómeno de interés es la productividad de las máquinas en una empresa multinacional. Dicha productividad se calcula basado en la producción mensual, teniendo en cuenta tres plantas de producción. Cada planta tiene sus características de producción, cada una de ellas son indispensables para la medida de la producción final. Es decir; la producción final depende de la producción de cada una de estas tres plantas. De esto último se entiende que, la pregunta problema se responde a través de un análisis de estratos (Cada una de las plantas). Luego, realiza un MAS para cada una de las plantas, seleccionando aleatoriamente una muestra de cada estrato (cada planta de producción) de manera independiente y aquí, claramente, la selección de una planta, no tiene relación ni incidencia sobre otras (muestras independientes). Bajo estas condiciones se asegura que el ingeniero realizó un Muestreo Aleatorio Estratificado.
- 2) Antes que nada, se debe tener en cuenta cada uno de los siguientes datos de la tabla:
  - $H = 3$  El número de estratos (Las tres plantas de producción)
  - $N_h$ , con  $h = 1, 2, 3$  El número de máquinas en la  $h$ -ésima planta de producción.
  - $n_h$  con  $h = 1, 2, 3$  Número de máquinas seleccionadas del  $h$ -ésimo estrato

- $N = N_1 + N_2 + N_3 = 5500$  El numero de maquinas en las respectivas plantas (Planta 1, tiene  $N_1$  maquinas, asi con las otras dos). (N será tomado como el tamaño poblacional total)
- Por notacion  $\bar{y}_h$ , con  $h = 1, 2, 3$  Produccion promedio en el h-esimo estrato (planta) Ademas, este es un estimador insesgado para la media poblacional. Este será el parametro a estimar.
- Por notacion  $S_h^2$ , con  $h = 1, 2, 3$  La varianza muestral en el h-esimo estrato.
- $\alpha = 0.05$  -Como en cada caso,  $\alpha$  es fijo y ademas, cada una de las muestras de los estratos es de un n mayor o igual a 30, entonces se tomará a  $B \approx 2 * \widehat{Var}(\bar{y}_h)$  para cada h. Esto debido a la aproximacion normal Z

Antes que nada, para hallar un IC al 95% se necesita realizar el calculo de la media muestral para cada estrato(dado en la tabla de resultados), con su respectiva varianza para cada planta. De esta manera:

**Para la planra de produccion #1:**  $\widehat{Var}(\bar{y}_1) = \frac{(N_1 - n_1) * S_1^2}{N_1 * n_1}$  asi, reemplazando los valores de la tabla obtenemos que:

$$\widehat{Var}(\bar{y}_1) = \frac{(500 - 50) * 12^2}{500 * 50} \approx 2.592$$

Con esto, se sabe que  $B_1 = 2 * \sqrt{2.592} \approx 3.22$  Teniendo en cuenta que  $B_1$  es el limite del error estimado asociado al estrato  $h = 1$  para la estimacion de la media muestral en el mismo h entonces un Ic de *aproximadamente* el 95% es  $\bar{y}_1 \pm B_1 = 40 \pm 3.22$

Por tanto el Ic solicitado para la media de la produccion mensual de la planta #1 es (36.78,43.22) implicando que, con una confianza de aproximadamente el 95% el valor real de la produccion real de toneladas promedio al mes esta entre el intervalo anterior.

**Para la planra de produccion #2:** Haciendo el mismo analisis hecho para la planta 1 se realizará para la planta #2.

$\widehat{Var}(\bar{y}_2) = \frac{(N_2 - n_2) * S_2^2}{N_2 * n_2}$  asi, reemplazando los valores de la tabla obtenemos que:

$$\widehat{Var}(\bar{y}_2) = \frac{(1000 - 80) * 17^2}{1000 * 80} \approx 3.3235$$

Con esto, se sabe que  $B_2 = 2 * \sqrt{3.3235} \approx 3.65$  Teniendo en cuenta que  $B_2$  es el limite del error estimado asociado al estrato  $h = 2$  para la estimacion de la media muestral en el mismo h entonces un Ic de *aproximadamente* el 95% es  $\bar{y}_2 \pm B_2 = 60 \pm 3.65$

Por tanto el Ic solicitado para la media de la produccion mensual de la planta #1 es (56.35,63.65) implicando que, con una confianza de aproximadamente el 95% el valor real de la produccion real de toneladas promedio al mes esta entre el intervalo anterior.

**Para la planta de produccion #3:** Haciendo el mismo analisis hecho para la planta 1 se realizará para la planta #2.

$\widehat{Var}(\bar{y}_3) = \frac{(N_3 - n_3) * S_3^2}{N_3 * n_3}$  asi, reemplazando los valores de la tabla obtenemos que:

$$\widehat{Var}(\bar{y}_3) = \frac{(4000 - 160) * 10^2}{4000 * 160} = 0.6$$

Con esto, se sabe que  $B_3 = 2 * \sqrt{0.6} \approx 1.55$  Teniendo en cuenta que  $B_3$  es el limite del error estimado asociado al estrato  $h = 3$  para la estimacion de la media muestral en el mismo h entonces un Ic de *aproximadamente* el 95% es  $\bar{y}_3 \pm B_3 = 100 \pm 1.55$

Por tanto el Ic solicitado para la media de la produccion mensual de la planta #1 es (98.45,101.55) implicando que, con una confianza de aproximadamente el 95% el valor real de la produccion real de toneladas promedio al mes esta entre el intervalo anterior.

Entonces para estimar la produccion media mensual de la multinacional se describe de la siguiente manera:

$$\bar{y}_{est} = \frac{1}{N} \sum_{h=1}^H N_h * \bar{y}_h$$

Y claramente, todos los parametros de esta expresion son conocidos. Asi, reemplazando, tendríamos que:

$$\bar{y}_{est} = \frac{1}{N} \sum_{h=1}^H N_h * \bar{y}_h = \frac{1}{5500} [(500)(40) + (60)(1000) + (100)(4000)] \approx 87.273$$

Por tanto, en promedio; la multinacional produce aproximadamente 87 toneladas mensuales.

Conociendo este dato, la varianza del estimador esta dada por:

$$\widehat{Var}(\bar{y}_{est}) = \frac{1}{N^2} \sum_{h=1}^3 N_h^2 * \widehat{Var}(\bar{y}_h) = \frac{1}{5500^2} [(500^2)(2.592) + (1000^2)(3.3235) + (4000^2)(0.6)] \approx 0.45$$

Sea  $B = 2 * \sqrt{0.45} \approx 1.35$  de esta forma, un IC de *aproximadamente* 95% para la produccion promedio mensual de la multinacional será (85.923,88.623)

Finalmente se concluye que, el valor real de la produccion mensual de la multinacional es un valor dentro de este intervalo, con una confianza aproximada del 95%.

**Estimacion total producido:** Para la estimacion del total producido en la multinacional se usará los datos ya calculados. En particular, la media ya estimada.

$$\hat{\tau}_{est} = \sum_{h=1}^H N_h * \bar{y}_h = (500 * 40) + (1000 * 60) + (4000 * 100) = 480000$$

La estimacion del total producido por la multinacional mensualmente es de unas 480000 toneladas.

Ahora, para calcular un IC al 90% de confianza, se tiene que:  $\widehat{Var}(\hat{\tau}_{est}) = \sum_{h=1}^H N_h^2 * \widehat{Var}(\bar{y}_h) = (500^2)(2.592) + (1000^2)(3.3235) + (4000^2)(0.6) = 13571500$

Ahora, para calcular el limite del error B se tiene que:

$$B = Z_{0.95} * \sqrt{\widehat{Var}(\hat{\tau}_{est})} = 1.644854 * 3683.952 = 6059.563$$

De esta manera un IC con una confianza al 90% para la produccion del total de la empresa estara dado por  $B \pm \hat{\tau} = (473940.4, 486059.6)$ . Lo que implica que el valor real de la totalidad mensual producida se encuentra en el IC dado.

**Estimar proporcion de maquinas en mantenimiento** Para calcular dicha proporcion, reemplazamos en la respectiva formula de la proporcion para muestreo estratificado.

$$\hat{p}_{est} = \frac{1}{N} \sum_{h=1}^H N_h * p_h$$

Pero de esta formula, se debe tener en cuenta que:

$\hat{p}_{est}$  es la proporcion de maquinas en mantenimiento (dato a estimar) -Dada por  $p_h = \frac{a_h}{n_h}$  cada una de las proporciones de las muestras.  $\widehat{Var}(p_h) = \frac{p_h(1-p_h)}{n_h-1} \frac{N_h}{N}$  la varianza estimada para la proporcion de maquinas en mantenimiento.

Al realizar todos los calculos se tiene que:  $\widehat{Var}(p_1) = \frac{4/50(46/50)}{50-1} \frac{500-50}{500} \approx 0.0014$

$$\widehat{Var}(p_2) = \frac{6/80(74/80)}{80-1} \frac{1000-80}{1000} \approx 0.0008$$

$$\widehat{Var}(p_3) = \frac{5/160(155/160)}{160-1} \frac{4000-160}{4000} \approx 0.0002$$

Finalmente,

$$\hat{p}_{est} = \frac{1}{5500} [(500 * 0.0014) + (1000 * 0.0008) + (4000 * 0.0002)] \approx 0.0436$$

Este dato se traduce como, la proporcion de maquinas en mantenimiento de la multinacional es de aproximadamente el 0.0435 (4.36%)

$$\widehat{Var}(\hat{p}_{est}) = \frac{1}{5500^2} [(500^2 * 0.0014) + (1000^2 * 0.0008) + (4000^2 * 0.0002)] \approx 0.00013$$

Para calcular el IC solicitado esta dado por  $\widehat{p}_{est} \pm Z_{0.975} * \widehat{Var}(\widehat{p}_{est}) = 0.0436 \pm 1.96 * \sqrt{0.0013} = (0.0213, 0.0659)$   
 Esto implica que el valor real de la proporción de la maquinaria en mantenimiento de la empresa esta en el intervalo dado con una confianza del 95%.

**Tamaño de muestra:** Esta es la información suministrada para calcular el tamaño de la muestra.

L.E.E:  $B = Z_{0.975} * \widehat{Var}(\widehat{y}_{est}) = 3$  o bien  $D = \frac{B^2}{Z_{0.975}^2} \approx 2.343$ ,  $\sigma_1^2 = 12^2, \sigma_2^2 = 17^2, \sigma_3^2 = 10^2$ ,  $D=2.343$ ,  $N=5500, N_1 = 500, N_2 = 1000$  y  $N_3 = 5500$

Y para calcular n se usa la expresión:

$$n = \frac{\sum_{h=1}^3 \frac{N_h^2 \sigma_h^2}{w_h}}{N^2 D + \sum_{h=1}^3 N_h \sigma_h^2}$$

De esta expresión anterior los únicos datos desconocidos son los  $w_h$  para ello, se calculan todos siguiendo todos la asignación óptima de Neyman ya que se desconocen costos del muestreo y se asumen todos ellos son iguales.

Por tanto  $w_h = \frac{N_h \sigma_h}{\sum_h N_h \sigma_h}$  para  $h=1$  sería:

$$w_1 = \frac{N_1 \sigma_1}{\sum_{h=1}^3 N_h \sigma_h} = \frac{500 * 12}{(500 * 12) + (1000 * 17) + (4000 * 10)}$$

y reemplazando los valores en esta expresión se tiene que  $w_1 = 2/21, w_2 = 17/63$  y  $w_3 = 40/63$ .

Luego:

$$N^2 * D = 5500^2 * 3 * 3 / (1.96)^2 = 70868908.7$$

$$\sum_{h=1}^3 \frac{N_h^2 \sigma_h^2}{w_h} = \frac{500^2 * 12^2}{2/21} + \frac{1000^2 * 17^2}{17/63} + \frac{4000^2 * 10^2}{40/63} \approx 3607870370.37037 \sum_{h=1}^3 N_h \sigma_h^2 = N_1 \sigma_1^2 + N_2 \sigma_2^2 + N_3 \sigma_3^2 = 761000$$

Finalmente, reemplazando todos los valores en la ecuación anterior; el valor final de  $n \approx 50.3682109$ , por tanto el tamaño de la muestra a tomar es  $n=51$ .

## Ejercicio 19 taller 2

Para este ejercicio se tiene que hay un total de 1000 personas. Si se toma a  $N=1000$  como el número total de habitantes y además sea  $Y_i$  la variable aleatoria definida como el número de personas que responde “sí” a la encuesta en la muestra  $i$ -ésima  $i=1,2$  (ya que hay dos grupos muestreados) Entonces, dadas las muestras del ejercicio, se tienen las siguientes proporciones:

- $p_1 = \frac{Y_1}{n_1} = \frac{60}{80} = 0.75$  Esta es la proporción de  $n_1$  de personas censadas que votaron “sí”
- $q_1 = 1 - p_1 = 0.25$  Este es el número de personas censadas que NO votaron “sí”
- $p_2 = \frac{Y_2}{n_2} = \frac{8}{20} = 0.4$  Proporción habitantes NO censados que votaron “Si”
- $q_2 = 1 - p_2 = 0.6$  Esta es la proporción de habitantes NO censados que no votaron “Si”

Al igual que en el ejercicio anterior, usamos la misma fórmula para calcular  $\widehat{p}_{est}$ . de esta manera:

$$\widehat{p}_{est} = \frac{1}{1000} [(0.75 * 800) + (0.4 * 200)] = 0.68 \text{ De esto se entiende que, aproximadamente el 68\% de los habitantes votaron “Si”, es decir; a favor.}$$

Ahora, para calcular el IC pedido, también se hará uso de la fórmula anterior de la varianza para la proporción. Así, para cada  $p$ , se tiene:

$$\widehat{Var}(p_h) = \frac{p_h(q_h)}{n_h - 1} \frac{N_h}{N_h}$$

$$\widehat{Var}(p_1) = \frac{0.75 * 0.25}{70} * \frac{800 - 80}{800} = 0.00213607 \quad \widehat{Var}(p_2) = \frac{0.4 * 0.6}{20} * \frac{200 - 20}{200} = 0.0108$$

Ahora:

$$\widehat{Var}(\widehat{p}_{est}) = \frac{1}{1000^2} [(0.00213607)(800^2) + (200^2)(0.0108)] \approx 0.0015$$

Ahora, Sea  $B = 2 * \sqrt{\widehat{Var}(p_{est})} = 0.07622335$  de esta manera, un IC de aproximadamente 95% para la proporción de votantes del municipio que votaron a favor es

$\hat{p}_{est} \pm B = 0.68 \pm 0.07622335 = (0.6037767, 0.7562234)$  Y esto, finalmente se interpreta que, con una confianza del 95% el dato real de la proporción de votantes a favor en el municipio se encuentra en el anterior IC dado.

NOTA PARA EL DOCENTE= Una duda profe. El error B se puede aproximar gracias a una Z cuando n es mayor o igual a 30. Sin embargo, en este caso n es “grande” pero los  $n_h$  son, 80 y 20 respectivamente. Ambos deben cumplir la condición de ser mayor a 30 para usar la aproximación del error por una normal? O no se fija en  $n_h$  si no en n, el tamaño de la muestra una vez sumado los estratos. La duda surge debido al tamaño del segundo estrato en este ejercicio y que apenas vengo a caer en cuenta de esta diferencia. Gracias de antemano!!