

Contenido I

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2
- 8 Coeficiente de determinación ó R^2 de una regresión

Contenido

- 1 **Introducción**
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2
- 8 Coeficiente de determinación ó R^2 de una regresión

Introducción

- Se desea modelar una relación de tendencia entre un par de variables (X, Y) ;
- *Pero muchas veces sólo se cuenta con datos observacionales sobre estas variables, obtenidos bajo situaciones no controladas estrictamente.*
- Posiblemente, no hubo replicación de las condiciones observadas
- *Bajo estas circunstancias lo más conveniente es el método de mínimos cuadrados (MCO).*

Introducción

- Se desea modelar una relación de tendencia entre un par de variables (X, Y) ;
- *Pero muchas veces sólo se cuenta con datos observacionales sobre estas variables, obtenidos bajo situaciones no controladas estrictamente.*
- Posiblemente, no hubo replicación de las condiciones observadas
- *Bajo estas circunstancias lo más conveniente es el método de mínimos cuadrados (MCO).*

Introducción

- Se desea modelar una relación de tendencia entre un par de variables (X, Y) ;
- *Pero muchas veces sólo se cuenta con datos observacionales sobre estas variables, obtenidos bajo situaciones no controladas estrictamente.*
- Posiblemente, no hubo replicación de las condiciones observadas
- *Bajo estas circunstancias lo más conveniente es el método de mínimos cuadrados (MCO).*

Introducción

- Se desea modelar una relación de tendencia entre un par de variables (X, Y) ;
- *Pero muchas veces sólo se cuenta con datos observacionales sobre estas variables, obtenidos bajo situaciones no controladas estrictamente.*
- Posiblemente, no hubo replicación de las condiciones observadas
- *Bajo estas circunstancias lo más conveniente es el método de mínimos cuadrados (MCO).*

Contenido

- 1 Introducción
- 2 Nomenclatura**
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2
- 8 Coeficiente de determinación ó R^2 de una regresión

Nomenclatura

En el modelo teórico:

- Y : Variable respuesta o dependiente.
- X : Variable predictora, independiente o regresora.
- E : Error aleatorio
- β_0, β_1 : Parámetros de la regresión. β_0 es el intercepto y β_1 la pendiente de la línea recta.
- $\mu_{Y|X}$: Valor esperado condicional de Y dado X , es decir, $E[Y|X]$

En el modelo estimado:

- $\widehat{\beta}_0$: Estimador del parámetro β_0
- $\widehat{\beta}_1$: Estimador del parámetro β_1 .
- \widehat{E} : Residual, es una estimación del error aleatorio.
- \widehat{Y} : Es la estimación de $\mu_{Y|X}$.

Nomenclatura

En el modelo teórico:

- Y : Variable respuesta o dependiente.
- X : Variable predictora, independiente o regresora.
- E : Error aleatorio
- β_0, β_1 : Parámetros de la regresión. β_0 es el intercepto y β_1 la pendiente de la línea recta.
- $\mu_{Y|X}$: Valor esperado condicional de Y dado X , es decir, $E[Y|X]$


En el modelo estimado:

- $\widehat{\beta}_0$: Estimador del parámetro β_0
- $\widehat{\beta}_1$: Estimador del parámetro β_1 .
- \widehat{E} : Residual, es una estimación del error aleatorio.
- \widehat{Y} : Es la estimación de $\mu_{Y|X}$.


Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 **Significado de la Regresión**
 - Función de medias en términos generales
 - Función de medias con forma lineal (MRLS)
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2

Función de medias en términos generales



(a)



(b)

Figura 1: Función de regresión: (a) Curva que pasa por las medias de Y dado cada valor de X , es decir, $\mu_{Y|X} = f(x)$
 (b) Curva con respecto a la cual es mínima la distancia vertical de las observaciones (x_i, y_i) $i = 1, 2, \dots, n$.

Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones**
 - Modelo de Regresión Lineal Simple (MRLS)
 - Consideraciones
 - Interpretación de los parámetros
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)

Modelo de Regresión Lineal Simple (MRLS)

Con n pares (X_i, Y_i) , $i = 1, 2, \dots, n$,

$$Y|X_i = \beta_0 + \beta_1 X_i + E_i, i = 1, 2, \dots, n \quad (1)$$

$$E[Y|X_i] = \beta_0 + \beta_1 X_i \quad (2)$$

Bajo el supuesto $E_i \stackrel{iid}{\sim} N(0, \sigma^2)$, *iid: Independientes e idénticamente distribuidos.*

Nota 4.1

Por simplicidad escribimos,

$$Y_i = \beta_0 + \beta_1 X_i + E_i, E_i \stackrel{iid}{\sim} N(0, \sigma^2) i = 1, 2, \dots, n \quad (3)$$

- Los errores $E_i = Y_i - (\beta_0 + \beta_1 X_i)$,
- Los errores E_i no son observables, desde que los parámetros β_j , $j = 0, 1$, son desconocidos y deben estimarse.

Modelo de Regresión Lineal Simple (MRLS)

Con n pares (X_i, Y_i) , $i = 1, 2, \dots, n$,

$$Y|X_i = \beta_0 + \beta_1 X_i + E_i, i = 1, 2, \dots, n \quad (1)$$

$$E[Y|X_i] = \beta_0 + \beta_1 X_i \quad (2)$$

Bajo el supuesto $E_i \stackrel{iid}{\sim} N(0, \sigma^2)$, *iid: Independientes e idénticamente distribuidos.*

Nota 4.1

Por simplicidad escribimos,

$$Y_i = \beta_0 + \beta_1 X_i + E_i, E_i \stackrel{iid}{\sim} N(0, \sigma^2) i = 1, 2, \dots, n \quad (3)$$

- Los errores $E_i = Y_i - (\beta_0 + \beta_1 X_i)$,
- Los errores E_i no son observables, desde que los parámetros β_j , $j = 0, 1$, son desconocidos y deben estimarse.

Modelo de Regresión Lineal Simple (MRLS)

Con n pares (X_i, Y_i) , $i = 1, 2, \dots, n$,

$$Y|X_i = \beta_0 + \beta_1 X_i + E_i, i = 1, 2, \dots, n \quad (1)$$

$$E[Y|X_i] = \beta_0 + \beta_1 X_i \quad (2)$$

Bajo el supuesto $E_i \stackrel{iid}{\sim} N(0, \sigma^2)$, *iid: Independientes e idénticamente distribuidos.*

Nota 4.1

Por simplicidad escribimos,

$$Y_i = \beta_0 + \beta_1 X_i + E_i, E_i \stackrel{iid}{\sim} N(0, \sigma^2) i = 1, 2, \dots, n \quad (3)$$

- Los errores $E_i = Y_i - (\beta_0 + \beta_1 X_i)$,
- Los errores E_i no son observables, desde que los parámetros β_j , $j = 0, 1$, son desconocidos y deben estimarse.

Interpretación de los parámetros

Nota 4.2

La interpretación de los coeficientes de regresión:

- β_1 : *Representa el cambio en la media de Y dado un cambio unitario en X.*
- β_0 : *Si el rango en que se observa X incluye a $x = 0$, entonces β_0 corresponde a la media de la distribución de Y cuando $x = 0$. Sin embargo, si $x = 0$ no ha sido observado en los datos, entonces β_0 no tiene interpretación práctica en el modelo de regresión.*

Interpretación de los parámetros

Nota 4.2

La interpretación de los coeficientes de regresión:

- β_1 : Representa el cambio en la media de Y dado un cambio unitario en X .
- β_0 : Si el rango en que se observa X incluye a $x = 0$, entonces β_0 corresponde a la media de la distribución de Y cuando $x = 0$. Sin embargo, si $x = 0$ no ha sido observado en los datos, entonces β_0 no tiene interpretación práctica en el modelo de regresión.

Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)**
 - Ejemplo con datos simulados
 - Tipos de sumas en MCO
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2

Estimación por Mínimos Cuadrados (MCO)

Con n pares (x_i, y_i) de observaciones: hallar β_0 y β_1 que minimicen a

Suma de Cuad. del error:
$$S(\beta_0, \beta_1) = \sum_{i=1}^n E_i^2 = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2 \quad (5)$$

Ecuaciones normales

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = 0, \quad \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} = 0$$

Conducen a

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i \quad (6)$$

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2, \quad (7)$$

Estimadores resultantes

Intercepto: $\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}, \quad (8)$

Pendiente: $\widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (9)$

o bien, $\widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (10)$

Estimación por Mínimos Cuadrados (MCO)

Con n pares (x_i, y_i) de observaciones: hallar β_0 y β_1 que minimicen a

Suma de Cuad. del error:
$$S(\beta_0, \beta_1) = \sum_{i=1}^n E_i^2 = \sum_{i=1}^n [Y_i - (\beta_0 + \beta_1 X_i)]^2 \quad (5)$$

Ecuaciones normales

$$\frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} = 0, \quad \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} = 0$$

Conducen a

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i \quad (6)$$

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2, \quad (7)$$

Estimadores resultantes

Intercepto: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad (8)$

Pendiente: $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (9)$

o bien, $\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (10)$


Ejemplo con datos simulados

Tabla 1: Datos simulados bajo modelo $Y_i = 62 + 3.5x_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, con $\sigma = 50$, y cálculos para ajuste del modelo de regresión lineal simple por mínimos cuadrados ordinarios.

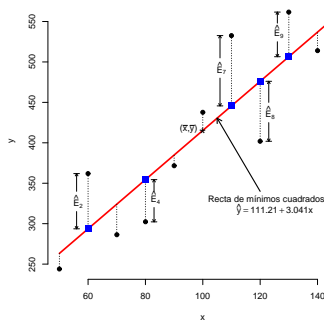
i	x_i	y_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$y_i - \bar{y}$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
1	50	243.93	-50	2500	-171.33	29353.35	8566.41
2	60	361.95	-40	1600	-53.31	2841.76	2132.33
3	70	286.37	-30	900	-128.89	16612.16	3866.65
4	80	302.25	-20	400	-113.01	12770.85	2260.16
5	90	371.58	-10	100	-43.68	1907.78	436.78
6	100	437.67	0	0	22.41	502.29	0
7	110	532.59	10	100	117.33	13766.76	1173.32
8	120	401.91	20	400	-13.35	178.17	-266.96
9	130	561.66	30	900	146.40	21433.49	4392.05
10	140	513.88	40	1600	98.62	9726.26	3944.87
11	150	554.05	50	2500	138.79	19263.17	6939.59
n	\bar{x}	\bar{y}	$\sum_{i=1}^n (x_i - \bar{x})$	$\sum_{i=1}^n (x_i - \bar{x})^2$	$\sum_{i=1}^n (y_i - \bar{y})$	$\sum_{i=1}^n (y_i - \bar{y})^2$	$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$
11	100	415.26	0	11000	0	128356.05	33445.2

$\widehat{\beta}_1 = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) / \sum_{i=1}^n (x_i - \bar{x})^2 = 3.041;$
 $\widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x} = 111.211;$

Tabla 2: Datos simulados, ajustes MCO y residuos (continuación Tabla 1).



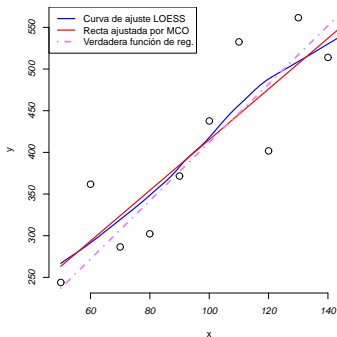
(a)



(b)


Figura 3: Ilustración del criterio de mínimos cuadrados. (a) Recta ajustada asumiendo como modelo a $Y_i = \beta_0 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, (b) Recta ajustada mediante mínimos cuadrados ordinarios con el modelo $Y_i = \beta_0 + \beta_1 x_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. La suma de cuadrados de residuos, $SSE = \sum_{i=1}^n \hat{E}_i^2 = 26666.83$, del ajuste en (b) es menor que en (a); para este último se tiene que $SSE = SST = \sum_{i=1}^n (y_i - \bar{y})^2 = 128356$, en cambio en (b), $SSE < SST$.

Gráfico de Dispersión datos simulados



(a)

Residuales vs. x



(b)

Figura 4: Resultados de ajuste en datos simulados. (a) Recta ajustada asumiendo como modelo a $Y_i = \beta_0 + \beta_1 x_i + E_i$, $E_i \stackrel{iid}{\sim} N(0, \sigma^2)$, curva LOESS y verdadera función de regresión $\mu_{Y|x} = 62 + 3.5x_i$, (b) Residuos \widehat{E}_i vs. x_i .

Funciones R para regresión lineal

Nombre	Descripción corta
<code>lm()</code>	Ajusta de modelos de regresión lineal.
<code>summary()</code>	Obtiene la tabla de parámetros estimados cuando se aplica a un objeto <code>lm</code> .
<code>anova()</code>	Para Tabla ANOVA.
<code>residuals()</code>	Obtiene los valores de los residuos de ajuste.
<code>fitted()</code>	Obtiene los valores ajustados en la variable respuesta.
<code>predict()</code>	Calcula predicciones puntuales y por intervalos de predicción. También permite calcular valores ajustados y los intervalos de confianza para $\mu_{Y x}$.
<code>qqnorm(), qqline()</code>	Para gráfico de probabilidad normal.
<code>shapiro.test()</code>	Para test de normalidad Shapiro-Wilk.
<code>coef()</code>	Extrae en un vector los valores estimados de los parámetros de la regresión.
<code>confint()</code>	Retorna una matriz en la cual en cada fila se dan los límites de los intervalos de confianza para los parámetros del modelo.
<code>vcov()</code>	Produce la matriz de varianzas y covarianzas estimadas, para el vector de parámetros estimado.

Tipos de sumas en MCO

Tabla 3: Principales sumas en el ajuste por mínimos cuadrados

Tipo de sumas	Expresión
Suma de cuadrados corregidos en x :	$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2 = \sum_{i=1}^n (x_i - \bar{x})x_i$
Suma de cuadrados corregidos en y . También es conocida como suma de cuadrados totales o SST:	$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - n\bar{y}^2 = \sum_{i=1}^n (y_i - \bar{y})y_i$
Suma de productos cruzados:	$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i$
Suma de los cuadrados de los residuos o SSE. Es la estimación de $S(\beta_0, \beta_1)$. Sea $\widehat{E}_i = y_i - \widehat{y}_i$ el i -ésimo residuo, entonces:	$SSE = \sum_{i=1}^n \widehat{E}_i^2 = \sum_{i=1}^n (y_i - \widehat{y}_i)^2 = S_{yy} - \widehat{\beta}_1 S_{xy}$
Suma de cuadrados de regresión SSR:	$SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2 = \widehat{\beta}_1^2 S_{xx} = \widehat{\beta}_1 S_{xy}$

$$\widehat{\beta}_1 \text{ puede ser expresado así: } \widehat{\beta}_1 = S_{xy}/S_{xx} \quad (11)$$

Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2
- 8 Coeficiente de determinación ó R^2 de una regresión

Estimación por máxima verosimilitud (MLE)

Estimación por máxima verosimilitud (MLE)

Definición 6.1 (Función de verosimilitud)

Dada una muestra observada \mathcal{M}_n de tamaño n y una distribución de probabilidad $F(\cdot, \theta)$, siendo θ un parámetro o un vector de parámetros, la función de verosimilitud $L(\theta|\mathcal{M}_n)$ puede concebirse como una cuantificación de la probabilidad de que la muestra proviene de la distribución F . La verosimilitud indica qué tan probable es que la muestra observada \mathcal{M}_n sea una función de los posibles valores de θ .

Estimación por máxima verosimilitud (MLE)

Definición 6.1 (Función de verosimilitud)

Dada una muestra observada \mathcal{M}_n de tamaño n y una distribución de probabilidad $F(\cdot, \theta)$, siendo θ un parámetro o un vector de parámetros, la función de verosimilitud $L(\theta|\mathcal{M}_n)$ puede concebirse como una cuantificación de la probabilidad de que la muestra proviene de la distribución F . La verosimilitud indica qué tan probable es que la muestra observada \mathcal{M}_n sea una función de los posibles valores de θ .

Definición 6.2 (Estimador de máxima verosimilitud ó MLE)

Dada una muestra observada \mathcal{M}_n , el estimador de máxima verosimilitud de θ , parámetro o vector de parámetros de una distribución de probabilidad $F(\cdot, \theta)$, es el valor de este parámetro (o vector de parámetros) que hace máxima la probabilidad de que la muestra \mathcal{M}_n haya sido generada de la distribución $F(\cdot, \theta)$.

Denotaremos por $\tilde{\theta}$ al MLE de θ .

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Entonces:

$$L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2\right\} \\ = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2\right\}. \quad (12)$$

Verosimilitud en el MRLS

- $\mathcal{M}_n = (\mathbf{x}, \mathbf{y})$: los pares de puntos observados $(x_1, y_1), \dots, (x_n, y_n)$.
- *Modelo probabilístico: $Y|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$, y $Y|x_1, \dots, Y|x_n$ son independientes, y la función de densidad conjunta es $f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$.*
- Vector de parámetros desconocidos: $\theta = (\beta_0, \beta_1, \sigma^2)$.
- *La función de verosimilitud: $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma^2)$,*

Entonces:

$$\begin{aligned} L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2} (y_i - \beta_0 - \beta_1 x_i)^2\right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2\right\}. \end{aligned} \quad (12)$$

Objetivo: Hallar β_0 , β_1 y σ^2 que maximicen a $L(\beta_0, \beta_1, \sigma^2 | \mathbf{x}, \mathbf{y})$, o equivalentemente a $\log L$ su logaritmo natural (log-versosimilitud).

El MLE de $\theta = (\beta_0, \beta_1, \sigma^2)$

Con n pares (x_i, y_i) de observaciones: hallar β_0, β_1 y σ^2 que maximicen al log-versosimilitud:

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}_{S(\beta_0, \beta_1) = \sum_{i=1}^n E_i^2}. \quad (13)$$

El MLE de $\theta = (\beta_0, \beta_1, \sigma^2)$

Con n pares (x_i, y_i) de observaciones: hallar β_0, β_1 y σ^2 que maximicen al log-versosimilitud:

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \underbrace{\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}_{S(\beta_0, \beta_1) = \sum_{i=1}^n E_i^2}. \quad (13)$$

Sistema de ecuaciones

$$\begin{aligned} \frac{\partial \log L}{\partial \beta_0} &= 0, \quad \frac{\partial \log L}{\partial \beta_1} = 0, \quad \frac{\partial \log L}{\partial \sigma^2} = 0 : \\ \sum_{i=1}^n y_i &= n\beta_0 + \beta_1 \sum_{i=1}^n x_i \end{aligned} \quad (14)$$

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 \quad (15)$$

$$\sigma^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 / n \quad (16)$$

El MLE de $\theta = (\beta_0, \beta_1, \sigma^2)$

Con n pares (x_i, y_i) de observaciones: hallar β_0, β_1 y σ^2 que maximicen al log-versosimilitud:

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \underbrace{\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2}_{S(\beta_0, \beta_1) = \sum_{i=1}^n E_i^2} \quad (13)$$

Sistema de ecuaciones

$$\frac{\partial \log L}{\partial \beta_0} = 0, \quad \frac{\partial \log L}{\partial \beta_1} = 0, \quad \frac{\partial \log L}{\partial \sigma^2} = 0 :$$

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i \quad (14)$$

$$\sum_{i=1}^n x_i y_i = \beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 \quad (15)$$

$$\sigma^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 / n \quad (16)$$

Estimadores resultantes

$$\text{Intercepto: } \widetilde{\beta}_0 = \widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}, \quad (17)$$

$$\text{Pendiente: } \widetilde{\beta}_1 = \widehat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (18)$$

$$\text{Varianza: } \widetilde{\sigma}^2 = \frac{1}{n} \underbrace{\sum_{i=1}^n (y_i - \widehat{\beta}_0 - \widehat{\beta}_1 x_i)^2}_{\text{SSE} = \sum_{i=1}^n \widehat{E}_i^2} \quad (19)$$

Estimadores MLE vs. estimadores MCO

- Los estimadores MLE: $\tilde{\beta}_0$ y $\tilde{\beta}_1$ son iguales, respectivamente, a los estimadores MCO: $\widehat{\beta}_0$ y $\widehat{\beta}_1$, sólo si se cumple los supuestos sobre los errores de ajuste: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$.
- *La diferencia entre los dos métodos se da en la estimación de la varianza σ^2 (ver más adelante).*
- Cuando alguno de los supuestos sobre los errores no es válido, hay que buscar soluciones alternativas: Transformaciones, modelos lineales generalizados, métodos no paramétricos, entre otros.

Estimadores MLE vs. estimadores MCO

- Los estimadores MLE: $\tilde{\beta}_0$ y $\tilde{\beta}_1$ son iguales, respectivamente, a los estimadores MCO: $\widehat{\beta}_0$ y $\widehat{\beta}_1$, sólo si se cumple los supuestos sobre los errores de ajuste: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$.
- *La diferencia entre los dos métodos se da en la estimación de la varianza σ^2 (ver más adelante).*
- Cuando alguno de los supuestos sobre los errores no es válido, hay que buscar soluciones alternativas: Transformaciones, modelos lineales generalizados, métodos no paramétricos, entre otros.

Estimadores MLE vs. estimadores MCO

- Los estimadores MLE: $\widetilde{\beta}_0$ y $\widetilde{\beta}_1$ son iguales, respectivamente, a los estimadores MCO: $\widehat{\beta}_0$ y $\widehat{\beta}_1$, sólo si se cumplen los supuestos sobre los errores de ajuste: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$.
- La diferencia entre los dos métodos se da en la estimación de la varianza σ^2 (ver más adelante).*
- Cuando alguno de los supuestos sobre los errores no es válido, hay que buscar soluciones alternativas: Transformaciones, modelos lineales generalizados, métodos no paramétricos, entre otros.

Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2**
- 8 Coeficiente de determinación ó R^2 de una regresión

Estimación de σ^2

Sean $\widehat{E}_i = y_i - \widehat{y}_i$ los residuos del ajuste del MRLS con base en una muestra de tamaño n . Sea también la suma de cuadrados de los residuos de ajuste, $SSE = \sum_{i=1}^n \widehat{E}_i^2$. Bajo supuestos: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$,

Estimación de σ^2

Sean $\widehat{E}_i = y_i - \widehat{y}_i$ los residuos del ajuste del MRLS con base en una muestra de tamaño n . Sea también la suma de cuadrados de los residuos de ajuste, $SSE = \sum_{i=1}^n \widehat{E}_i^2$. Bajo supuestos: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$,

Tabla 4: Comparación estimadores de la varianza

Estimador	Ecuación	Valor Esperado
Insesgado: MSE	$\hat{\sigma}^2 = \frac{SSE}{n-2}$	$E[\hat{\sigma}^2] = \sigma^2$
MLE	$\hat{\sigma}^2 = \frac{1}{n} SSE$	$E[\hat{\sigma}^2] = \left(\frac{n-2}{n}\right) \sigma^2$

Estimación de σ^2

Sean $\widehat{E}_i = y_i - \widehat{y}_i$ los residuos del ajuste del MRLS con base en una muestra de tamaño n . Sea también la suma de cuadrados de los residuos de ajuste, $SSE = \sum_{i=1}^n \widehat{E}_i^2$. Bajo supuestos: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$,

Tabla 4: Comparación estimadores de la varianza

Estimador	Ecuación	Valor Esperado
Insesgado: MSE	$\hat{\sigma}^2 = \frac{SSE}{n-2}$	$E[\hat{\sigma}^2] = \sigma^2$
MLE	$\tilde{\sigma}^2 = \frac{1}{n}SSE$	$E[\tilde{\sigma}^2] = \left(\frac{n-2}{n}\right)\sigma^2$

- Note que $\hat{\sigma}^2 = \left(\frac{n-2}{n}\right) \hat{\sigma}^2$.
- $\hat{\sigma}^2$ es insesgado mientras que $\hat{\sigma}^2$ es sesgado con respecto a σ^2 , sin embargo, este último es asintóticamente insesgado: $\lim_{n \rightarrow \infty} E[\hat{\sigma}^2] = \sigma^2$.
- El estimador MLE es de mínima varianza y consistente: $\hat{\sigma}^2 \xrightarrow{P} \sigma^2$.

Estimación de σ^2

Sean $\widehat{E}_i = y_i - \widehat{y}_i$ los residuos del ajuste del MRLS con base en una muestra de tamaño n . Sea también la suma de cuadrados de los residuos de ajuste, $SSE = \sum_{i=1}^n \widehat{E}_i^2$. Bajo supuestos: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$,

Tabla 4: Comparación estimadores de la varianza

Estimador	Ecuación	Valor Esperado
Insesgado: MSE	$\hat{\sigma}^2 = \frac{SSE}{n-2}$	$E[\hat{\sigma}^2] = \sigma^2$
MLE	$\hat{\sigma}^2 = \frac{1}{n} SSE$	$E[\hat{\sigma}^2] = \left(\frac{n-2}{n}\right) \sigma^2$

- Note que $\hat{\sigma}^2 = \left(\frac{n-2}{n}\right)\hat{\sigma}^2$.
- $\hat{\sigma}^2$ es insesgado mientras que $\hat{\sigma}^2$ es sesgado con respecto a σ^2 , sin embargo, este último es asintóticamente insesgado: $\lim_{n \rightarrow \infty} E[\hat{\sigma}^2] = \sigma^2$.
- El estimador MLE es de mínima varianza y consistente: $\hat{\sigma}^2 \xrightarrow{P} \sigma^2$.

Estimación de σ^2

Sean $\widehat{E}_i = y_i - \widehat{y}_i$ los residuos del ajuste del MRLS con base en una muestra de tamaño n . Sea también la suma de cuadrados de los residuos de ajuste, $SSE = \sum_{i=1}^n \widehat{E}_i^2$. Bajo supuestos: $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$,

Tabla 4: Comparación estimadores de la varianza

Estimador	Ecuación	Valor Esperado
Insesgado: MSE	$\hat{\sigma}^2 = \frac{SSE}{n-2}$	$E[\hat{\sigma}^2] = \sigma^2$
MLE	$\hat{\sigma}^2 = \frac{1}{n} SSE$	$E[\hat{\sigma}^2] = \left(\frac{n-2}{n}\right) \sigma^2$

- Note que $\hat{\sigma}^2 = \left(\frac{n-2}{n}\right)\hat{\sigma}^2$.
- $\hat{\sigma}^2$ es insesgado mientras que $\hat{\sigma}^2$ es sesgado con respecto a σ^2 , sin embargo, este último es asintóticamente insesgado: $\lim_{n \rightarrow \infty} E[\hat{\sigma}^2] = \sigma^2$.
- El estimador MLE es de mínima varianza y consistente: $\hat{\sigma}^2 \xrightarrow{P} \sigma^2$.

Contenido

- 1 Introducción
- 2 Nomenclatura
- 3 Significado de la Regresión
- 4 Modelo y consideraciones
- 5 Estimación por Mínimos Cuadrados (MCO)
- 6 Estimación por máxima verosimilitud (MLE)
- 7 Estimación de σ^2
- 8 Coeficiente de determinación ó R^2 de una regresión

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

- Suma de cuadrados totales (vista previamente como S_{yy}): $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- Suma de cuadrados de residuos: $SSE = \sum_{i=1}^n \widehat{E}_i^2$
- Suma de cuadrados de regresión: $SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2$

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

- Suma de cuadrados totales (vista previamente como S_{yy}): $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- Suma de cuadrados de residuos: $SSE = \sum_{i=1}^n \widehat{E}_i^2$
- Suma de cuadrados de regresión: $SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2$

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

- Suma de cuadrados totales (vista previamente como S_{yy}): $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- Suma de cuadrados de residuos: $SSE = \sum_{i=1}^n \widehat{E}_i^2$
- Suma de cuadrados de regresión: $SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2$

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

- Suma de cuadrados totales (vista previamente como S_{yy}): $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- Suma de cuadrados de residuos: $SSE = \sum_{i=1}^n \widehat{E}_i^2$
- Suma de cuadrados de regresión: $SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2$

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

- Suma de cuadrados totales (vista previamente como S_{yy}): $SST = \sum_{i=1}^n (y_i - \bar{y})^2$
- Suma de cuadrados de residuos: $SSE = \sum_{i=1}^n \widehat{E}_i^2$
- Suma de cuadrados de regresión: $SSR = \sum_{i=1}^n (\widehat{y}_i - \bar{y})^2$

La descomposición: $SST = SSR + SSE$, la veremos más adelante como Análisis de varianza o ANOVA.

Coeficiente de determinación ó R^2 de una regresión

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (20)$$

Interpretación: La proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con la variable predictora considerada.

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

La descomposición: $SST = SSR + SSE$, la veremos más adelante como Análisis de varianza o ANOVA.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (20)$$

Interpretación: La proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con la variable predictora considerada.

Interpretaciones erróneas:

- *Un R^2 alto indica que el modelo puede hacer predicciones útiles.*
- *Un R^2 alto indica que la recta de regresión tiene buen ajuste.*
- *Un R^2 cercano a cero indica que X y Y no están relacionados.*

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

La **descomposición**: $SST = SSR + SSE$, la veremos más adelante como Análisis de varianza o ANOVA.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (20)$$

Interpretación: La proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con la variable predictora considerada.

Interpretaciones erróneas:

- Un R^2 alto indica que el modelo puede hacer predicciones útiles.
- Un R^2 alto indica que la recta de regresión tiene buen ajuste.
- Un R^2 cercano a cero indica que X y Y no están relacionados.

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:

La **descomposición**: $SST = SSR + SSE$, la veremos más adelante como Análisis de varianza o ANOVA.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (20)$$

Interpretación: La proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con la variable predictora considerada.

Interpretaciones erróneas:

- Un R^2 alto indica que el modelo puede hacer predicciones útiles.
- Un R^2 alto indica que la recta de regresión tiene buen ajuste.
- Un R^2 cercano a cero indica que X y Y no están relacionados.

Coeficiente de determinación ó R^2 de una regresión

Considere las siguientes sumas de cuadrados:


La **descomposición**: $SST = SSR + SSE$, la veremos más adelante como Análisis de varianza o ANOVA.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (20)$$


Interpretación: La proporción de la variabilidad total observada en la variable respuesta, que es explicada por la relación lineal con la variable predictora considerada.

Interpretaciones erróneas:


- Un R^2 alto indica que el modelo puede hacer predicciones útiles.
- Un R^2 alto indica que la recta de regresión tiene buen ajuste.
- Un R^2 cercano a cero indica que X y Y no están relacionados.



(a)



(b)



(c)

Figura 5: Datos simulados.(a) la verdadera relación estadística es lineal: $\mu_{Y|X} = 650 + 2x$ y el ajuste RLS arroja R^2 cercano a 1; (b) La verdadera relación no es lineal: $\mu_{Y|X} = 30000 + 2x + 0.2x^2$ aunque el ajuste por RLS arroja R^2 cercano a 1; (c) La verdadera relación no es lineal: $\mu_{Y|X} = 92500 - 100x + 0.2x^2$ y el ajuste RLS produce un R^2 de casi cero, sin embargo, en este caso, no se puede decir que no existe relación estadística entre X y Y sino que la relación es no lineal.




Figura 6: Datos simulados. El verdadero modelo es $Y_i = 5000 + E_i$, $E_i \stackrel{iid}{\sim} N(0, 10000)$, es decir, no hay ningún tipo de asociación estadística de Y con X , sin embargo, se ajustó modelo de RLS asumiendo que $\mu_{Y|x} = \beta_0 + \beta_1 x$, y su ajuste da un R^2 pequeño, como era de esperarse bajo estas circunstancias. El modelo $Y_i = \beta_0 + E_i$, $E_i \stackrel{iid}{\sim} N(0, \sigma^2)$ da como estimación $\hat{\beta}_0 = 4995.508$ muy próximo a la media verdadera de Y .