

Notas de Clase Sobre Regresión Lineal

Regresión Lineal Simple (RLS): Parte III

Nelfi González Alvarez

Profesora Asociada Escuela de Estadística

e-mail: ngonzale@unal.edu.co

Isabel Cristina Ramírez Guevara

Profesora Asociada Escuela de Estadística

e-mail: iscramirezgu@unal.edu.co

Facultad de Ciencias, Universidad Nacional de Colombia Sede Medellín



UNIVERSIDAD NACIONAL DE COLOMBIA

Escuela de Estadística

2021

Contenido I

1 Tipos de diagnósticos

Contenido

1 Tipos de diagnósticos

- Test de carencia de ajuste: No linealidad de la función de regresión
- Tests de homocedasticidad
- Evaluación de la independencia
- Evaluación de normalidad y outliers

Tipos de diagnósticos

Para la variable predictora

- * *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- * *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

¿El modelo se ajusta bien a los datos? ¿Hay observaciones de observación de ajuste (por hay explicación) por los datos observados.

¿El modelo cumple los supuestos de la regresión? Tests de homocedasticidad, gráficos de residuos.

¿El modelo es válido para los datos? ¿Hay observaciones de ajuste (por hay explicación) por los datos observados? ¿Hay observaciones de ajuste (por hay explicación) por los datos observados? ¿Hay observaciones de ajuste (por hay explicación) por los datos observados?

¿Hay observaciones de ajuste (por hay explicación) por los datos observados? ¿Hay observaciones de ajuste (por hay explicación) por los datos observados? ¿Hay observaciones de ajuste (por hay explicación) por los datos observados?

Tipos de diagnósticos

Para el modelo

• *¿El modelo es adecuado?*
• *¿El modelo es lineal?*
• *¿El modelo es homogéneo?*
• *¿El modelo es independiente?*

• *¿El modelo es normal?*
• *¿El modelo es estable?*
• *¿El modelo es robusto?*

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

• *¿El modelo es estable?*
• *¿El modelo es robusto?*

• *¿El modelo es normal?*
• *¿El modelo es estable?*
• *¿El modelo es robusto?*

• *¿El modelo es normal?*
• *¿El modelo es estable?*
• *¿El modelo es robusto?*

• *¿El modelo es normal?*
• *¿El modelo es estable?*
• *¿El modelo es robusto?*

Tipos de diagnósticos

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Tipos de diagnósticos

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianzas constantes?* Tests de homocedasticidad, gráficos de residuos.

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Tipos de diagnósticos

Para la variable predictora

- *Observaciones x extremas que puedan influenciar el ajuste de regresión?* Un análisis descriptivo: box plots, diagramas de puntos.
- *Patrones temporales en los valores x ?* Gráfico de x vs. tiempo o algún índice de ordenación.

Para el modelo

- *La función de regresión es lineal?* Test de carencia de ajuste (si hay réplicas), gráficos de residuos.
- *Los errores tienen varianza constante?* Tests de homocedasticidad, gráficos de residuos.
- *Los errores son independientes?* Tests de incorrelación y gráfico residuos vs. tiempo (si se conoce orden temporal).
- *Los errores son normales?* Gráfico de probabilidad normal y tests para normalidad, con residuos.
- *Hay observaciones outliers?* Análisis residuos estandarizados, residuos estudentizados.
- *No hace falta una o más variables predictoras?* Gráficos residuos vs. otras variables no consideradas.

Comportamientos esperados

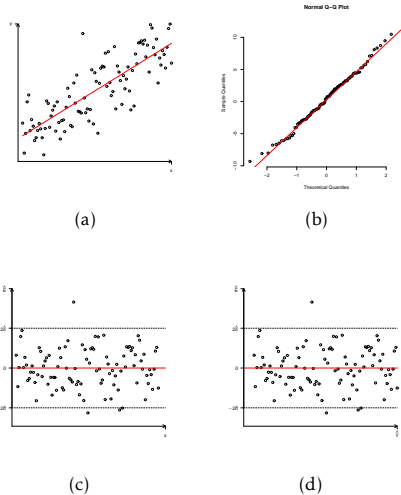


Figura 1: Ilustración de un modelo lineal adecuado con varianza constante y supuesto de normalidad válido. (a) gráfico de dispersión; (b) gráfico de probabilidad normal con residuos; (c) gráfico de residuos vs. x ; (d) gráfico de residuos vs. \hat{y} .

Por qué se espera un patrón rectangular en la dispersión de residuos?




Figura 2: En (a) \widehat{E}_i vs. \widehat{y}_i y (b) \widehat{E}_i vs. x_i , con n grande, en cada nivel de \widehat{y}_i y de x_i , se espera que los \widehat{E}_i se comporten como v.a normales, independientes, de media cero y con misma varianza, como consecuencia de que los verdaderos errores satisfacen $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. También se espera que no más de un 5% de los residuos estén por fuera de las bandas $\pm 2\widehat{\sigma}$.

Nota 1.1

No se grafican \widehat{E}_i vs. y_i , desde que $\text{Cov}(\widehat{E}_i, Y_i) = (1 - h_{ii})\sigma^2 \rightarrow \sigma^2$, con $n \rightarrow \infty$, de modo que a mayor σ^2 , veríamos en esa gráfica una tendencia lineal con pendiente positiva, y no un gráfico como los ilustrados previamente.

Por qué se espera un patrón rectangular en la dispersión de residuos?




Figura 2: En (a) \widehat{E}_i vs. \widehat{y} y (b) \widehat{E}_i vs. x , con n grande, en cada nivel de \widehat{y} y de x , se espera que los \widehat{E}_i se comporten como v.a normales, independientes, de media cero y con misma varianza, como consecuencia de que los verdaderos errores satisfacen $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. También se espera que no más de un 5% de los residuos estén por fuera de las bandas $\pm 2\widehat{\sigma}$.

Nota 1.1

No se grafican \widehat{E}_i vs. y_i , desde que $\text{Cov}(\widehat{E}_i, Y_i) = (1 - h_{ii})\sigma^2 \rightarrow \sigma^2$, con $n \rightarrow \infty$, de modo que a mayor σ^2 , veríamos en esa gráfica una tendencia lineal con pendiente positiva, y no un gráfico como los ilustrados previamente.

Ejemplo patrones que indican varianza no constante






Figura 3: Patrón de embudo: (a) gráfico de dispersión con recta ajustada; (c) residuos vs. x. Patrón de balón de fútbol americano: (b) gráfico de dispersión con recta ajustada; (d) residuos vs. x.


Ejemplo patrón que indica carencia de ajuste



(a)




(b)




(c)

Figura 4: Ejemplo del caso donde el modelo lineal entre y y x no es adecuado, pero la varianza es constante: (a) gráfico de dispersión con recta ajustada, (b) residuos vs. x y (c) residuos vs. \hat{y} .


Ejemplo patrón carencia de ajuste junto con varianza no constante



(a)



(b)



(c)

Figura 5: Ejemplo del caso donde el modelo lineal entre y y x no es adecuado, ni la varianza es constante: (a) gráfico de dispersión con recta ajustada (b) residuos vs. x y (c) residuos vs. \hat{y} .

Test de carencia de ajuste: No linealidad de la función de regresión

- *El test asume que los valores de Y dado X son:*
 - independientes
 - se distribuyen en forma normal
 - tienen varianza constante
- *Se requiere que en uno o más valores de X haya más de una observación de Y ó réplicas. Usaremos la siguiente notación:*

- Y_{ij} , la respuesta j -ésima en el i -ésimo nivel de X ;
- x_i , i -ésimo nivel de X ; supondremos $i = 1, 2, \dots, k$;
- n_i , número de observaciones de Y tomadas en el i -ésimo nivel de X . Por tanto, el total de observaciones n corresponde a

$$n = \sum_{i=1}^k n_i. \quad (1)$$

- *El test define el modelo lineal general que corresponde a*

$$Y_{ij} = \mu_i + E_{ij}, \text{ con } E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \forall i, j, i = 1, \dots, k, j = 1, \dots, n_i, \quad (2)$$

donde $\mu_i = E[Y_{ij}]$,

Test de carencia de ajuste: No linealidad de la función de regresión

- El test asume que los valores de Y dado X son:
 - independientes
 - se distribuyen en forma normal
 - tienen varianza constante
- Se requiere que en uno o más valores de X haya más de una observación de Y ó réplicas. Usaremos la siguiente notación:
 - Y_{ij} , la respuesta j -ésima en el i -ésimo nivel de X ;
 - x_i , i -ésimo nivel de X ; supondremos $i = 1, 2, \dots, k$;
 - n_i , número de observaciones de Y tomadas en el i -ésimo nivel de X . Por tanto, el total de observaciones n corresponde a

$$n = \sum_{i=1}^k n_i. \quad (1)$$

- El test define el modelo lineal general que corresponde a

$$Y_{ij} = \mu_i + E_{ij}, \text{ con } E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \forall i, j, i = 1, \dots, k, j = 1, \dots, n_i, \quad (2)$$

donde $\mu_i = E[Y_{ij}]$,

Test de carencia de ajuste: No linealidad de la función de regresión

- El test asume que los valores de Y dado X son:
 - independientes
 - se distribuyen en forma normal
 - tienen varianza constante
- Se requiere que en uno o más valores de X haya más de una observación de Y ó réplicas. Usaremos la siguiente notación:

- Y_{ij} , la respuesta j -ésima en el i -ésimo nivel de X ;
- x_i , i -ésimo nivel de X ; supondremos $i = 1, 2, \dots, k$;
- n_i , número de observaciones de Y tomadas en el i -ésimo nivel de X . Por tanto, el total de observaciones n corresponde a

$$n = \sum_{i=1}^k n_i. \quad (1)$$

- El test define **el modelo lineal general** que corresponde a

$$Y_{ij} = \mu_i + E_{ij}, \text{ con } E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \forall i, j, i = 1, \dots, k, j = 1, \dots, n_i, \quad (2)$$

donde $\mu_i = E[Y_{ij}]$,

Tabla 1: Comparación entre el MRLS y el modelo lineal general

Características	MRLS	Modelo lineal general
Ecuación	$Y_{ij} = \beta_0 + \beta_1 x_i + E_{ij}$ $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$	$Y_{ij} = \mu_i + E_{ij}$ $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$
Respuesta media	$E[Y_{ij}] = \beta_0 + \beta_1 x_i$	$E[Y_{ij}] = \mu_i$
Respuesta estimada	$\widehat{Y}_{ij} = \widehat{Y}_{i\bullet} = \widehat{\beta}_0 + \widehat{\beta}_1 x_i$ Todas las obs. en mismo nivel x_i tienen misma respuesta estimada: $\widehat{Y}_{i\bullet}$	$\widehat{Y}_{ij} = \widehat{Y}_{i\bullet} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}$ Todas las obs. en mismo nivel x_i tienen misma respuesta estimada: $\widehat{Y}_{i\bullet}$
Residuos de ajuste	$\widehat{E}_{ij} = Y_{ij} - \widehat{Y}_{i\bullet}$	$\widehat{E}_{ij} = Y_{ij} - \widehat{Y}_{i\bullet}$
Suma cuad. residuos	$SSE = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \widehat{Y}_{i\bullet})^2$ $\text{g.l}(SSE) = n - 2$	$SSPE = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \widehat{Y}_{i\bullet})^2$ Conocido como suma de cuadrados de error puro $\text{g.l}(SSPE) = n - k$

Tenemos la siguiente descomposición bajo supuestos $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$:

$$\begin{aligned}
 SSE &= \underbrace{SSPE}_{\text{S.C error puro}} + \underbrace{SSLOF}_{\text{S.C carencia de ajuste}} \\
 \text{g.l}(SSE) &= \underbrace{\text{g.l}(SSPE)}_{n-2} + \underbrace{\text{g.l}(SSLOF)}_{k-2}
 \end{aligned}
 \tag{3}$$

Tabla 1: Comparación entre el MRLS y el modelo lineal general

Características	MRLS	Modelo lineal general
Ecuación	$Y_{ij} = \beta_0 + \beta_1 x_i + E_{ij}$ $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$	$Y_{ij} = \mu_i + E_{ij}$ $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$
Respuesta media	$E[Y_{ij}] = \beta_0 + \beta_1 x_i$	$E[Y_{ij}] = \mu_i$
Respuesta estimada	$\widehat{Y}_{ij} = \widehat{Y}_{i\bullet} = \widehat{\beta}_0 + \widehat{\beta}_1 x_i$ Todas las obs. en mismo nivel x_i tienen misma respuesta estimada: $\widehat{Y}_{i\bullet}$	$\widehat{Y}_{ij} = \widehat{Y}_{i\bullet} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}$ Todas las obs. en mismo nivel x_i tienen misma respuesta estimada: $\widehat{Y}_{i\bullet}$
Residuos de ajuste	$\widehat{E}_{ij} = Y_{ij} - \widehat{Y}_{i\bullet}$	$\widehat{E}_{ij} = Y_{ij} - \widehat{Y}_{i\bullet}$
Suma cuad. residuos	$SSE = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \widehat{Y}_{i\bullet})^2$ $\text{g.l}(SSE) = n - 2$	$SSPE = \sum_{i=1}^k \sum_{j=1}^{n_i} (Y_{ij} - \widehat{Y}_{i\bullet})^2$ Conocido como suma de cuadrados de error puro $\text{g.l}(SSPE) = n - k$

Tenemos la siguiente descomposición bajo supuestos $E_{ij} \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \forall i = 1, \dots, k, j = 1, \dots, n_i$:

$$\begin{aligned}
 SSE &= \underbrace{SSPE}_{\text{S.C error puro}} + \underbrace{SSLOF}_{\text{S.C carencia de ajuste}} \\
 \underbrace{\text{g.l}(SSE)}_{n-2} &= \underbrace{\text{g.l}(SSPE)}_{n-k} + \underbrace{\text{g.l}(SSLOF)}_{k-2}
 \end{aligned}$$

(3)

Despejando tenemos para la suma de cuadrados de carencia de ajuste:

$$SSLOF = \sum_{i=1}^k \sum_{j=1}^{n_i} (\bar{Y}_{i\bullet} - \hat{Y}_{i\bullet})^2 = \sum_{i=1}^k n_i (\bar{Y}_{i\bullet} - \hat{Y}_{i\bullet})^2, \text{ con g.l(SSLOF)} = k - 2. \quad (4)$$

Note que en SSLOF se comparan las estimaciones de la respuesta media de los modelos lineal general y MRLS, mediante las diferencias $\bar{Y}_{i\bullet} - \hat{Y}_{i\bullet}$.

Tabla 2: ANOVA para modelo de regresión y carencia de ajuste

Fuente	SC	gl	CM	ECM	F calculada	Valor P
Regresión	SSR	1	$MSR = \frac{SSR}{1}$	$\sigma^2 + \beta_1^2 S_{xx}$	$F_{0,reg}$	$P(f_{1,n-2} > F_{0,reg})$
LOF	SSLOF	$k - 2$	$MSLOF = \frac{SSLOF}{k-2}$	$\sigma^2 + \frac{\sum_{i=1}^k n_i Q_i^2}{k-2}$	$F_{0,LOF}$	$P(f_{k-2,n-k} > F_{0,LOF})$
Error Puro	SSPE	$n - k$	$MSPE = \frac{SSPE}{n-k}$	σ^2	Test LOF: con $F_{0,LOF}$ probar que $H_0 : \mu_i = \beta_0 + \beta_1 x_i$ vs. $H_1 : \mu_i \neq \beta_0 + \beta_1 x_i$	
Error	SSE	$n - 2$	$MSE = \frac{SSE}{n-2}$	σ^2		
Total	SST	$n - 1$	$MST = \frac{SST}{n-1}$			

SC: Suma de cuadrados, CM: cuadrado medio y ECM cuadrado medio esperado es decir $E[CM]$, gl: grados de libertad.

$F_{0,reg} = \frac{MSR}{MSE}$ para test de significancia del modelo de regresión lineal simple.

LOF: Carencia de ajuste, $Q_i = \mu_i - (\beta_0 + \beta_1 x_i)$, $F_{0,LOF} = \frac{MSLOF}{MSPE}$

bajo H_0 y validez supuestos sobre E_{ij} , Estadístico de prueba en test LOF cumple que $F_{0,LOF} \sim f_{k-2,n-k}$

Despejando tenemos para la suma de cuadrados de carencia de ajuste:

$$SSLOF = \sum_{i=1}^k \sum_{j=1}^{n_i} (\bar{Y}_{i\bullet} - \bar{Y}_{i\bullet})^2 = \sum_{i=1}^k n_i (\bar{Y}_{i\bullet} - \bar{Y}_{i\bullet})^2, \text{ con g.l(SSLOF)} = k - 2. \quad (4)$$

Note que en SSLOF se comparan las estimaciones de la respuesta media de los modelos lineal general y MRLS, mediante las diferencias $\bar{Y}_{i\bullet} - \hat{Y}_{i\bullet}$.

Tabla 2: ANOVA para modelo de regresión y carencia de ajuste

Fuente	SC	gl	CM	ECM	F calculada	Valor P
Regresión	SSR	1	$MSR = \frac{SSR}{1}$	$\sigma^2 + \beta_1^2 S_{xx}$	$F_{0,\text{reg}}$	$P(f_{1,n-2} > F_{0,\text{reg}})$
LOF	SSLOF	$k - 2$	$MSLOF = \frac{SSLOF}{k-2}$	$\sigma^2 + \frac{\sum_{i=1}^k n_i Q_i^2}{k-2}$	$F_{0,\text{LOF}}$	$P(f_{k-2,n-k} > F_{0,\text{LOF}})$
Error Puro	SSPE	$n - k$	$MSPE = \frac{SSPE}{n-k}$	σ^2	Test LOF: con $F_{0,\text{LOF}}$ probar que $H_0 : \mu_i = \beta_0 + \beta_1 x_i$ vs. $H_1 : \mu_i \neq \beta_0 + \beta_1 x_i$	
Error	SSE	$n - 2$	$MSE = \frac{SSE}{n-2}$	σ^2		
Total	SST	$n - 1$	$MST = \frac{SST}{n-1}$			

SC: Suma de cuadrados, CM: cuadrado medio y ECM cuadrado medio esperado es decir $E[CM]$, gl: grados de libertad.

$F_{0,\text{reg}} = \frac{MSR}{MSE}$ para test de significancia del modelo de regresión lineal simple.

LOF: Carencia de ajuste, $Q_i = \mu_i - (\beta_0 + \beta_1 x_i)$, $F_{0,\text{LOF}} = \frac{MSLOF}{MSPE}$

bajo H_0 y validez supuestos sobre E_{ij} , Estadístico de prueba en test LOF cumple que $F_{0,\text{LOF}} \sim f_{k-2,n-k}$

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Algunas consideraciones en test LOF

- *Cálculo del SSPE sólo usa aquellos niveles x_i de X en los cuales $n_i > 1$, entonces k es el número de niveles de X donde $n_i > 1$.*
- Test LOF aplica con cualquier función de regresión lineal, $g.l(SSLOF) = k - p$, con p el número de parámetros en la función de regresión propuesta y con $k > p$.
- *Como estimador de σ^2 cuando no hay carencia de ajuste, se usa el MSE de la regresión y no el MSPE como un estimador de la varianza, debido a que el primero tiene más grados de libertad.*
- Cualquier inferencia sobre los parámetros del modelo lineal sólo debe llevarse a cabo luego de haber probado que el modelo de regresión lineal es apropiado.

Nota 1.2

Ver Código R 3.1 Capítulo 3 de notas de clase, para implementación del test de carencia de ajuste con función `anova()` combinada con `aov()` y con función `summary()` combinada con función `rsm()` de la librería del mismo nombre.

Qué hacer si hay carencia de ajuste significativa?

- Desarrollar un modelo más apropiado (tal vez un modelo de regresión no lineal).
- *Transformar las variables X y/o Y para tener un MRLS en los datos transformados.*
- Regresión no paramétrica, para explorar y/o confirmar la forma de la función de regresión.

Qué hacer si hay carencia de ajuste significativa?

- Desarrollar un modelo más apropiado (tal vez un modelo de regresión no lineal).
- *Transformar las variables X y/o Y para tener un MRLS en los datos transformados.*
- Regresión no paramétrica, para explorar y/o confirmar la forma de la función de regresión.

Qué hacer si hay carencia de ajuste significativa?

- Desarrollar un modelo más apropiado (tal vez un modelo de regresión no lineal).
- *Transformar las variables X y/o Y para tener un MRLS en los datos transformados.*
- Regresión no paramétrica, para explorar y/o confirmar la forma de la función de regresión.

Tests de homocedasticidad

Considerando el modelo: $Y_i = \beta_0 + \beta_1 x_i + E_i$, con

$$E_i \stackrel{\text{ind.}}{\sim} N(0, \sigma_i^2), \quad i = 1, 2, \dots, n, \quad (5)$$

donde $\text{Var}[E_i] = \sigma_i^2$, probaremos que,

$$\begin{aligned} H_0 : \sigma_i^2 &= \sigma^2 \quad \forall i \\ H_1 : \sigma_i^2 &\neq \sigma^2 \quad \text{para algún } i. \end{aligned} \quad (6)$$

Tests:

- Levene modificado o test Brown-Forsythe
- Breusch-Pagan
- Breusch-Pagan estudentizado

Tests de homocedasticidad

Considerando el modelo: $Y_i = \beta_0 + \beta_1 x_i + E_i$, con

$$E_i \stackrel{\text{ind.}}{\sim} N(0, \sigma_i^2), \quad i = 1, 2, \dots, n, \quad (5)$$

donde $\text{Var}[E_i] = \sigma_i^2$, probaremos que,

$$\begin{aligned} H_0 : \sigma_i^2 &= \sigma^2 \quad \forall i \\ H_1 : \sigma_i^2 &\neq \sigma^2 \quad \text{para algún } i. \end{aligned} \quad (6)$$

Tests:

- Levene modificado o test Brown-Forsythe
- Breusch-Pagan
- Breusch-Pagan estudentizado

Levene modificado o test Brown-Forsythe (BF)

Divide en tres o cuatro grupos los residuos de acuerdo a niveles observados o valores de la variable x , cuando son muchos los niveles y toma grupos de los extremos:

Grupo 1: Niveles de X bajos
con n_1 casos

Grupo 2: Niveles de X altos
con n_2 casos

$x_{(1)}$ $x_{(k)}$ $x_{(l)}$ $x_{(n)}$

$x_{(k)}, x_{(l)}$ tales que: $x_{(k)} - x_{(1)} \approx x_{(n)} - x_{(1)}$

Si no son muchos los niveles o valores distintos en x , divide en sólo dos grupos,

Grupo 1: Niveles de X bajos
con n_1 casos


Grupo 2: Niveles de X altos
con n_2 casos

$x_{(1)}$ $x_{(k)}$ $x_{(n)}$


$x_{(k)}$ tal que: $x_{(k)} - x_{(1)} \approx x_{(n)} - x_{(k)}$

Levene modificado o test Brown-Forsythe (BF)

Divide en tres o cuatro grupos los residuos de acuerdo a niveles observados o valores de la variable x , cuando son muchos los niveles y toma grupos de los extremos:



Si no son muchos los niveles o valores distintos en x , divide en sólo dos grupos,



Levene modificado o test Brown-Forsythe (BF)

Divide en tres o cuatro grupos los residuos de acuerdo a niveles observados o valores de la variable x , cuando son muchos los niveles y toma grupos de los extremos:

Grupo 1: Niveles de X bajos
con n_1 casos

Grupo 2: Niveles de X altos
con n_2 casos

$x_{(1)}$ $x_{(k)}$ $x_{(l)}$ $x_{(n)}$

$x_{(k)}, x_{(l)}$ tales que: $x_{(k)} - x_{(1)} \approx x_{(n)} - x_{(1)}$

Si no son muchos los niveles o valores distintos en x , divide en sólo dos grupos,

Grupo 1: Niveles de X bajos
con n_1 casos

Grupo 2: Niveles de X altos
con n_2 casos

$x_{(1)}$ $x_{(k)}$ $x_{(n)}$

$x_{(k)}$ tal que: $x_{(k)} - x_{(1)} \approx x_{(n)} - x_{(k)}$

Consideraciones del test BF:

- **Test robusto a no normalidad**
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

Se reparten los datos de acuerdo a grupos $1, 2, \dots, k$ en k orden creciente en x_i (por ej. $k=4$).

Se calcula la media en cada grupo: $\bar{y}_1, \bar{y}_2, \dots, \bar{y}_k$ ($\bar{y}_1 = 1, \bar{y}_2 = 2, \dots, \bar{y}_k = k$).

Se calcula la media en cada grupo de acuerdo a los residuos: $\bar{e}_1, \bar{e}_2, \dots, \bar{e}_k$ ($\bar{e}_1 = 1, \bar{e}_2 = 2, \dots, \bar{e}_k = k$).

Se calcula la media en cada grupo de acuerdo a los residuos de acuerdo a los residuos: $\bar{e}_1, \bar{e}_2, \dots, \bar{e}_k$ ($\bar{e}_1 = 1, \bar{e}_2 = 2, \dots, \bar{e}_k = k$).

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

Se reparten los datos de acuerdo a grupos $1, 2, 3, \dots, k$ en función de los valores de x_i . Los grupos se ordenan de menor a mayor en función de la media de x_i .

Se calcula la media de cada grupo: $\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k$ y se calcula la media global: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.

Se calcula la media de cada grupo de acuerdo a los residuos de los grupos $1, 2, 3, \dots, k$. Se calcula la media global de los residuos: $\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i$.

Se calcula la media de cada grupo de residuos de los grupos $1, 2, 3, \dots, k$ y se calcula la media global de los residuos de los grupos: $\bar{e}_k = \frac{1}{n_k} \sum_{i=1}^{n_k} e_i$.

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

Se supone que los residuos están distribuidos de acuerdo a la hipótesis de normalidad y se dividen en dos grupos, los L primeros y los R últimos, donde $L + R = n$.

Se calcula la media muestral de los residuos en cada uno de los grupos:

Se calcula la media muestral de los residuos en cada uno de los grupos y se calcula la diferencia entre las medias muestrales de los grupos L y R .

Se calcula la media muestral de los residuos en cada uno de los grupos y se calcula la diferencia entre las medias muestrales de los grupos L y R .

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- ***Funciona como un test t para comparación de dos medias poblacionales.***
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

Se supone que los residuos ϵ_i de la regresión $\hat{y}_i = \beta_0 + \beta_1 x_i + \epsilon_i$ se agrupan en k subgrupos de n_k cada uno, donde $k = 2, 3, 4, \dots$ y $n = n_1 + n_2 + \dots + n_k$.

Se supone que los ϵ_i son independientes y que $\epsilon_i \sim N(0, \sigma^2)$.

Se supone que los ϵ_i son independientes y que $\epsilon_i \sim N(0, \sigma^2)$.

Se supone que los ϵ_i son independientes y que $\epsilon_i \sim N(0, \sigma^2)$.

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

1. Separar residuos de acuerdo a grupos 1 y 2: e_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.

2. Test de homocedasticidad: $H_0: \sigma_1^2 = \sigma_2^2$ vs. $H_1: \sigma_1^2 \neq \sigma_2^2$

3. Construcción de estadístico de prueba: $F = \frac{\text{Var}(e_{1j})}{\text{Var}(e_{2j})}$

4. Comparación de F con $F_{\alpha/2, n_1-1, n_2-1}$ y $F_{1-\alpha/2, n_1-1, n_2-1}$

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

- Separar residuos de acuerdo a grupos 1 y 2: x_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.
- Calcular medianas en los grupos: $\tilde{x}_j = \text{mediana} \{x_{1j}, \dots, x_{n_j j}\}$, $j = 1, 2$.

- Calcular estadístico de prueba: $B_F = \frac{\tilde{x}_1 - \tilde{x}_2}{\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$
- El estadístico B_F se distribuye como una variable aleatoria estandarizada con $n_1 + n_2 - 2$ grados de libertad.

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

- 1 Separar residuos de acuerdo a grupos 1 y 2: e_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.
- 2 Calcular medianas en los grupos: $\tilde{e}_j = \text{mediana} \{e_{1j}, \dots, e_{n_j j}\}$, $j = 1, 2$
- 3 Calcular en cada grupo desv. absolutas respecto a las medianas: $d_{ij} = |e_{ij} - \tilde{e}_j|$, $j = 1, 2$, $i = 1, \dots, n_j$
- 4 Calcular en cada grupo la media de las desv. absolutas respecto a la mediana: $\bar{d}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} d_{ij}$, $j = 1, 2$

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

- 1 Separar residuos de acuerdo a grupos 1 y 2: e_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.
- 2 Calcular medianas en los grupos: $\tilde{e}_j = \text{mediana} \{e_{1j}, \dots, e_{n_j j}\}$, $j = 1, 2$
- 3 Calcular en cada grupo desv. absolutas respecto a las medianas: $d_{ij} = |e_{ij} - \tilde{e}_j|$, $j = 1, 2$, $i = 1, \dots, n_j$
- 4 Calcular en cada grupo la media de las desv. absolutas respecto a la mediana: $\bar{d}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} d_{ij}$, $j = 1, 2$

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

- 1 Separar residuos de acuerdo a grupos 1 y 2: e_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.
- 2 Calcular medianas en los grupos: $\tilde{e}_j = \text{mediana} \{e_{1j}, \dots, e_{n_j j}\}$, $j = 1, 2$
- 3 Calcular en cada grupo desv. absolutas respecto a las medianas: $d_{ij} = |e_{ij} - \tilde{e}_j|$, $j = 1, 2$, $i = 1, \dots, n_j$
- 4 Calcular en cada grupo la media de las desv. absolutas respecto a la mediana: $\bar{d}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} d_{ij}$, $j = 1, 2$

Consideraciones del test BF:

- *Test robusto a no normalidad*
- *Supone comportamiento monótono de σ_i^2 vs. x_i*
- *Requiere n grande para que sean despreciables correlaciones entre residuos*
- *Funciona como un test t para comparación de dos medias poblacionales.*
- *$n_1 + n_2 = n$ cuando se dividen residuos sólo en dos grupos; $n_1 + n_2 < n$ cuando se dividen residuos en 3 ó 4 grupos y se toman los grupos de los extremos de acuerdo a niveles de x .*

Construcción de la prueba:

- 1 Separar residuos de acuerdo a grupos 1 y 2: e_{ij} i -ésimo residuo en grupo j , $j = 1, 2$, $i = 1, \dots, n_j$.
- 2 Calcular medianas en los grupos: $\tilde{e}_j = \text{mediana} \{e_{1j}, \dots, e_{n_j j}\}$, $j = 1, 2$
- 3 Calcular en cada grupo desv. absolutas respecto a las medianas: $d_{ij} = |e_{ij} - \tilde{e}_j|$, $j = 1, 2$, $i = 1, \dots, n_j$
- 4 Calcular en cada grupo la media de las desv. absolutas respecto a la mediana: $\bar{d}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} d_{ij}$, $j = 1, 2$

Tabla 3: Test BF: Prueba indirectamente (6), realizando el siguiente test:

Test	Estadístico de prueba	Criterio de rechazo
$H_0 : \mu_{d_1} = \mu_{d_2}$ $H_1 : \mu_{d_1} \neq \mu_{d_2}$	$t_L^* = \frac{\bar{d}_1 - \bar{d}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \stackrel{a}{\sim} t_{n_1+n_2-2}, \text{ con,}$ $S_p^2 = \frac{\sum_{i=1}^{n_1} (d_{i1} - \bar{d}_1)^2 + \sum_{i=1}^{n_2} (d_{i2} - \bar{d}_2)^2}{n-2}$	si $P\left(\left t_{n_1+n_2-2}\right > \left t_L^*\right \right)$ es pequeño, o a un nivel α si : $\left t_L^*\right > t_{\alpha/2, n_1+n_2-2}$
donde: $\mu_{d_1} = E[d_{i1}], \quad \mu_{d_2} = E[d_{i2}]$		

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:

$$\sigma_i^2 = \sigma^2 \exp(\alpha x_i)$$

$$\sigma_i^2 = \sigma^2(1 + \alpha x_i)$$

$$\sigma_i^2 = \sigma^2(1 + \alpha x_i^2)$$

Para que $\sigma_i^2 > 0$ se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

Se genera los E_i^2 y se obtiene

El Test de Breusch-Pagan de la varianza del parámetro α se obtiene de la siguiente manera:

Se genera E_i^2 y se obtiene la varianza de E_i^2 y se genera la varianza de E_i^2 y se genera la varianza de E_i^2 .

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- *n debe ser grande*
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:

$$h(x_i) = \sigma^2 \exp(\alpha_0 + \alpha_1 x_i)$$

$$h(x_i) = \sigma^2 (1 + \alpha_0 + \alpha_1 x_i)$$

$$h(x_i) = \sigma^2 (1 + \alpha_0 x_i^2)$$

Nota que σ_i^2 puede ser también que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

$$E[E_i^2] = E[E_i^2 | x_i]$$

El test de Breusch-Pagan del parámetro α_0 es el estadístico de la prueba de Breusch-Pagan

que tiene como $E[E_i^2]$ como función de la x_i y σ^2 como parámetro. La forma de la

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- *Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.*
- *algunos modelos para la varianza son:*

- $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$

- $\sigma_i^2 = \sigma^2 \exp(\gamma x_i^2)$

- $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$

Nota que γ puede ser también que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

se puede ver que

El test de Breusch-Pagan es el estadístico de la prueba de la hipótesis de homocedasticidad.

El test de Breusch-Pagan es el estadístico de la prueba de la hipótesis de homocedasticidad.

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- *algunos modelos para la varianza son:*
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

se define los U_i como:

El test de la heterocedasticidad del parámetro γ es el estadístico de la prueba asintótica

que tiene como límite la forma de la estadística de la prueba de Breusch-Pagan.

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

- Se ajustan los E_i^2 vs. x_i .

El test de Breusch-Pagan se basa en la hipótesis de que la varianza de los errores es constante. Si la varianza no es constante, el test de Breusch-Pagan será significativo. El test de Breusch-Pagan se basa en la hipótesis de que la varianza de los errores es constante. Si la varianza no es constante, el test de Breusch-Pagan será significativo.

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

1. Se ajustan los \hat{E}_i^2 vs. x_i .

2. Se prueba la significancia del parámetro γ . El estadístico de la prueba se construye con base en SSR: la suma de cuadrados de la regresión hecha en el paso 1, y el SSE de la regresión de y_i vs. x_i de la cual se obtuvieron inicialmente los residuos \hat{E}_i .

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

- Se ajustan los \widehat{E}_i^2 vs. x_i .
- Se prueba la significancia del parámetro γ . El estadístico de la prueba se construye con base en SSR^* : la suma de cuadrados de la regresión hecha en el paso 1, y el SSE de la regresión de y_i vs. x_i de la cual se obtuvieron inicialmente los residuos \widehat{E}_i .

Test Breusch-Pagan (BP)

Consideraciones del test BP:

- Requiere validez de incorrelación y normalidad en los errores
- n debe ser grande
- Supone que $\sigma_i^2 = \sigma^2 h(x_i)$ con $h(\cdot)$ t.q $\sigma_i^2 > 0$.
- algunos modelos para la varianza son:
 - $\sigma_i^2 = \sigma^2 \exp(\gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)$
 - $\sigma_i^2 = \sigma^2 (1 + \gamma x_i)^2$

Note que si $\gamma = 0$, se tendría que $\sigma_i^2 = \sigma^2$.

Construcción de la prueba: Teniendo en cuenta que $\sigma_i^2 = E[E_i^2]$,

- 1 Se ajustan los \widehat{E}_i^2 vs. x_i .
- 2 Se prueba la significancia del parámetro γ . El estadístico de la prueba se construye con base en SSR*: la suma de cuadrados de la regresión hecha en el paso 1, y el SSE de la regresión de y_i vs. x_i de la cual se obtuvieron inicialmente los residuos \widehat{E}_i .

Tabla 4: Test BP en el MRLS: Prueba indirectamente (6), realizando el siguiente test:

Test	Estadístico de prueba	Criterio de rechazo
$H_0 : \gamma = 0$ $H_1 : \gamma \neq 0$	$\chi_{BP}^2 = \frac{1}{2} \frac{SSR^*}{(SSE/n)^2} \underset{\sim}{\text{aprox}} \chi_1^2$	si $P(\chi_1^2 > \chi_{BP}^2)$ es pequeño, o a un nivel α si : $\chi_{BP}^2 > \chi_{\alpha,1}^2$
	Test BP estudentizado: $\chi_{BP}^{*2} = nR^{*2} \underset{\sim}{\text{aprox}} \chi_1^2$	si $P(\chi_1^2 > \chi_{BP}^{*2})$ es pequeño, o a un nivel α si : $\chi_{BP}^{*2} > \chi_{\alpha,1}^2$
R^{*2} : Coeficiente de determinación muestral de la regresión lineal de \widehat{E}_i^2 vs. x_i SSR^* : Suma de cuadrados de la regresión hecha en el paso 1		

Nota 1.3

Ver Código R 3.2 en el Capítulo 3 de notas de clase, para la implementación del Test Breusch-Pagan mediante función `ncvTest()` de la librería `car` y con la función `bptest()` de la librería `lmtest`.

Tabla 4: Test BP en el MRLS: Prueba indirectamente (6), realizando el siguiente test:

Test	Estadístico de prueba	Criterio de rechazo
$H_0 : \gamma = 0$ $H_1 : \gamma \neq 0$	$\chi_{BP}^2 = \frac{1}{2} \frac{SSR^*}{(SSE/n)^2} \underset{\sim}{\text{aprox}} \chi_1^2$	si $P(\chi_1^2 > \chi_{BP}^2)$ es pequeño, o a un nivel α si : $\chi_{BP}^2 > \chi_{\alpha,1}^2$
	Test BP estudentizado: $\chi_{BP}^{*2} = nR^{*2} \underset{\sim}{\text{aprox}} \chi_1^2$	si $P(\chi_1^2 > \chi_{BP}^{*2})$ es pequeño, o a un nivel α si : $\chi_{BP}^{*2} > \chi_{\alpha,1}^2$
R^{*2} : Coeficiente de determinación muestral de la regresión lineal de \widehat{E}_i^2 vs. x_i SSR^* : Suma de cuadrados de la regresión hecha en el paso 1		

Nota 1.3

Ver Código R 3.2 en el Capítulo 3 de notas de clase, para la implementación del Test Breusch-Pagan mediante función `ncvTest()` de la librería `car` y con la función `bptest()` de la librería `lmtest`.

Qué hacer si hay heterocedasticidad?

- Ajustar por mínimos cuadrados ponderados: Se buscan β_0, β_1 que minimicen a

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \omega_i E_i^2 = \sum_{i=1}^n \omega_i (Y_i - \beta_0 - \beta_1 x_i)^2. \quad (7)$$

con w_i inversamente proporcional a $\text{Var}[Y_i]$.

- *Usar transformaciones sobre Y que estabilicen la varianza: Con respuesta continua existen las transformaciones de potencia o Box-Cox.*
- Modelos heterocedásticos (pero ya no son modelos lineales).

Qué hacer si hay heterocedasticidad?

- Ajustar por mínimos cuadrados ponderados: Se buscan β_0, β_1 que minimicen a

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \omega_i E_i^2 = \sum_{i=1}^n \omega_i (Y_i - \beta_0 - \beta_1 x_i)^2. \quad (7)$$

con w_i inversamente proporcional a $\text{Var}[Y_i]$.

- *Usar transformaciones sobre Y que estabilicen la varianza: Con respuesta continua existen las transformaciones de potencia o Box-Cox.*
- Modelos heterocedásticos (pero ya no son modelos lineales).

Qué hacer si hay heterocedasticidad?

- Ajustar por mínimos cuadrados ponderados: Se buscan β_0, β_1 que minimicen a

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \omega_i E_i^2 = \sum_{i=1}^n \omega_i (Y_i - \beta_0 - \beta_1 x_i)^2. \quad (7)$$

con w_i inversamente proporcional a $\text{Var}[Y_i]$.

- *Usar transformaciones sobre Y que estabilicen la varianza: Con respuesta continua existen las transformaciones de potencia o Box-Cox.*
- Modelos heterocedásticos (pero ya no son modelos lineales).

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- La correlación sólo es una medida de dependencia lineal entre dos variables;
- Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;
- Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.
- Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4

Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*

Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*

Evaluación de la independencia

Nota 1.4


Recuerde que

- *La correlación sólo es una medida de dependencia lineal entre dos variables;*
- *Por lo anterior, aunque dos variables aleatorias sean incorrelacionadas, podrían no ser independientes;*
- *Sin embargo, si dos variables aleatorias son independientes, entonces son incorrelacionadas.*
- *Se procederá a evaluar si hay evidencia de correlación entre los errores del MRLS, y de hallar tal evidencia, entonces se rechazaría la independencia, en caso contrario, se dice que no se ha hallado evidencia en contra de la independencia.*


Tests: Requieren conocer orden de observación de los datos y n grande,

- Tests de la función de autocorrelación (ACF)
- Tests Ljung-Box, Box-Pierce
- Tests de la función de autocorrelación parcial (PACF)
- *Test Durbin-Watson para autocorrelación de orden 1*


Algunos ejemplos de patrones en residuos vs. orden de observación



(a)



(b)



(c)

Figura 7: (a) Sin patrón claro; (b) con patrón cíclico; (c) con patrón de rachas de cambio sistemático en signos \pm .

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- *Aplica sólo en modelos de regresión lineal*
- *Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):*

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- *Bajo este modelo se cumple que la autocorrelación de orden 1, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.*

Construcción de la prueba:

Se define como el estadístico de Durbin-Watson:

Donde \hat{e}_t es el residuo de la regresión de Y sobre X , \hat{e}_{t-1} es el residuo de la regresión de Y sobre X en el periodo anterior.

$$DW = \frac{\sum_{t=2}^n (\hat{e}_t - \hat{e}_{t-1})^2}{\sum_{t=1}^n \hat{e}_t^2}$$

Donde n es el número de observaciones de la serie de tiempo.

El estadístico DW se distribuye entre 0 y 4, donde 0 indica autocorrelación positiva y 4 indica autocorrelación negativa.

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- *Aplica sólo en modelos de regresión lineal*
- *Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como $AR(1)$):*

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- *Bajo este modelo se cumple que la autocorrelación de orden 1, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.*

Construcción de la prueba:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

El test de Durbin-Watson para la autocorrelación de orden 1 se define como:

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- Aplica sólo en modelos de regresión lineal
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como $AR(1)$):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- Bajo este modelo se cumple que la **autocorrelación de orden 1**, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.

Construcción de la prueba:

1. Se ajusta el modelo de regresión ordinario,

2. Se calcula el estadístico de autocorrelación de orden 1:

3. Se calcula el estadístico de Durbin-Watson:

4. Se compara el estadístico de Durbin-Watson con los valores críticos:

5. Se concluye sobre la presencia de autocorrelación de orden 1.

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- Aplica sólo en modelos de regresión lineal
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- Bajo este modelo se cumple que la **autocorrelación de orden 1**, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.

Construcción de la prueba:

⊛ Se ajusta el modelo de regresión ordinario,

⊛ Con residuos de ajuste \bar{E}_t , en orden de t , se calcula estadístico de prueba d_1 :

$$d_1 = \frac{\sum_{t=2}^n (\bar{E}_t - \bar{E}_{t-1})^2}{\sum_{t=1}^n \bar{E}_t^2} = 2(1 - \hat{\rho}(1)), \quad \text{donde } \hat{\rho}(1) = \frac{\sum_{t=2}^n \bar{E}_t \bar{E}_{t-1}}{\sum_{t=1}^n \bar{E}_t^2}. \quad (9)$$

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- Aplica sólo en modelos de regresión lineal
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- Bajo este modelo se cumple que la **autocorrelación de orden 1**, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.

Construcción de la prueba:

- 1 Se ajusta el modelo de regresión ordinario,
- 2 Con residuos de ajuste \widehat{E}_t en orden de t , se calcula estadístico de prueba d_1 :

$$d_1 = \frac{\sum_{t=2}^n (\widehat{E}_t - \widehat{E}_{t-1})^2}{\sum_{t=1}^n \widehat{E}_t^2} \approx 2(1 - \widehat{\rho}(1)), \quad \text{donde} \quad \widehat{\rho}(1) = \frac{\sum_{t=2}^n \widehat{E}_t \widehat{E}_{t-1}}{\sum_{t=1}^n \widehat{E}_t^2}, \quad (9)$$

- 3 El juego de hipótesis a considerar se escoge de acuerdo a valores de d_1 : Si $0 < d_1 < 2$, se prueba autocorrelación positiva de orden 1; si $2 < d_1 < 4$, se prueba autocorrelación negativa de orden 1.

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- Aplica sólo en modelos de regresión lineal
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- Bajo este modelo se cumple que la **autocorrelación de orden 1**, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.

Construcción de la prueba:

- 1 Se ajusta el modelo de regresión ordinario,
- 2 Con residuos de ajuste \widehat{E}_t en orden de t , se calcula estadístico de prueba d_1 :

$$d_1 = \frac{\sum_{t=2}^n (\widehat{E}_t - \widehat{E}_{t-1})^2}{\sum_{t=1}^n \widehat{E}_t^2} \approx 2(1 - \widehat{\rho}(1)), \quad \text{donde} \quad \widehat{\rho}(1) = \frac{\sum_{t=2}^n \widehat{E}_t \widehat{E}_{t-1}}{\sum_{t=1}^n \widehat{E}_t^2}, \quad (9)$$

- 3 El juego de hipótesis a considerar se escoge de acuerdo a valores de d_1 : Si $0 < d_1 < 2$, se prueba autocorrelación positiva de orden 1; si $2 < d_1 < 4$, se prueba autocorrelación negativa de orden 1.

Test Durbin-Watson (DW) para autocorrelación de orden 1

Consideraciones del test DW:

- Aplica sólo en modelos de regresión lineal
- Para los errores del modelo en el orden del tiempo, E_t , considera modelo autorregresivo de orden 1 (conocido en series de tiempo como AR(1)):

$$E_t = \phi_1 E_{t-1} + a_t, \text{ con } a_t \stackrel{iid}{\sim} N(0, \sigma_a^2) \text{ y } |\phi_1| < 1. \quad (8)$$

- Bajo este modelo se cumple que la **autocorrelación de orden 1**, es: $\rho(1) = \text{Corr}(E_t, E_{t-1}) = \phi_1$.

Construcción de la prueba:

- 1 Se ajusta el modelo de regresión ordinario,
- 2 Con residuos de ajuste \widehat{E}_t en orden de t , se calcula estadístico de prueba d_1 :

$$d_1 = \frac{\sum_{t=2}^n (\widehat{E}_t - \widehat{E}_{t-1})^2}{\sum_{t=1}^n \widehat{E}_t^2} \approx 2(1 - \widehat{\rho}(1)), \quad \text{donde} \quad \widehat{\rho}(1) = \frac{\sum_{t=2}^n \widehat{E}_t \widehat{E}_{t-1}}{\sum_{t=1}^n \widehat{E}_t^2}, \quad (9)$$

- 3 El juego de hipótesis a considerar se escoge de acuerdo a valores de d_1 : Si $0 < d_1 < 2$, se prueba autocorrelación positiva de orden 1; si $2 < d_1 < 4$, se prueba autocorrelación negativa de orden 1.

Tabla 5: Tests de hipótesis Durbin Watson para autocorrelación de orden 1. De acuerdo a d_1 se debe elegir entre uno de los dos juegos de hipótesis que se describen en esta tabla.

Test de auto correlación de orden 1 positiva: Si $0 < d_1 < 2$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) > 0$, o equivalentemente $H_1 : \phi_1 > 0$	Si $P(DW_1 < d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están positivamente correlacionados.	

Test de auto correlación de orden 1 negativa: Si $2 < d_1 < 4$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) < 0$, o equivalentemente $H_1 : \phi_1 < 0$	Si $P(DW_1 > d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están negativamente correlacionados.	

Nota 1.5

Ver Código R 3.3 en el Capítulo 3 de notas de clase, para la ejecución del test Durbin-Watson con la función `durbinWatsonTest()` de la librería `car`.

Tabla 5: Tests de hipótesis Durbin Watson para autocorrelación de orden 1. De acuerdo a d_1 se debe elegir entre uno de los dos juegos de hipótesis que se describen en esta tabla.

Test de auto correlación de orden 1 positiva: Si $0 < d_1 < 2$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) > 0$, o equivalentemente $H_1 : \phi_1 > 0$	Si $P(DW_1 < d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están positivamente correlacionados.	
Test de auto correlación de orden 1 negativa: Si $2 < d_1 < 4$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) < 0$, o equivalentemente $H_1 : \phi_1 < 0$	Si $P(DW_1 > d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están negativamente correlacionados.	

Nota 1.5

Ver Código R 3.3 en el Capítulo 3 de notas de clase, para la ejecución del test Durbin-Watson con la función `durbinWatsonTest()` de la librería `car`.

Tabla 5: Tests de hipótesis Durbin Watson para autocorrelación de orden 1. De acuerdo a d_1 se debe elegir entre uno de los dos juegos de hipótesis que se describen en esta tabla.

Test de auto correlación de orden 1 positiva: Si $0 < d_1 < 2$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) > 0$, o equivalentemente $H_1 : \phi_1 > 0$	Si $P(DW_1 < d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están positivamente correlacionados.	
Test de auto correlación de orden 1 negativa: Si $2 < d_1 < 4$	
Juego de hipótesis	Criterio de rechazo
$H_0 : \rho(1) = 0$, o equivalentemente $H_0 : \phi_1 = 0$ vs. $H_1 : \rho(1) < 0$, o equivalentemente $H_1 : \phi_1 < 0$	Si $P(DW_1 > d_1)$ es pequeño
Conclusiones posibles: Si no se rechaza H_0 , se concluye que no se ha encontrado evidencia de auto correlación de orden 1; si se rechaza H_0 se concluye que los errores consecutivos (o sea que distan una unidad de tiempo) están negativamente correlacionados.	

Nota 1.5

Ver Código R 3.3 en el Capítulo 3 de notas de clase, para la ejecución del test Durbin-Watson con la función `durbinWatsonTest()` de la librería `car`.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*

• Se define la primera diferencia de y_t como $\Delta y_t = y_t - y_{t-1}$ y la primera diferencia de x_t como $\Delta x_t = x_t - x_{t-1}$. El nuevo modelo tiene la forma:

• Construye el modelo para $\Delta y_t = \beta_0 + \beta_1 \Delta x_t + \epsilon_t$, donde

$$\begin{aligned} \Delta y_t &= y_t - y_{t-1} \\ \Delta x_t &= x_t - x_{t-1} \end{aligned}$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). Applied Linear Statistical Models, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*

➊ Calcular las primeras diferencias: $Y_1^* = Y_1 - Y_{1-1}$, $X_1^* = X_1 - X_{1-1}$

➋ Calcular las primeras diferencias para $t = 2, \dots, T$

➌ Calcular la regresión de Y_t^* sobre X_t^* para $t = 1, \dots, T$

➍ Interpretar los resultados de la regresión

➎ Verificar los supuestos de la regresión

➏ Interpretar los resultados de la regresión

➐ Interpretar los resultados de la regresión

➑ Interpretar los resultados de la regresión

➒ Interpretar los resultados de la regresión

➓ Interpretar los resultados de la regresión

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - ➊ Calcular las primeras diferencias: $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - ➋ Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- ➌ Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). Applied Linear Statistical Models, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - **Calcular las primeras diferencias:** $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1^* \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). Applied Linear Statistical Models, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - 1. Calcular las primeras diferencias: $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - 2. Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- 3. Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1^* \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - ➊ Calcular las primeras diferencias: $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - ➋ Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- ➌ Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1^* \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - ➊ Calcular las primeras diferencias: $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - ➋ Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- ➌ Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1^* \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill Irwing, New York.

Qué hacer si no se cumple independencia?

- *Modelar la dependencia entre los errores: Modelos de regresión con errores correlacionados.*
- Incluir funciones del índice de tiempo t para modelar tendencias, patrones periódicos o estacionales.
- *Trabajar con primeras diferencias:*
 - ➊ Calcular las primeras diferencias: $Y_t^* = Y_t - Y_{t-1}$, $X_t^* = X_t - X_{t-1}$
 - ➋ Ajustar Y_t^* vs. X_t^* bajo el modelo (sin intercepto)

$$Y_t^* = \beta_1^* X_t^* + u_t, \quad u_t \stackrel{\text{iid}}{\sim} N(0, \sigma_u^2) \quad (10)$$

- ➌ Construir ec. ajustada para Y_t , $\widehat{Y}_t = \widehat{\beta}_0 + \widehat{\beta}_1 X_t$, tomando

$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1^* \bar{X} \quad (11)$$

$$\widehat{\beta}_1 = \widehat{\beta}_1^* \quad (12)$$

Nota 1.6

Detalles en Capítulo 12 de: Kutner, M. H., Nachtsheim, C. J., Neter, J. and Li. W. (2005). *Applied Linear Statistical Models*, 5th ed. McGraw-Hill Irwing, New York.

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- Son mutuamente independientes
- Son aleatoriamente distribuidos

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2). \quad (13)$$

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- Son mutuamente independientes
- Son idénticamente distribuidas

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- Son mutuamente independientes
- Son idénticamente distribuidas

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- 1 Son mutuamente independientes
- 2 Son idénticamente distribuidas

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- 1 Son mutuamente independientes
- 2 Son idénticamente distribuidas

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.*

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- 1 Son mutuamente independientes*
- 2 Son idénticamente distribuidas*

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.*
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:*

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.*

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- 1 Son mutuamente independientes*
- 2 Son idénticamente distribuidas*

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.*
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:*

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Evaluación de normalidad

Consideraciones

- Como cualquier test de bondad de ajuste, los tests de normalidad exigen que el conjunto de valores sobre los que se aplican provengan de una muestra aleatoria.*

Definición 1.1

Un conjunto de variables aleatorias, W_1, W_2, \dots, W_n , constituyen una muestra aleatoria de tamaño n si y solo si

- 1 Son mutuamente independientes*
- 2 Son idénticamente distribuidas*

- La correlación entre variables en una muestra puede afectar significativamente el desempeño de los tests de bondad de ajuste.
- El supuesto de independencia debería verificarse antes de la evaluación de normalidad.*
- La no normalidad frecuentemente va de la mano con la no homogeneidad de la varianza.
- Aunque se aplican estos tests usando los valores de los residuos de ajuste, no debe perder de vista que el supuesto y las conclusiones deben formularse para los errores del modelo:*

$$H_0 : E_i \sim N(0, \sigma^2)$$

$$H_1 : E_i \not\sim N(0, \sigma^2).$$

(13)

Tabla 6: Pruebas para normalidad

Pruebas especiales para normalidad			
Test	Característica	Estadístico	Valor P
Jarque-Bera:	Basada en asimetría y kurtosis	$JB = \frac{n}{6} \left[S^2 + \frac{(k-3)^2}{4} \right] \sim \chi^2_2$ <p>S es el coef. de asimetría muestral, k es la kurtosis</p>	$P(\chi^2_2 > JB)$
Shapiro-Wilk:	Compara estimador varianza basado en estadísticos de orden muestrales vs. estimador basado en Suma de cuadrados corregidos.	$W_0 = \frac{\left(\sum_{i=1}^n a_i x(i) \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \text{ con } 0 < W_0 < 1$ <p>y los a_i funciones de las medias, varianzas y covarianzas de los estadísticos de orden de v.a $N(0, 1)$.</p>	$P(W \leq W_0)$
Pruebas generales			
Test	Característica	Estadístico	Valor P
Kolmogorov-Smirnov:	Para cualquier distribución continua	$D_0 = \max_{1 \leq i \leq n} F_n(x_i) - F_0(x_i) $	$P(D \geq D_0)$
Anderson-Darling:	Mejora sensibilidad de K-S en las colas de la distribución, pero sólo está disponible para las distribuciones normal, lognormal, weibull, exponencial, de valor extremo y logística.	$A_n^2 = n \int_{-\infty}^{\infty} \frac{(F_n(x) - F_0(x))^2}{F_0(x)(1 - F_0(x))} dF_0(x)$	$P(A^2 \geq A_0^2)$
Cramer-Von Mises:	Similar a K-S, pero más complejo computacionalmente.	$W_0^2 = n \int_{-\infty}^{\infty} [F_n(x) - F_0(x)]^2 dF_0(x)$	$P(W^2 \geq W_0^2)$

Nota 1.7 (Otros tests)

- *Test Lilliefors (Kolmogorov-Smirnov para normalidad):*

$$D = \max\{D^+, D^-\}$$

con


$$D^+ = \max_{i=1, \dots, n} \left\{ \frac{i}{n} - p_{(i)} \right\}, \quad D^- = \max_{i=1, \dots, n} \left\{ p_{(i)} - \frac{(i-1)}{n} \right\}$$

$$p_{(i)} = \Phi\left(\frac{x_{(i)} - \bar{x}}{s}\right)$$


\bar{x} y s son la media y desviación estándar de los valores ingresados a la prueba y $x_{(i)}$ el i ésimo valor de menor a mayor. Disponible en librería nortest bajo la función:

`lillie.test()`.

- También en esta librería se hayan implementadas las pruebas Anderson-Darling y Shapiro-Francia, para normalidad, en las funciones `ad.test()` y `sf.test`, respectivamente.




(a)



(b)



(c)



(d)

Figura 8: Densidades poblacionales y gráficos de probabilidad normal con muestras provenientes de: (a) (b) una distribución normal de media cero; (c) y (d) con una distribución no normal y asimétrica a derecha

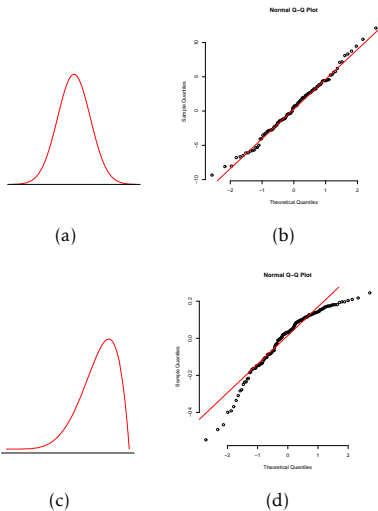





Figura 9: Densidades poblacionales y gráficos de probabilidad normal con muestras provenientes de: (a) (b) una distribución normal de media cero; (c) y (d) con una distribución no normal asimétrica a izquierda




(a)



(b)



(c)



(d)

Figura 10: Densidades poblacionales y gráficos de probabilidad normal con muestras provenientes de: (a) (b) una distribución normal de media cero; (c) y (d) con una distribución no normal, simétrica pero de colas pesadas.

Algunas soluciones a no normalidad

La no normalidad puede estar vinculada a no homogeneidad de varianza. En algunos casos las transformaciones sobre Y que estabilizan varianza también logran una variables respuesta normal en escala transformada.

- *Transformaciones sobre la variable respuesta: las transformaciones de potencia Box-Cox: Y^λ (ver Sección 3.5, Capítulo 3 Notas de Clase).*
- *Regresión no paramétrica: Por ejemplo la regresión local polinomial o LOESS.*
- *Modelos lineales (o no lineales) generalizados: Donde considera para $Y|x$ distribuciones diferentes a la normal.*

Algunas soluciones a no normalidad

La no normalidad puede estar vinculada a no homogeneidad de varianza. En algunos casos las transformaciones sobre Y que estabilizan varianza también logran una variables respuesta normal en escala transformada.

- *Transformaciones sobre la variable respuesta: las transformaciones de potencia Box-Cox: Y^λ (ver Sección 3.5, Capítulo 3 Notas de Clase).*
- *Regresión no paramétrica: Por ejemplo la regresión local polinomial o LOESS.*
- *Modelos lineales (o no lineales) generalizados: Donde considera para $Y|x$ distribuciones diferentes a la normal.*

Algunas soluciones a no normalidad

La no normalidad puede estar vinculada a no homogeneidad de varianza. En algunos casos las transformaciones sobre Y que estabilizan varianza también logran una variables respuesta normal en escala transformada.

- *Transformaciones sobre la variable respuesta: las transformaciones de potencia Box-Cox: Y^λ (ver Sección 3.5, Capítulo 3 Notas de Clase).*
- *Regresión no paramétrica: Por ejemplo la regresión local polinomial o LOESS.*
- *Modelos lineales (o no lineales) generalizados: Donde considera para $Y|x$ distribuciones diferentes a la normal.*

Outliers u observaciones atípicas en la respuesta

Definición 1.2

Un outlier es aquella observación en donde la respuesta toma un valor bastante alejado o atípico con respecto al resto de valores.

Procedimientos gráficos para identificación

- Residuos ordinarios \hat{e}_i
- Residuos estandarizados e_i

$$e_i = \frac{\hat{e}_i}{\sqrt{MSE}} \quad (14)$$

Outliers u observaciones atípicas en la respuesta

Definición 1.2

Un outlier es aquella observación en donde la respuesta toma un valor bastante alejado o atípico con respecto al resto de valores.

Procedimientos gráficos para identificación

- Residuos ordinarios \widehat{E}_i
- Residuos estandarizados e_i

$$e_i = \frac{\widehat{E}_i}{\sqrt{\text{MSE}}} \quad (14)$$

- Residuos estudentizados (internamente estudentizados) r_i , en R con función `rsstandard()`.

$$r_i = \frac{\widehat{E}_i}{\sqrt{\text{Var}(\widehat{E}_i)}} = \frac{\widehat{E}_i}{\sqrt{(1 - h_{ii})\text{MSE}}}, \text{ con } h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}. \quad (15)$$

- Residuos externamente estudentizados t_i , en R con función `rsstudent()`.

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2} \sim t_{n-p-1}, \quad (16)$$

Outliers u observaciones atípicas en la respuesta

Definición 1.2

Un outlier es aquella observación en donde la respuesta toma un valor bastante alejado o atípico con respecto al resto de valores.

Procedimientos gráficos para identificación

- Residuos ordinarios \widehat{E}_i
- Residuos estandarizados e_i

$$e_i = \frac{\widehat{E}_i}{\sqrt{\text{MSE}}} \quad (14)$$

- Residuos estudentizados (internamente estudentizados) r_i , en R con función `rsstandard()`.

$$r_i = \frac{\widehat{E}_i}{\sqrt{\text{Var}(\widehat{E}_i)}} = \frac{\widehat{E}_i}{\sqrt{(1 - h_{ii})\text{MSE}}}, \text{ con } h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}. \quad (15)$$

- Residuos externamente estudentizados t_i , en R con función `rsstudent()`.

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2} \sim t_{n-p-1}, \quad (16)$$

Outliers u observaciones atípicas en la respuesta

Definición 1.2

Un outlier es aquella observación en donde la respuesta toma un valor bastante alejado o atípico con respecto al resto de valores.

Procedimientos gráficos para identificación

- Residuos ordinarios \widehat{E}_i
- Residuos estandarizados e_i

$$e_i = \frac{\widehat{E}_i}{\sqrt{\text{MSE}}} \quad (14)$$

- Residuos estudentizados (internamente estudentizados) r_i , en R con función `rsstandard()`.

$$r_i = \frac{\widehat{E}_i}{\sqrt{\text{Var}(\widehat{E}_i)}} = \frac{\widehat{E}_i}{\sqrt{(1 - h_{ii})\text{MSE}}}, \text{ con } h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}. \quad (15)$$

- Residuos externamente estudentizados t_i , en R con función `rstudent()`.

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2} \sim t_{n-p-1}, \quad (16)$$

Outliers u observaciones atípicas en la respuesta

Definición 1.2

Un outlier es aquella observación en donde la respuesta toma un valor bastante alejado o atípico con respecto al resto de valores.

Procedimientos gráficos para identificación

- Residuos ordinarios \widehat{E}_i
- Residuos estandarizados e_i

$$e_i = \frac{\widehat{E}_i}{\sqrt{\text{MSE}}} \quad (14)$$


- Residuos estudentizados (internamente estudentizados) r_i , en R con función `rstandard()`.

$$r_i = \frac{\widehat{E}_i}{\sqrt{\widehat{\text{Var}}(\widehat{E}_i)}} = \frac{\widehat{E}_i}{\sqrt{(1 - h_{ii})\text{MSE}}}, \text{ con } h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}. \quad (15)$$


- Residuos externamente estudentizados t_i , en R con función `rstudent()`.

$$t_i = r_i \left[\frac{n - p - 1}{n - p - r_i^2} \right]^{1/2} \sim t_{n-p-1}, \quad (16)$$


p número de parámetros en el modelo de regresión, siendo 2 para la RLS.




(a)



(b)




(c)




(d)


Figura 11: Observación outlier identificada como un valor atípico en la variable respuesta (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos de ajuste; (c) y (d) gráficos de residuos vs x y vs. \hat{y} , respectivamente.




(a)



(b)



(c)



(d)

Figura 12: Dos bservaciones outliers identificadas como valores atípicos en la variable respuesta (a) Gráfico de dispersión y recta ajustada (b) gráfico de probabilidad normal con residuos estudentizados externamente; (c) y (d) gráficos de residuos estudentizados externamente vs x y vs. \hat{y} , respectivamente.