

Contenido I

- 1 Definición de linealidad de un modelo de regresión
- 2 Modelos intrínsecamente lineales
- 3 Transformaciones Box-Cox sobre Y

Contenido

- 1 Definición de linealidad de un modelo de regresión
- 2 Modelos intrínsecamente lineales
- 3 Transformaciones Box-Cox sobre Y

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + \varepsilon, \quad \varepsilon \stackrel{iid}{\sim} N(0, \sigma^2).$$

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Definición de linealidad de un modelo de regresión

- El término “modelo de regresión lineal” no implica una relación de tendencia lineal entre Y y X , esta relación puede tener una curvatura;
- La linealidad del modelo es con relación a los parámetros de la función de regresión: ningún parámetro de la regresión aparece como el exponente o es dividido o multiplicado por otro parámetro.

Definición 1.1

Un modelo de regresión para un variable respuesta Y vs. un conjunto de predictores X_1, \dots, X_k , con función de regresión $f(X_1, \dots, X_k, \beta)$:

$$Y = f(X_1, \dots, X_k, \beta) + E, \quad E \stackrel{iid}{\sim} N(0, \sigma^2),$$

es lineal en el vector de parámetros $\beta = (\beta_0, \beta_1, \dots, \beta_k)^T$, si al evaluar el modelo en un conjunto de n observaciones, el sistema resultante de n ecuaciones con $(k+1)$ incógnitas, puede escribirse en forma matricial como

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{E},$$

donde $\mathbf{y} \in \mathbb{R}^n$ es el vector respuesta, $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$ es la matriz de diseño y $\mathbf{E} \in \mathbb{R}^n$ es el vector de errores.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4 \end{aligned} \tag{1}$$

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matriz de datos X de tamaño $n \times p$ en este caso $n=4$ y $p=2$ $X = \begin{bmatrix} x_1 & x_2 \\ x_3 & x_4 \end{bmatrix}$

$$\begin{aligned}Y &= \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} \beta_0 + \beta_1 \cdot x_1 + E_1 \\ \beta_0 + \beta_1 \cdot x_2 + E_2 \\ \beta_0 + \beta_1 \cdot x_3 + E_3 \\ \beta_0 + \beta_1 \cdot x_4 + E_4 \end{bmatrix} \\&= \begin{bmatrix} \beta_0 & \beta_1 \cdot x_1 \\ \beta_0 & \beta_1 \cdot x_2 \\ \beta_0 & \beta_1 \cdot x_3 \\ \beta_0 & \beta_1 \cdot x_4 \end{bmatrix} + \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix} \\&= X \cdot \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + E\end{aligned}$$

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4 \end{aligned} \tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 1: Suponga el MRLS con una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$. Al evaluar la ec. del modelo, $Y_i = \beta_0 + \beta_1 X_i + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$, en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con dos incógnitas (β_0 y β_1 son las incógnitas)

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 \cdot x_1 + E_1 \\y_2 &= \beta_0 + \beta_1 \cdot x_2 + E_2 \\y_3 &= \beta_0 + \beta_1 \cdot x_3 + E_3 \\y_4 &= \beta_0 + \beta_1 \cdot x_4 + E_4\end{aligned}\tag{1}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \end{bmatrix}_{4 \times 2} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}_{2 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo es lineal en el vector de parámetros $\boldsymbol{\beta}$.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \end{aligned} \quad (2)$$

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Ejemplo 2: Suponga de nuevo una muestra de $n = 4$ observaciones (x_i, y_i) , $i = 1, \dots, 4$ pero ahora el modelo es $Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + E_i$, $E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$. Al evaluar esta ec. en las observaciones, se obtiene el siguiente sistema de cuatro ecuaciones con tres incógnitas (β_0 , β_1 y β_2 son las incógnitas)

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_1^2 + E_1 \\ y_2 &= \beta_0 + \beta_1 \cdot x_2 + \beta_2 \cdot x_2^2 + E_2 \\ y_3 &= \beta_0 + \beta_1 \cdot x_3 + \beta_2 \cdot x_3^2 + E_3 \\ y_4 &= \beta_0 + \beta_1 \cdot x_4 + \beta_2 \cdot x_4^2 + E_4 \end{aligned} \tag{2}$$

matricialmente, tiene la representación $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{E}$, donde

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}_{4 \times 1} \quad \mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \end{bmatrix}_{4 \times 3} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}_{3 \times 1} \quad \mathbf{E} = \begin{bmatrix} E_1 \\ E_2 \\ E_3 \\ E_4 \end{bmatrix}_{4 \times 1}$$

por tanto, el modelo de regresión es lineal en el vector de parámetros $\boldsymbol{\beta}$, a pesar que la relación de tendencia entre Y y X es no lineal.

Contenido

1 Definición de linealidad de un modelo de regresión

2 Modelos intrínsecamente lineales

- Modelo exponencial multiplicativo
- Modelo de potencia multiplicativo
- Modelo logarítmico
- Modelo recíproco
- Algunas consideraciones

3 Transformaciones Box-Cox sobre Y

Modelos intrínsecamente lineales

Definición 2.1

Denominamos modelos intrínsecamente lineales a aquellos que relacionan Y con X por medio de una transformación en Y y/o en X , originando el modelo,

$$Y^* = \beta_0 + \beta_1 X^* + E^*, \quad (3)$$

donde

- las variables transformadas son: $Y^* = h(Y)$ y $X^* = g(X)$,
- las funciones $h(\cdot)$ y $g(\cdot)$ deben ser invertibles, es decir, $h^{-1}(\cdot)$ y $g^{-1}(\cdot)$ existen.

Modelos intrínsecamente lineales

Definición 2.1

Denominamos modelos intrínsecamente lineales a aquellos que relacionan Y con X por medio de una transformación en Y y/o en X , originando el modelo,

$$Y^* = \beta_0 + \beta_1 X^* + E^*, \quad (3)$$

donde

- las variables transformadas son: $Y^* = h(Y)$ y $X^* = g(X)$,
- las funciones $h(\cdot)$ y $g(\cdot)$, deben ser tales que conduzcan a la ecuación (3).
- los supuestos $\overset{\text{iid}}{\sim} N(0, \sigma^2)$ se atribuyen al término de error en el modelo con variables transformadas y por tanto, la evaluación de supuestos se realiza con residuos del ajuste de este modelo.

Modelos intrínsecamente lineales

Definición 2.1

Denominamos modelos intrínsecamente lineales a aquellos que relacionan Y con X por medio de una transformación en Y y/o en X , originando el modelo,

$$Y^* = \beta_0 + \beta_1 X^* + E^*, \quad (3)$$

donde

- las variables transformadas son: $Y^* = h(Y)$ y $X^* = g(X)$,
- las funciones $h(\cdot)$ y $g(\cdot)$, deben ser tales que conduzcan a la ecuación (3).
- los supuestos $\overset{\text{iid}}{\sim} N(0, \sigma^2)$ se atribuyen al término de error en el modelo con variables transformadas y por tanto, la evaluación de supuestos se realiza con residuos del ajuste de este modelo.

Modelos intrínsecamente lineales

Definición 2.1

Denominamos modelos intrínsecamente lineales a aquellos que relacionan Y con X por medio de una transformación en Y y/o en X , originando el modelo,

$$Y^* = \beta_0 + \beta_1 X^* + E^*, \quad (3)$$

donde

- las variables transformadas son: $Y^* = h(Y)$ y $X^* = g(X)$,
- las funciones $h(\cdot)$ y $g(\cdot)$, deben ser tales que conduzcan a la ecuación (3).
- los supuestos $\overset{\text{iid}}{\sim} N(0, \sigma^2)$ se atribuyen al término de error en el modelo con variables transformadas y por tanto, la evaluación de supuestos se realiza con residuos del ajuste de este modelo.

Modelos intrínsecamente lineales

Definición 2.1

Denominamos modelos intrínsecamente lineales a aquellos que relacionan Y con X por medio de una transformación en Y y/o en X , originando el modelo,

$$Y^* = \beta_0 + \beta_1 X^* + E^*, \quad (3)$$

donde

- las variables transformadas son: $Y^* = h(Y)$ y $X^* = g(X)$,
- las funciones $h(\cdot)$ y $g(\cdot)$, deben ser tales que conduzcan a la ecuación (3).
- los supuestos $\overset{\text{iid}}{\sim} N(0, \sigma^2)$ se atribuyen al término de error en el modelo con variables transformadas y por tanto, la evaluación de supuestos se realiza con residuos del ajuste de este modelo.

Modelo exponencial multiplicativo



Ecuación original

$$Y_i = \beta_0 \exp(\beta_1 X_i) \cdot E_i, \beta_0 > 0, \text{ con}$$
$$E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad E_i^* = \log(E_i)$
- $\beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 X_i + E_i), \text{ con}$$
$$E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i)$

Modelo exponencial multiplicativo



Ecuación original

$$Y_i = \beta_0 \exp(\beta_1 X_i) \cdot E_i, \beta_0 > 0, \text{ con} \\ E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad E_i^* = \log(E_i)$
- $\beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 X_i + E_i), \text{ con} \\ E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i)$

Modelo exponencial multiplicativo

Ecuación original



$$Y_i = \beta_0 \exp(\beta_1 X_i) \cdot E_i, \beta_0 > 0, \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad E_i^* = \log(E_i)$
- $\beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 X_i + E_i), \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i)$

Modelo de potencia multiplicativo

Ecuación original



$$Y_i = \beta_0 X_i^{\beta_1} \cdot E_i, \beta_0 > 0, X_i > 0, \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i^* + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i)$
- $E_i^* = \log(E_i), \quad \beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 \log(X_i) + E_i), \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i^* + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i).$

Modelo de potencia multiplicativo

Ecuación original



$$Y_i = \beta_0 X_i^{\beta_1} \cdot E_i, \beta_0 > 0, X_i > 0, \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i^* + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i)$
- $E_i^* = \log(E_i), \quad \beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 \log(X_i) + E_i), \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i^* + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i).$

Modelo de potencia multiplicativo

Ecuación original



$$Y_i = \beta_0 X_i^{\beta_1} \cdot E_i, \beta_0 > 0, X_i > 0, \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} \text{lognorm}(\mu = 0, \sigma)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0^* + \beta_1 X_i^* + E_i^*, \text{ con } E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i)$
- $E_i^* = \log(E_i), \quad \beta_0^* = \log(\beta_0)$



Otra parametrización:

Ecuación original

$$Y_i = \exp(\beta_0 + \beta_1 \log(X_i) + E_i), \text{ con}$$

$$E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y_i^* = \beta_0 + \beta_1 X_i^* + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $Y_i^* = \log(Y_i), \quad X_i^* = \log(X_i).$

Modelo logarítmico



Ecuación original

$$Y_i = \beta_0 + \beta_1 \log(X_i) + E_i, X_i > 0, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y = \beta_0 + \beta_1 X_i^* + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $X_i^* = \log(X_i)$



Modelo recíproco



Ecuación original

$$Y_i = \beta_0 + \beta_1 (1/X_i) + E_i, \quad X_i > 0, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Ec. con variables transformadas

$$Y = \beta_0 + \beta_1 X_i^* + E_i, \text{ con } E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2),$$

- $X_i^* = 1/X_i$



Algunas consideraciones

- En modelos multiplicativos de la forma

$$Y_i = \beta_0 \cdot h(X_i, \beta_1) \cdot E_i, \quad \text{con } \log(E_i) \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (4)$$

con $h(X_i, \beta_1) = e^{\beta_1 X_i}$ en modelo exponencial, $h(X_i, \beta_1) = X_i^{\beta_1}$ en modelo de potencia,

$$\widehat{\beta}_0 \approx \exp(\widehat{\beta}_0^*) \quad (5)$$

con $\widehat{\beta}_0^*$ obtenido en el ajuste por MCO del modelo con variables transformadas.

- En los modelos multiplicativos (cualquiera de las parametrizaciones presentadas),

$$\widehat{Y}_i = \widehat{\mu}_{Y|X_i} \approx \exp(\widehat{Y}_i^*) \times \exp(\text{MSE}^*/2) \quad (6)$$

con MSE la suma de cuadrados medios de residuos del ajuste del modelo con variables transformadas.

- Los modelos multiplicativos son modelos heterocedásticos: en la escala de Y la varianza cambia con X .
- Los modelos logarítmico y recíproco, son modelos homocedásticos: En la escala de Y la varianza no cambia con X .

Algunas consideraciones

- En modelos multiplicativos de la forma

$$Y_i = \beta_0 \cdot h(X_i, \beta_1) \cdot E_i, \quad \text{con } \log(E_i) \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (4)$$

con $h(X_i, \beta_1) = e^{\beta_1 X_i}$ en modelo exponencial, $h(X_i, \beta_1) = X_i^{\beta_1}$ en modelo de potencia,

$$\widehat{\beta}_0 \approx \exp(\widehat{\beta}_0^*) \quad (5)$$

con $\widehat{\beta}_0^*$ obtenido en el ajuste por MCO del modelo con variables transformadas.

- En los modelos multiplicativos (cualquiera de las parametrizaciones presentadas),*

$$\widehat{Y}_i = \widehat{\mu}_{Y|X_i} \approx \exp(\widehat{Y}_i^*) \times \exp(\text{MSE}^*/2) \quad (6)$$

con MSE la suma de cuadrados medios de residuos del ajuste del modelo con variables transformadas.

- Los modelos multiplicativos son modelos heterocedásticos: en la escala de Y la varianza cambia con X .
- Los modelos logarítmico y recíproco, son modelos homocedásticos: En la escala de Y la varianza no cambia con X .*

Algunas consideraciones

- En modelos multiplicativos de la forma

$$Y_i = \beta_0 \cdot h(X_i, \beta_1) \cdot E_i, \quad \text{con } \log(E_i) \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (4)$$

con $h(X_i, \beta_1) = e^{\beta_1 X_i}$ en modelo exponencial, $h(X_i, \beta_1) = X_i^{\beta_1}$ en modelo de potencia,

$$\widehat{\beta}_0 \approx \exp(\widehat{\beta}_0^*) \quad (5)$$

con $\widehat{\beta}_0^*$ obtenido en el ajuste por MCO del modelo con variables transformadas.

- En los modelos multiplicativos (cualquiera de las parametrizaciones presentadas),

$$\widehat{Y}_i = \widehat{\mu}_{Y|X_i} \approx \exp(\widehat{Y}_i^*) \times \exp(\text{MSE}^*/2) \quad (6)$$

con MSE la suma de cuadrados medios de residuos del ajuste del modelo con variables transformadas.

- Los modelos multiplicativos son modelos heterocedásticos: en la escala de Y la varianza cambia con X .
- Los modelos logarítmico y recíproco, son modelos homocedásticos: En la escala de Y la varianza no cambia con X .

Algunas consideraciones

- En modelos multiplicativos de la forma

$$Y_i = \beta_0 \cdot h(X_i, \beta_1) \cdot E_i, \quad \text{con } \log(E_i) \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (4)$$

con $h(X_i, \beta_1) = e^{\beta_1 X_i}$ en modelo exponencial, $h(X_i, \beta_1) = X_i^{\beta_1}$ en modelo de potencia,

$$\widehat{\beta}_0 \approx \exp(\widehat{\beta}_0^*) \quad (5)$$

con $\widehat{\beta}_0^*$ obtenido en el ajuste por MCO del modelo con variables transformadas.

- En los modelos multiplicativos (cualquiera de las parametrizaciones presentadas),

$$\widehat{Y}_i = \widehat{\mu}_{Y|X_i} \approx \exp(\widehat{Y}_i^*) \times \exp(\text{MSE}^*/2) \quad (6)$$

con MSE la suma de cuadrados medios de residuos del ajuste del modelo con variables transformadas.

- Los modelos multiplicativos son modelos heterocedásticos: en la escala de Y la varianza cambia con X .
- Los modelos logarítmico y recíproco, son modelos homocedásticos: En la escala de Y la varianza no cambia con X .

- No son intrínsecamente lineales los modelos exponenciales y de potencia aditivos:

$$Y_i = \beta_0 \exp(\beta_1 X_i) + E_i, E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (7)$$

$$Y_i = \beta_0 X_i^{\beta_1} + E_i, E_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (8)$$

Estos modelos se ajustan por **mínimos cuadrados no lineales** (tema que no es visto en este curso).

Contenido

- 1 Definición de linealidad de un modelo de regresión
- 2 Modelos intrínsecamente lineales
- 3 Transformaciones Box-Cox sobre Y

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^\lambda, E_i^\lambda \stackrel{\text{iid}}{\sim} N(0, \sigma^2). \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):

- [Box-Cox](#) (1958) *Biometrika* 45: 285-310. [Box-Cox](#) (1964) *Biometrika* 51: 381-400.
- [Cox](#) (1962) *Biometrika* 49: 523-550.
- [Cox](#) (1969) *Biometrika* 56: 1-45.
- [Cox](#) (1972) *Biometrika* 59: 1-45.

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):

• Máxima verosimilitud: En librería `car` se dispone de la función `boxCox()`.

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):
 - *Máxima verosimilitud:* En librería `car` se dispone de la función `boxCox()`.
 - *Método iterativo:* Basado en búsqueda de λ en un rango de valores potenciales, tal que minimice SSE^* del MRLS

$$Y_i^{\lambda} = \beta_0^{\lambda} + \beta_1^{\lambda} x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \quad (10)$$

Modelos intrínsecamente lineales: Transformaciones Box-Cox sobre Y

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):
 - **Máxima verosimilitud:** En librería `car` se dispone de la función `boxCox()`.
 - **Método iterativo:** Basado en búsqueda de λ en un rango de valores potenciales, tal que minimice SSE^* del MRLS

$$Y_i^{\lambda*} = \beta_0^* + \beta_1^* x_i + E_i^*, E_i^* \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \quad (10)$$

donde $Y^{\lambda*}$ es una versión estandarizada de Y^λ para hacer comparables los SSE^* obtenidos con diferentes valores de λ .

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{iid}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):
 - **Máxima verosimilitud:** En librería `car` se dispone de la función `boxCox()`.
 - **Método iterativo:** Basado en búsqueda de λ en un rango de valores potenciales, tal que minimice SSE^* del MRLS

$$Y^{*\lambda} = \beta_0^* + \beta_1^* x_i + E_i^*, E_i^* \stackrel{iid}{\sim} N(0, \sigma^2) \quad (10)$$

donde $Y^{*\lambda}$ es una versión estandarizada de Y^λ para hacer comparables los SSE^* obtenidos con diferentes valores de λ .

Transformaciones Box-Cox sobre Y

- Procura corregir no normalidad junto con varianza no constante.
- Transformación: El modelo de regresión cambia a

$$Y_i^\lambda = \beta_0 + \beta_1 x_i + E_i^*, E_i^* \stackrel{iid}{\sim} N(0, \sigma^2), \quad (9)$$

- Los parámetros a estimar son $\beta_0, \beta_1, \lambda, \sigma^2$.
- Métodos (Ver Sección 3.5 Capítulo 3 Notas de Clase):
 - **Máxima verosimilitud:** En librería `car` se dispone de la función `boxCox()`.
 - **Método iterativo:** Basado en búsqueda de λ en un rango de valores potenciales, tal que minimice SSE^* del MRLS

$$Y^{*\lambda} = \beta_0^* + \beta_1^* x_i + E_i^*, E_i^* \stackrel{iid}{\sim} N(0, \sigma^2) \quad (10)$$

donde $Y^{*\lambda}$ es una versión estandarizada de Y^λ para hacer comparables los SSE^* obtenidos con diferentes valores de λ .