

Series de tiempo univariadas - Presentación 9

Mauricio Alejandro Mazo Lopera

Universidad Nacional de Colombia
Facultad de Ciencias
Escuela de Estadística
Medellín



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Comportamiento de las ACF y PACF teóricas

Proceso	ACF	PACF
$AR(p)$	Decaimiento exponencial y/o onda senoidal amortiguada	Corte después del rezago p
$MA(q)$	Corte después del rezago q	Decaimiento exponencial y/o onda senoidal amortiguada
$ARMA(p, q)$	Decaimiento exponencial y/o onda senoidal amortiguada	Decaimiento exponencial y/o onda senoidal amortiguada

Estimación de modelos ARMA(p, q)

Después de ver cuál es el comportamiento teórico de las ACF y PACF de los modelos:

- AR(p): $X_t = \phi_0 + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + w_t$
- MA(q): $X_t = \mu + w_t + \theta_1 w_{t-1} + \cdots + \theta_q w_{t-q}$
- ARMA(p, q): $X_t = \alpha + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + w_t + \theta_1 w_{t-1} + \cdots + \theta_q w_{t-q}$

Podemos aplicar esto para identificar los ordenes p y/o q del modelo que queremos ajustar a una serie de tiempo, a partir de las ACF y PACF muestrales.

Estimación de modelos ARMA(p, q)

Después de ver cuál es el comportamiento teórico de las ACF y PACF de los modelos:

- AR(p): $X_t = \phi_0 + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + w_t$
- MA(q): $X_t = \mu + w_t + \theta_1 w_{t-1} + \cdots + \theta_q w_{t-q}$
- ARMA(p, q): $X_t = \alpha + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + w_t + \theta_1 w_{t-1} + \cdots + \theta_q w_{t-q}$

Podemos aplicar esto para identificar los ordenes p y/o q del modelo que queremos ajustar a una serie de tiempo, a partir de las ACF y PACF muestrales.

Luego, el **objetivo** es **estimar** los parámetros $\phi_0, \phi_1, \phi_2, \dots, \phi_p, \mu, \theta_1, \theta_2, \dots, \theta_q$ y σ_w^2 .

Algunos de los métodos de estimación son:

- Método de los momentos.
- Mínimos cuadrados condicional.
- Máxima verosimilitud condicional.

Veamos una breve presentación de estos métodos de estimación (para ver una explicación más detallada ver TEXTO 3 - TEÓRICO - Wei-Time series analysis - Capítulo 7):

Método de los momentos:

Este método funciona bien principalmente para el proceso $AR(p)$, ya que para este se cumplen las ecuaciones de Yule-Walker:

$$\rho_1 = \phi_1 + \phi_2\rho_1 + \cdots + \phi_p\rho_{p-1}$$

$$\rho_2 = \phi_1\rho_1 + \phi_2 + \cdots + \phi_p\rho_{p-2}$$

$$\vdots$$

$$\rho_p = \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \cdots + \phi_p$$

Método de los momentos:

Este métodos funciona bien principalmente para el proceso $AR(p)$, ya que para este se cumplen las ecuaciones de Yule-Walker:

$$\begin{aligned}\rho_1 &= \phi_1 + \phi_2\rho_1 + \cdots + \phi_p\rho_{p-1} \\ \rho_2 &= \phi_1\rho_1 + \phi_2 + \cdots + \phi_p\rho_{p-2} \\ &\vdots \\ \rho_p &= \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \cdots + \phi_p\end{aligned}$$

Reemplazando las ACF ρ_1, \dots, ρ_p por sus estimaciones muestrales $\hat{\rho}_1, \dots, \hat{\rho}_p$ en este sistema, llegamos a los estimadores:

$$\begin{bmatrix} \hat{\phi}_1 \\ \hat{\phi}_2 \\ \vdots \\ \hat{\phi}_p \end{bmatrix} = \begin{bmatrix} 1 & \hat{\rho}_1 & \hat{\rho}_2 & \cdots & \hat{\rho}_{p-2} & \hat{\rho}_{p-1} \\ \hat{\rho}_1 & 1 & \hat{\rho}_1 & \cdots & \hat{\rho}_{p-3} & \hat{\rho}_{p-2} \\ \vdots & & & & & \vdots \\ \hat{\rho}_{p-1} & \hat{\rho}_{p-2} & \hat{\rho}_{p-3} & \cdots & \hat{\rho}_1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \\ \vdots \\ \hat{\rho}_p \end{bmatrix}$$

Método de los momentos:

Este métodos funciona bien principalmente para el proceso $AR(p)$, ya que para este se cumplen las ecuaciones de Yule-Walker:

$$\begin{aligned}\rho_1 &= \phi_1 + \phi_2\rho_1 + \cdots + \phi_p\rho_{p-1} \\ \rho_2 &= \phi_1\rho_1 + \phi_2 + \cdots + \phi_p\rho_{p-2} \\ &\vdots \\ \rho_p &= \phi_1\rho_{p-1} + \phi_2\rho_{p-2} + \cdots + \phi_p\end{aligned}$$

Reemplazando las ACF ρ_1, \dots, ρ_p por sus estimaciones muestrales $\hat{\rho}_1, \dots, \hat{\rho}_p$ en este sistema, llegamos a los estimadores:

$$\begin{bmatrix} \hat{\phi}_1 \\ \hat{\phi}_2 \\ \vdots \\ \hat{\phi}_p \end{bmatrix} = \begin{bmatrix} 1 & \hat{\rho}_1 & \hat{\rho}_2 & \cdots & \hat{\rho}_{p-2} & \hat{\rho}_{p-1} \\ \hat{\rho}_1 & 1 & \hat{\rho}_1 & \cdots & \hat{\rho}_{p-3} & \hat{\rho}_{p-2} \\ \vdots & & & & \vdots & \\ \hat{\rho}_{p-1} & \hat{\rho}_{p-2} & \hat{\rho}_{p-3} & \cdots & \hat{\rho}_1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} \hat{\rho}_1 \\ \hat{\rho}_2 \\ \vdots \\ \hat{\rho}_p \end{bmatrix}$$

El estimador de σ_w^2 está dado por:

$$\hat{\sigma}_w^2 = \hat{\gamma}(0)(1 - \hat{\phi}_1\hat{\rho}_1 - \hat{\phi}_2\hat{\rho}_2 - \cdots - \hat{\phi}_p\hat{\rho}_p) \quad (\text{¿por qué?})$$

Máxima verosimilitud condicional:

EL método de los momentos tiene como desventaja que no funciona muy bien para estimar los parámetros del modelo $MA(q)$.

Máxima verosimilitud condicional:

EL método de los momentos tiene como desventaja que no funciona muy bien para estimar los parámetros del modelo $MA(q)$. Esto abre paso a otro método conocido como máxima verosimilitud condicional, en donde se asume que w_t es un ruido blanco Gaussiano y se busca maximizar la log-verosimilitud condicional:

$$\ln(L_*(\tilde{\phi}, \tilde{\theta}, \alpha, \sigma_w^2)) = -\frac{n}{2} \ln(2\pi\sigma_w^2) - \frac{S_*(\tilde{\phi}, \alpha, \tilde{\theta})}{2\sigma_w^2}$$

donde $\tilde{\phi} = (\phi_1, \phi_2, \dots, \phi_p)^\top$, $\tilde{\theta} = (\theta_1, \theta_2, \dots, \theta_q)^\top$ y la **suma condicional de cuadrados está dada por**:

$$S_*(\tilde{\phi}, \alpha, \tilde{\theta}) = \sum_{t=1}^n w_t^2$$

con

$$w_t = X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} - \alpha - \theta_1 w_{t-1} - \dots - \theta_q w_{t-q}$$

Máxima verosimilitud condicional:

El estimador de σ_w^2 está dado por:

$$\hat{\sigma}_w^2 = \frac{S_*(\hat{\phi}, \hat{\alpha}, \hat{\theta})}{g.l.}$$

donde $g.l.$ son los grados de libertad iguales al tamaño de muestra n menos el número de parámetros estimados.

Máxima verosimilitud condicional:

El estimador de σ_w^2 está dado por:

$$\hat{\sigma}_w^2 = \frac{S_*(\hat{\tilde{\phi}}, \hat{\tilde{\alpha}}, \hat{\tilde{\theta}})}{g.l.}$$

donde *g.l.* son los grados de libertad iguales al tamaño de muestra n menos el número de parámetros estimados.

En la mayoría de paquetes estadísticos minimizan la **suma condicional de cuadrados** $S_*(\tilde{\phi}, \alpha, \tilde{\theta})$ con el fin de obtener valores iniciales en el proceso de maximización de la log-verosimilitud condicional $\ln(L_*(\tilde{\phi}, \tilde{\theta}, \alpha, \sigma_w^2))$.

Estimación de modelos ARMA(p, q) en R:

En R existen distintas funciones para estimar los parámetros de un modelo ARMA(p, q), entre los cuales están:

- **arima**: Hace parte del paquete **stats**. Para mayor información escribir **?stats::arima** en la consola del RStudio.
- **Arima**: Hace parte del paquete **forecast**. Para mayor información escribir **?forecast::Arima** en la consola del RStudio.
- **arima**: Hace parte del paquete **TSA**. Para mayor información escribir **?TSA::arima** en la consola del RStudio.
- **arma**: Hace parte del paquete **tseries**. Para mayor información escribir **?tseries::arma** en la consola del RStudio. Solo minimiza la suma de cuadrados condicionales y no pasa por la verosimilitud.

La tres primeras funciones estiman unos valores iniciales minimizando la suma de cuadrados condicionales y luego usan estos valores para maximizar la función de verosimilitud.

Estimación de modelos ARMA(p, q) en Python:

Dentro del módulo **statmodels** del Python existe un submódulo conocido como **tsa** por sus siglas en inglés *time series analysis* (sitio web [AQUÍ](#)).

Este submódulo contiene el proceso **arima_model** cuya función **ARIMA** permite estimar los parámetros del modelo ARMA también utilizando el método de máxima verosimilitud condicional.


Para cargarlo utilice los códigos

```
from statsmodels.tsa.arima_model import ARIMA
```

Estimación de modelos ARMA(p, q):

Consideremos un ejemplo simple para ver cómo trabajar con las funciones del R que vimos:

```
require(tseries)
data(tcm)
plot(tcm10y) # Escriba ?tcm para más información
```




Estimación de modelos ARMA(p, q):

Encontremos las ACF y PACF muestrales:

```
acf(tcm10y)
```

Series tcm10y




Se observa un decaimiento lento debido a la tendencia en la serie.

Estimación de modelos ARMA(p, q):

pacf(tcm10y)

Series tcm10y



Se observan los dos primeros lags fuera de la banda de confianza.

Estimación de modelos ARMA(p, q):

Lo anterior sugiere ajustar un un modelo AR(2):

```
modelo1 <- arima(tcm10y, order=c(2, 0, 0)) # order=c()  
modelo1
```

```
## Warning in arima(tcm10y, order = c(2, 0, 0)): possible convergence p  
## optim gave code = 1
```

```
##
```

```
## Call:
```

```
## arima(x = tcm10y, order = c(2, 0, 0))
```

```
##
```

```
## Coefficients:
```

```
##          ar1          ar2  intercept
```

```
##          1.3250   -0.3320         6.2448
```

```
## s.e.    0.0399    0.0399         1.4044
```

```
##
```

```
## sigma^2 estimated as 0.07231:  log likelihood = -61.28,  aic = 130.5
```

Estimación de modelos ARMA(p, q):

```
names(modelo1)
```

```
## [1] "coef"      "sigma2"    "var.coef"  "mask"      "loglik"    "aic"  
## [7] "arma"      "residuals" "call"      "series"    "code"      "n.cond"  
## [13] "nobs"      "model"
```

Los valores ajustados se pueden obtener como:

```
mod1_ajust <- tcm10y - modelo1$residuals
```

Los coeficientes estimados son:


```
modelo1$coef
```

```
##          ar1          ar2  intercept  
## 1.3249527 -0.3320146  6.2448425
```

Estimación de modelos ARMA(p, q):

Grafiquemos la serie **tcm10y** versus los valores ajustados por el modelo:

```
plot(tcm10y, col="gray")  
lines(mod1_ajust, col="red", lty=2)
```



Estimación de modelos ARMA(p, q):

En este ejemplo, vemos lo siguiente:

- Las ACF y PACF funcionan para identificar los ordenes p y/o q de modelos estacionarios y vemos que esta serie tiene tendencia y nos lleva a parámetros estimados $\hat{\phi}_0 = 6.245$, $\hat{\phi}_1 = 1.325$, $\hat{\phi}_2 = -0.332$.
- Si utilizamos estos parámetros para analizar la estacionariedad del proceso estimado: $\hat{X}_t = \hat{\phi}_0 + \hat{\phi}_1 X_{t-1} + \hat{\phi}_2 X_{t-2}$, tenemos el polinomio $\phi(B) = 1 - \hat{\phi}_1 B - \hat{\phi}_2 B^2$ cuyas raíces son:

```
polyroot(c(1,-1.3250,0.3320))
```

```
## [1] 1.010647+0i 2.980317+0i
```

Las cuales se encuentran fuera del círculo unitario:


```
abs(polyroot(c(1,-1.3250,0.3320)))
```

```
## [1] 1.010647 2.980317
```

Estimación de modelos ARMA(p, q):

Una opción recomendada en una serie con tendencia es considerar la diferencia de la serie entre el mes t y el mes $t - 1$, es decir, si X_t denota el precio mensual de los bonos a 10 años, la serie diferencia es $Y_t = X_t - X_{t-1}$:

```
y <- diff(tcm10y)
plot(y)
```




Estimación de modelos ARMA(p, q):

Encontremos las ACF y PACF muestrales:

acf(y)

Series y




Se observa primeros dos lags fuera de la banda de confianza

Estimación de modelos $ARMA(p, q)$:

Encontremos las ACF y PACF muestrales:

pacf(y)

Series y



Decaimiento senoidal.

Estimación de modelos ARMA(p, q):

Lo anterior sugiere ajustar un modelo MA(2):

```
modelo2 <- arima(y, order=c(0, 0, 2))
modelo2
```

```
##
```

```
## Call:
```

```
## arima(x = y, order = c(0, 0, 2))
```

```
##
```

```
## Coefficients:
```

```
##          ma1          ma2  intercept
```

```
##          0.4488  -0.1180          0.0055
```

```
## s.e.    0.0424    0.0426          0.0146
```

```
##
```

```
## sigma^2 estimated as 0.06698:  log likelihood = -37.63,  aic = 83.27
```

Estimación de modelos ARMA(p, q):

```
names(modelo2)
```

```
## [1] "coef"      "sigma2"    "var.coef"  "mask"      "loglik"    "aic"  
## [7] "arma"      "residuals" "call"      "series"    "code"      "n.cond"  
## [13] "nobs"      "model"
```

Los valores ajustados se pueden obtener como:

```
mod2_ajust <- y - modelo2$residuals
```

Los coeficientes estimados son:


```
modelo2$coef
```

```
##          ma1          ma2    intercept  
## 0.448766481 -0.118042957 0.005514984
```

Estimación de modelos ARMA(p, q):

Grafiquemos la serie Y_t versus los valores ajustados por el modelo:

```
plot(y, col="gray")  
lines(mod2_ajust, col="red", lty=2)
```



En estos ajustes surgen varias preguntas:

- ❶ ¿Cómo se estiman los errores estándar (s.e.) de los parámetros estimados? ¿Para qué usarlos?
- ❷ ¿Cómo se calcula el **aic** y cómo usarlo en este contexto?
- ❸ Entre varios modelos, ¿cómo saber cuál es el mejor?
- ❹ ¿Cómo podemos realizar un diagnóstico para saber si el modelo ajusta de manera correcta los datos con respecto a los supuestos realizados?

Errores estándar (s.e.) de los estimadores

Para responder a la primera pregunta, recurrimos al siguiente resultado ([visto en inferencia estadística y que se encuentra en TEXTO 2 - EN R - Time-series-analysis-and-its-applications-with-examples-in-r](#) **página 133**) sobre los estimadores de máxima verosimilitud:

Para un proceso $\text{ARMA}(p, q)$ que es estacionario e invertible se cumple que los estimadores de máxima verosimilitud, además de los estimadores de mínimos cuadrados no condicionales y también condicionales, denotados por $\hat{\beta}$, tienen distribución asintóticamente normal dada por:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}, \sigma_w^2 \mathbf{\Gamma}_{p, q}^{-1})$$

donde $\sigma_w^2 \mathbf{\Gamma}_{p, q}^{-1}$ representa la matriz de varianzas-covarianzas de $\hat{\beta}$ y se obtiene como la inversa de la matriz de información.

Errores estándar (s.e.) de los estimadores

En particular la matriz $(p + q) \times (p + q)$ tiene la forma:

$$\Gamma_{p, q} = \begin{pmatrix} \Gamma_{\phi\phi} & \Gamma_{\phi\theta} \\ \Gamma_{\theta\phi} & \Gamma_{\theta\theta} \end{pmatrix}$$

Con $\Gamma_{\phi\phi}$ representando a la matriz de covarianzas de los parámetros $AR(p)$, $\Gamma_{\theta\theta}$ representando a la matriz de covarianzas de los parámetros $MA(q)$ y $\Gamma_{\phi\theta}$, $\Gamma_{\theta\phi}$ representando a la matriz de covarianzas-cruzadas entre los parámetros $AR(p)$ y $MA(q)$.

Errores estándar (s.e.) de los estimadores

En particular la matriz $(p + q) \times (p + q)$ tiene la forma:

$$\Gamma_{p, q} = \begin{pmatrix} \Gamma_{\phi\phi} & \Gamma_{\phi\theta} \\ \Gamma_{\theta\phi} & \Gamma_{\theta\theta} \end{pmatrix}$$

Con $\Gamma_{\phi\phi}$ representando a la matriz de covarianzas de los parámetros AR(p), $\Gamma_{\theta\theta}$ representando a la matriz de covarianzas de los parámetros MA(q) y $\Gamma_{\phi\theta}$, $\Gamma_{\theta\phi}$ representando a la matriz de covarianzas-cruzadas entre los parámetros AR(p) y MA(q).

La raíz cuadrada de los elementos de la diagonal de la matriz $\sigma_w^2 \Gamma_{p, q}^{-1}$ contiene a los errores estándar (s.e.) teóricos de los parámetros de la parte AR(p) y MA(q). Reemplazando σ_w^2 por su estimador $\hat{\sigma}_w^2$ (además de los otros estimadores en $\Gamma_{p, q}^{-1}$) obtenemos los valores en la salida de la función **arma** del R.

Errores estándar (s.e.) de los estimadores

Un uso que se le puede dar a estos valores de errores estándar es plantear las hipótesis individuales:

- En la parte $AR(p)$:

$$H_0 : \phi_i = 0 \quad \text{versus} \quad \phi_i \neq 0, \quad i = 0, 1, 2, \dots, p$$

- En la parte $MA(q)$:

$$H_0 : \theta_j = 0 \quad \text{versus} \quad \theta_j \neq 0, \quad j = 1, 2, \dots, q$$

Cuyos estadísticos de prueba son:

$$Z_{\phi,i} = \frac{\hat{\phi}_i}{\widehat{s.e.}(\phi_i)} \quad \text{y} \quad Z_{\theta,j} = \frac{\hat{\theta}_j}{\widehat{s.e.}(\theta_j)}$$

Y comparando con el cuantil $z_{\alpha/2}$ de la normal estándar, rechazamos H_0 si:

$$|Z_{\phi,i}| > z_{\alpha/2} \quad \text{y} \quad |Z_{\theta,j}| > z_{\alpha/2}$$

Otro uso que se le puede dar a los errores estándar es para construir intervalos de confianza dados por:

- Parámetros de la parte AR(p):

$$\hat{\phi}_i \pm z_{\alpha/2} \times \widehat{s.e.}(\phi_i), \quad i = 0, 1, 2, \dots, p$$

- Parámetros de la parte MA(q):

$$\hat{\theta}_j \pm z_{\alpha/2} \times \widehat{s.e.}(\theta_j), \quad j = 1, 2, \dots, q$$

NOTA: Recuerde que cuando no hay información sobre el nivel de significancia α , se toma por defecto igual a 0.05 o 5 %.

Ejemplo aplicado a datos reales:

Considere la base de datos de **Incidentes Viales con Motos** registrados en Medellín entre el 2015 y el 2021 (para ver el sitio web donde se puede descargar la base de datos dé click [AQUÍ](#)). La BD también se puede descargar de la pestaña de datos del Moodle:

```
require(tidyverse)
require(magrittr)
require(readr)
require(janitor)
direccion <- "../..//DATOS/incidentes_viales_motos.csv"
bd_incidentes <- read_delim(direccion,
                           delim = ";")
bd_incidentes %<>% clean_names()
bd_incidentes %>% dim()
```

```
## [1] 223439      9
```

Ejemplo aplicado a datos reales:

Esta base de datos tiene un problema con las fechas y es el siguiente:

```
bd_incidentes %>% head(n=3)
```

```
## # A tibble: 3 x 9
##   nro_radicado ano_incidente fecha_incidente hora_incidente clase_incidente
##         <dbl>         <dbl> <chr>           <chr>           <chr>
## 1      1473523         2015 27/01/15         22:00:00         Choque
## 2      1473525         2015 27/01/15         15:40:00         Choque
## 3      1473526         2015 27/01/15         18:00:00         Choque
## # ... with 4 more variables: gravedad_incidente <chr>, direccion <chr>,
## #   zona <chr>, diseno_via <chr>
```

```
bd_incidentes %>% tail(n=3)
```

```
## # A tibble: 3 x 9
##   nro_radicado ano_incidente fecha_incidente hora_incidente clase_incidente
##         <dbl>         <dbl> <chr>           <chr>           <chr>
## 1      1759665         2021 25/08/2021         20:15:00         Choque
## 2      1759743         2021 25/08/2021         20:25:00         Choque
## 3      1759627         2021 25/08/2021         21:00:00         Otro
## # ... with 4 more variables: gravedad_incidente <chr>, direccion <chr>,
## #   zona <chr>, diseno_via <chr>
```

Ejemplo aplicado a datos reales:

Este problema con las fechas lleva a que si queremos darle el formato adecuado tengamos un problema, ya que para fechas como la siguiente:

```
as.Date("27/01/15", format="%d/%m/%y") # y minúscula
```

```
## [1] "2015-01-27"
```

El formato no funciona si es:

```
as.Date("27/01/2015", format="%d/%m/%y") # y minúscula
```

```
## [1] "2020-01-27"
```

Ejemplo aplicado a datos reales:

Este problema con las fechas lleva a que si queremos darle el formato adecuado tengamos un problema, ya que para fechas como la siguiente:

```
as.Date("27/01/15", format="%d/%m/%y") # y minúscula
```

```
## [1] "2015-01-27"
```

El formato no funciona si es:

```
as.Date("27/01/2015", format="%d/%m/%y") # y minúscula
```

```
## [1] "2020-01-27"
```

Lo correcto es:

```
as.Date("27/01/2015", format="%d/%m/%Y") # Y mayúscula
```

```
## [1] "2015-01-27"
```

Ejemplo aplicado a datos reales:

Una solución a este problema particular es observando que el número de caracteres es diferente en ambos formatos, pero constante:

```
nchar("27/01/15")
```

```
## [1] 8
```

```
nchar("27/01/2015")
```

```
## [1] 10
```

Ejemplo aplicado a datos reales:

Una solución a este problema particular es observando que el número de caracteres es diferente en ambos formatos, pero constante:

```
nchar("27/01/15")
```

```
## [1] 8
```

```
nchar("27/01/2015")
```

```
## [1] 10
```

Así, podemos darle formato a la fecha del incidente considerando un condicional como:

```
aux1 <- as.Date(rep(NA, nrow(bd_incidentes)))  
aux2 <- bd_incidentes$fecha_incidente  
ind1<-which(nchar(aux2)==8)  
ind2<-which(nchar(aux2)==10)  
aux1[ind1] <- as.Date(aux2[ind1], format = "%d/%m/%y")  
aux1[ind2] <- as.Date(aux2[ind2], format = "%d/%m/%Y")  
bd_incidentes$fecha_incidente<-aux1
```

Ejemplo aplicado a datos reales:


Obtenemos el conteo de accidentes por día:

```
require(lubridate)
bd_incidentes$mes<-month(bd_incidentes$fecha_incidente)
bd_incidentes$anio<-year(bd_incidentes$fecha_incidente)
resum1 <- bd_incidentes %>% group_by(anio, mes) %>%
                                summarise(accidentes=n())
resum1$fecha <- as.Date(
                                paste(resum1$anio,resum1$mes,1,sep="-"),
                                format = "%Y-%m-%d")
```

El gráfico de la serie de accidentes mensuales está dado por:

Ejemplo aplicado a datos reales:


```
resum1 %>% ggplot(aes(x=fecha, y=accidentes))+  
  geom_line()
```



Ejemplo aplicado a datos reales:

Encontremos las ACF y PACF muestrales:


```
acf(resum1$accidentes)
```



Se observa un decaimiento.

Ejemplo aplicado a datos reales:

```
pacf(resum1$accidentes)
```



Los lags 1 y 6 sobresalen de la banda de confianza.

Ejemplo aplicado a datos reales:

Lo anterior sugiere ajustar un modelo AR(6):

```
modelo3 <- arima(resum1$accidentes, order=c(6, 0, 0))
modelo3
```

```
##
## Call:
## arima(x = resum1$accidentes, order = c(6, 0, 0))
##
## Coefficients:
##          ar1      ar2      ar3      ar4      ar5      ar6  intercept
##          0.7024  0.1013 -0.0705 -0.0515  0.2258 -0.2969  2794.4827
## s.e.  0.1055  0.1307   0.1328   0.1328  0.1409   0.1117   83.4591
##
## sigma^2 estimated as 83525:  log likelihood = -567.52,  aic = 1151.04
```

Ejemplo aplicado a datos reales:

La matriz de covarianzas de los estimadores está dada por

```
modelo3$var.coef
```

```
##           ar1      ar2      ar3      ar4      ar5      ar6 intercept
## ar1      0.0111 -0.0080 -0.0015  0.0006  0.0011  0.0001   -0.0519
## ar2     -0.0080  0.0171 -0.0073 -0.0013 -0.0007  0.0012   -0.0232
## ar3     -0.0015 -0.0073  0.0176 -0.0075 -0.0012  0.0000    0.0870
## ar4      0.0006 -0.0013 -0.0075  0.0176 -0.0084 -0.0006    0.1867
## ar5      0.0011 -0.0007 -0.0012 -0.0084  0.0198 -0.0098   -0.0470
## ar6      0.0001  0.0012  0.0000 -0.0006 -0.0098  0.0125   -0.0559
## intercept -0.0519 -0.0232  0.0870  0.1867 -0.0470 -0.0559 6965.4181
```

Los errores estandar (s.e.) son:

```
se <- modelo3$var.coef %>% diag() %>% sqrt() %>% round(4)
```

Ejemplo aplicado a datos reales:

Los intervalos de confianza están dados por:

```
modelo3$coef-1.96*se
```

##	ar1	ar2	ar3	ar4	ar5	ar6	intercept
##	0.496	-0.155	-0.331	-0.312	-0.050	-0.516	2630.903

```
modelo3$coef+1.96*se
```

##	ar1	ar2	ar3	ar4	ar5	ar6	intercept
##	0.909	0.357	0.190	0.209	0.502	-0.078	2958.063

donde $z_{\alpha/2} = z_{0.025} = 1.96$.

¿Qué se puede concluir de estos resultados?

Ejemplo aplicado a datos reales:

Los intervalos de confianza están dados por:

```
modelo3$coef-1.96*se
```

##	ar1	ar2	ar3	ar4	ar5	ar6	intercept
##	0.496	-0.155	-0.331	-0.312	-0.050	-0.516	2630.903

```
modelo3$coef+1.96*se
```

##	ar1	ar2	ar3	ar4	ar5	ar6	intercept
##	0.909	0.357	0.190	0.209	0.502	-0.078	2958.063

donde $z_{\alpha/2} = z_{0.025} = 1.96$.

¿Qué se puede concluir de estos resultados? Solo los parámetros ϕ_1 , ϕ_6 y el intercepto (ϕ_0) tienen intervalos que no contienen al cero, lo cual puede interpretarse como que son estadísticamente distintos de cero con una confianza del 95 %.