

Series de tiempo univariadas - Presentación 18

Mauricio Alejandro Mazo Lopera

Universidad Nacional de Colombia
Facultad de Ciencias
Escuela de Estadística
Medellín



UNIVERSIDAD
NACIONAL
DE COLOMBIA

La mayoría de los modelos de predicción asumen la la variación de la serie permanece constante a lo largo del tiempo. Sin embargo, este supuesto suele no cumplirse y por tanto, es necesario aplicar una transformación que busque estabilizar la varianza. Dos transformaciones usualmente utilizadas son:

- **Logaritmo natural:** En este caso, aplicamos a la serie $\{X_t\}$ el logaritmo natural, es decir, la serie a modelar sería $X_t^* = \ln(X_t)$.
- **Transformación Box-Cox:** Está basada en la siguiente fórmula

$$X_t^* = \begin{cases} \frac{X_t^\lambda - 1}{\lambda}, & \text{si } \lambda \neq 0 \\ \ln(X_t), & \text{si } \lambda = 0 \end{cases}$$

Transformaciones estabilizadoras de varianza: Ejemplo 1

Veamos un ejemplo típico relacionado con este tipo de situaciones:

```
require(forecast)
require(magrittr)
require(tidyverse)
pas_lambda <- BoxCox.lambda(AirPassengers)
pas_lambda
```


```
## [1] -0.2947156
```

```
pasa_transform <- BoxCox(AirPassengers,
                          lambda=pas_lambda)
```

Transformaciones estabilizadoras de varianza: Ejemplo 1

Con esta transformación pasamos de:


```
AirPassengers %>% plot(main="Serie Original",  
                        las=1)
```



Transformaciones estabilizadoras de varianza: Ejemplo 1

A la serie transformada:

```
pasa_transform %>% plot(main="Serie Transformada",  
                        las=1)
```



Transformaciones estabilizadoras de varianza: Ejemplo 1


Aplicamos la función **auto.arima** del paquete **forecast**:

```
modelo1_sin <- auto.arima(AirPassengers)
modelo1_sin
```

```
## Series: AirPassengers
## ARIMA(2,1,1)(0,1,0)[12]
##
## Coefficients:
##          ar1      ar2      ma1
##      0.5960  0.2143 -0.9819
## s.e.  0.0888  0.0880  0.0292
##
## sigma^2 = 132.3:  log likelihood = -504.92
## AIC=1017.85   AICc=1018.17   BIC=1029.35
```

Transformaciones estabilizadoras de varianza: Ejemplo 1

```
modelo1_sin %>% checkresiduals()
```



```
##
```

```
## Ljung-Box test
```

```
##
```

```
## data: Residuals from ARIMA(2,1,1)(0,1,0)[12]
```


```
## Q* = 37.784, df = 21, p-value = 0.01366
```

```
##
```

```
## Model df: 3. Total lags used: 24
```

Transformaciones estabilizadoras de varianza: Ejemplo 1

```
modelo1_sin$residuals %>% qqnorm()  
modelo1_sin$residuals %>% qqline()
```



Transformaciones estabilizadoras de varianza: Ejemplo 1

```
require(tseries)
modelo1_sin$residuals %>% shapiro.test()
```

```
##
##  Shapiro-Wilk normality test
##
## data:  .
## W = 0.97235, p-value = 0.005165
```

```
modelo1_sin$residuals %>% jarque.bera.test()
```

```
##
##  Jarque Bera Test
##
## data:  .
## X-squared = 15.131, df = 2, p-value = 0.0005181
```

Transformaciones estabilizadoras de varianza: Ejemplo 1


Aplicamos la función **auto.arima** del paquete **forecast**:

```
modelo1_con <- auto.arima(pasa_transform)
modelo1_con
```

```
## Series: pasa_transform
## ARIMA(0,1,1)(0,1,1)[12]
##
## Coefficients:
##             ma1      sma1
##        -0.4355  -0.5847
## s.e.    0.0908   0.0725
##
## sigma^2 = 5.855e-05:  log likelihood = 451.6
## AIC=-897.19   AICc=-897.01   BIC=-888.57
```

Transformaciones estabilizadoras de varianza: Ejemplo 1

```
modelo1_con %>% checkresiduals()
```



```
##
```

```
## Ljung-Box test
```

```
##
```

```
## data: Residuals from ARIMA(0,1,1)(0,1,1)[12]
```


```
## Q* = 28.635, df = 22, p-value = 0.1556
```

```
##
```

```
## Model df: 2. Total lags used: 24
```

Transformaciones estabilizadoras de varianza: Ejemplo 1

```
modelo1_con$residuals %>% qqnorm()  
modelo1_con$residuals %>% qqline()
```



Transformaciones estabilizadoras de varianza: Ejemplo 1

```
modelo1_con$residuals %>% shapiro.test()
```

```
##  
##  Shapiro-Wilk normality test  
##  
## data:  .  
## W = 0.98016, p-value = 0.03484
```

```
modelo1_con$residuals %>% jarque.bera.test()
```

```
##  
##  Jarque Bera Test  
##  
## data:  .  
## X-squared = 13.604, df = 2, p-value = 0.001111
```

Regresión lineal con errores ARIMA

Recuerden que un modelo de regresión lineal puede ser representado por:

$$X_t = \beta_0 + \beta_1 Z_{1t} + \beta_2 Z_{2t} + \cdots + \beta_p Z_{kt} + e_t$$

donde Z_{1t}, \dots, Z_{kt} son covariables medidas en el tiempo t utilizadas para explicar X_t , y además, se asume que e_t es un ruido blanco (comúnmente Gaussiano o Normal).

Regresión lineal con errores ARIMA

Recuerden que un modelo de regresión lineal puede ser representado por:

$$X_t = \beta_0 + \beta_1 Z_{1t} + \beta_2 Z_{2t} + \cdots + \beta_p Z_{kt} + e_t$$

donde Z_{1t}, \dots, Z_{kt} son covariables medidas en el tiempo t utilizadas para explicar X_t , y además, se asume que e_t es un ruido blanco (comúnmente Gaussiano o Normal). Sin embargo, este último supuesto suele NO cumplirse.

Una solución consiste en modelar los residuales por medio de un modelo $ARIMA(p, d, q)$ (o $SARIMA$), es decir:


$$X_t = \beta_0 + \beta_1 Z_{1t} + \beta_2 Z_{2t} + \cdots + \beta_p Z_{kt} + \sum_{i=1}^p \phi_i X_{t-i} + \sum_{j=1}^q \theta_j w_{t-j} + w_t$$

donde w_t se asume como un ruido blanco (comúnmente Gaussiano o Normal).

Regresión lineal con errores ARIMA: Ejemplo 1

Dentro del paquete **forecast** existe una función llamada **tslm** que permite ajustar un modelo de regresión a una serie de tiempo (un objeto **ts**):

```
modelo21 <- tslm(AirPassengers~trend+season)
checkresiduals(modelo21)
```



##

Breusch-Godfrey test for serial correlation of order up to

##

Note que en el modelo anterior, **AirPassengers** es un objeto **ts** y por tanto, automáticamente la función **tslm** reconoce que este tiene una tendencia (trend) y un componente estacional (season).

En los gráficos del diagnóstico de los residuales se observa que no se cumple el supuesto de no autocorrelación. El resumen de dicho modelo se obtiene con el código:

```
modelo21 %>% summary()
```

Regresión lineal con errores ARIMA: Ejemplo 1

```
##
## Call:
## tslm(formula = AirPassengers ~ trend + season)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -42.121 -18.564  -3.268   15.189   95.085
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  63.50794     8.38856   7.571 5.88e-12 ***
## trend        2.66033     0.05297  50.225 < 2e-16 ***
## season2     -9.41033    10.74941  -0.875 0.382944
## season3     23.09601    10.74980   2.149 0.033513 *
## season4     17.35235    10.75046   1.614 0.108911
## season5     19.44202    10.75137   1.808 0.072849 .
## season6     56.61502    10.75254   5.265 5.58e-07 ***
## season7     93.62136    10.75398   8.706 1.17e-14 ***
## season8     90.71103    10.75567   8.434 5.32e-14 ***
## season9     39.38403    10.75763   3.661 0.000363 ***
## season10     0.89037    10.75985   0.083 0.934177
## season11    -35.51996    10.76232  -3.300 0.001244 **
## season12     -9.18029    10.76506  -0.853 0.395335
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 26.33 on 131 degrees of freedom
## Multiple R-squared:  0.9559, Adjusted R-squared:  0.9518
## F-statistic: 236.5 on 12 and 131 DF, p-value: < 2.2e-16
```

Regresión lineal con errores ARIMA: Ejemplo 1

El intercepto, la tendencia y varios valores relacionados con algunos meses son significativos. Además, el R^2 -Ajustado muestra que el modelo explica un 95.18 % de la variabilidad de la serie de tiempo. Sin embargo, el supuesto de no autocorrelación de los residuales definitivamente no se cumple.

Debido a lo anterior, definimos lo siguiente:

```
require(TSstudio)
pasajeros <- ts_to_prophet(AirPassengers)
names(pasajeros) <- c("fecha", "valores")
pasajeros %>% head(3)
```

```
##           fecha valores
## 1 1949-01-01      112
## 2 1949-02-01      118
## 3 1949-03-01      132
```

Regresión lineal con errores ARIMA: Ejemplo 1

Luego, creamos algunas variables que nos servirán para explicar la variabilidad de la serie:

```
require(tidyverse)
require(lubridate)

# Creamos una variable que representa la estacionalidad anual:
pasajeros$lag12 <- dplyr::lag(pasajeros$valores, n=12)


# Creamos la variable mes que representa el componente
# estacional:
pasajeros$mes <- pasajeros$fecha %>% month(label=TRUE) %>%
  factor(ordered=FALSE)

# Creamos una variable que denote el paso a lo largo del
# tiempo:
pasajeros$tendencia <- 1:nrow(pasajeros)
```

Regresión lineal con errores ARIMA: Ejemplo 1

Ajustamos entonces un nuevo modelo considerando la función **lm** del R:

```
modelo22 <- lm(valores~tendencia+mes+lag12,data=pasajeros)
checkresiduals(modelo22)
```



```
##
```

```
## Breusch-Godfrey test for serial correlation of order up
```

```
##
```

```
## data: Residuals
```

Regresión lineal con errores ARIMA: Ejemplo 1

Los residuales aún no se ajustan bien y presentan autocorrelación. Por este motivo, ajustamos un modelo $ARIMA(p, d, q)$ (o también $SARIMA(p, d, q) \times (P, D, Q)_s$) a los residuales:

```
matriz_disenio <- model.matrix(~mes+tendencia+lag12,  
                                data=pasajeros)[,-1]  
x_t <- ts(pasajeros$valores[13:nrow(pasajeros)],  
          frequency = 12)  
modelo23 <- auto.arima(x_t, xreg=matriz_disenio,  
                       seasonal = TRUE,  
                       stepwise = FALSE,  
                       approximation = FALSE)
```

Note que en la matriz de diseño, dejamos afuera la primera columna (correspondiente a una variable dummy de unos) para que el modelo no se “confunda” con el intercepto.

Regresión lineal con errores ARIMA: Ejemplo 1

Vemos el modelo ajustado:

```
modelo23
```

```
## Series: x_t
## Regression with ARIMA(2,0,0)(2,0,0)[12] errors
##
## Coefficients:
##          ar1      ar2      sar1      sar2  intercept  mesfeb  mesmar  mesabr
##          0.4676  0.3058 -0.4505 -0.1982    15.3395  -3.2534 -0.7725  1.6408
## s.e.      0.0842  0.0870  0.1045  0.1085     5.5906   2.0778  2.4096  2.5872
##      mesmay  mesjun  mesjul  mesago  messept  mesoct  mesnov  mesdic
##          3.6479  8.2835 14.7739 14.0767   4.9765  1.5624 -3.4306 -1.1302
## s.e.      2.7170  3.4527 4.4101  4.3006   3.0654  2.5210  2.5572  2.1281
##      tendencia  lag12
##          0.1873  0.9926
## s.e.      0.1187  0.0401
##
## sigma^2 = 102.3:  log likelihood = -484.79
## AIC=1007.58  AICc=1014.37  BIC=1062.35
```

Regresión lineal con errores ARIMA: Ejemplo 1

Vemos el modelo ajustado:


```
require(lmtest)
modelo23 %>% coeftest()
```

```
##
## z test of coefficients:
##
##           Estimate Std. Error z value Pr(>|z|)
## ar1           0.467609  0.084233  5.5514 2.834e-08 ***
## ar2           0.305752  0.087033  3.5131 0.000443 ***
## sar1          -0.450527  0.104482 -4.3120 1.618e-05 ***
## sar2          -0.198169  0.108523 -1.8261 0.067842 .
## intercept    15.339514  5.590631  2.7438 0.006073 **
## mesfeb        -3.253368  2.077764 -1.5658 0.117395
## mesmar        -0.772511  2.409560 -0.3206 0.748512
## mesabr         1.640813  2.587166  0.6342 0.525942
## mesmay         3.647868  2.716979  1.3426 0.179395
## mesjun         8.283532  3.452668  2.3992 0.016432 *
## mesjul        14.773947  4.410100  3.3500 0.000808 ***
## mesago        14.076703  4.300579  3.2732 0.001063 **
## messept       4.976471  3.065380  1.6234 0.104495
## mesoct         1.562373  2.521001  0.6197 0.535427
## mesnov        -3.430616  2.557188 -1.3416 0.179739
## mesdic        -1.130204  2.128087 -0.5311 0.595357
## tendencia     0.187297  0.118728  1.5775 0.114673
## lag12         0.992596  0.040051 24.7835 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Regresión lineal con errores ARIMA: Ejemplo 1

Vemos el diagnóstico del moelo:

```
checkresiduals(modelo23)
```



```
##
```

```
## Ljung-Box test
```

```
##
```

```
## data: Residuals from Regression with ARIMA(2,0,0)(2,0,0)
```

```
## Q* = 45.447, df = 6, p-value = 3.814e-08
```

```
##
```

Considere las bases de datos del petróleo brent (con nombre **petroleo_brent_historico.csv**) y de la tasa representativa del mercado (**trm_historico.csv**) que se encuentran en la carpeta DATOS del Google Drive.

- 1 Lea ambas bases de datos.
- 2 Una las dos bases de datos en una sola BD.
- 3 Realice un gráfico donde aparezcan ambas series de tiempo.
- 4 Ajuste un modelo de regresión con los errores descritos por medio de un proceso ARIMA.
- 5 Realice un diagnóstico del modelo y saque conclusiones.